


7.4. Puntuacions factorials i ús als models predictius

Un cop definit el model definitiu, s'han calculat puntuacions factorials per regressió per a cada observació, bàsicament és una "nota" en cada factor que resumeix la posició de l'alumne en aquell constructe latent. Aquestes puntuacions substitueixen el conjunt de variables originals als models econòmics posteriors, resolent el problema de multicol·linealitat i reduint la dimensió de l'espai de predictors de forma interpretable.

Els factors resultants han rebut els noms definitius que s'usaran a la resta de l'estudi: *MOT_DESMOTIVACIO*, *MOT_AUTOGESTIO*, *MOT_FORCA_MAJOR* per al bloc Motius; *EST_QUALITAT_DOC*, *EST_AVALUACIO_AC*, *EST_TEMPS_CLASSE*, *EST_GRUPS_REDUIITS* per al bloc Estratègies; i *IA_EINA_ESTUDI* i *IA_SUBSTITUCIO* per al bloc IA.



8. Models explicatius

Fins aquí, l'anàlisi ha constatat primer d'entendre les dades (descriptiva i EDA) i després identificar l'estructura subjacent de les percepcions dels estudiants (EFA). El resultat d'aquests apartats és l'obtenció de factors que influeixen en l'absentisme. El pas següent és aprofitar-los per respondre les preguntes de fons del treball.

Concretament, l'anàlisi de models es divideix en dos blocs amb objectius diferenciats.

Aquest primer bloc té un enfocament explicatiu: l'objectiu és identificar quines variables tenen un efecte real i estadísticament significatiu sobre l'assistència, entendre la direcció i la magnitud d'aquest efecte, i construir una narrativa coherent sobre per què alguns estudiants no van a classe.

El lògit s'utilitzarà tant per a predir com per a explicar. La raó resideix en que, a diferència dels models de *machine learning*, que s'avaluen per la seva capacitat predictiva però no permeten fer inferència estadística formal, la regressió logística permet contrastar si l'efecte de cada variable és significativa i construir intervals de confiança per als odds ratios. Per aquest motiu, el logit d'aquest bloc s'estima sobre la mostra completa ($n = 342$).

8.1. Model logístic

8.1.1. Introducció i justificació del model

L'objectiu d'aquest model no és predir si un estudiant anirà o no anirà a classe, sinó identificar quines variables tenen un efecte real i estadísticament significatiu sobre l'assistència i quantificar-ne la magnitud. Per això s'utilitza la regressió logística binària estimada sobre la mostra completa ($n = 342$): a diferència dels models de *machine learning*, el logit proporciona estimadors amb propietats asimptòtiques conegudes que permeten fer inferència estadística, és a dir, contrastar si l'efecte de cada variable és significativament diferent de zero i construir intervals de confiança per als *odds ratios*². Els models predictius del bloc següent oferiran millor capacitat de classificació, però no aquesta interpretabilitat.

8.1.2. Selecció del model

La selecció de variables es fa en dues etapes. Primer, una eliminació *backward* per BIC a partir del model complet amb tots els factors de l'EFA i les variables acadèmiques i personals rellevants. El BIC és el criteri adequat per a un objectiu explicatiu perquè penalitza més la complexitat que l'AIC i tendeix a seleccionar menys variables.

El model seleccionat per BIC inclou set variables: MOT_DESMOTIVACIO, MOT_FORCA_MAJOR, EST_AVALUACIO_AC, IA_SUBST_num³, T_AVAL, CURS_1R i NOTA_num.

Segon, sobre el model seleccionat per BIC es proven possibles interaccions. L'única que resulta significativa és CURS_1R $\times$ MOT_DESMOTIVACIO ($LRT: \chi^2 = 8,79, p = 0,003, \Delta BIC = -2,96$), que s'incorpora al model final. La resta d'interaccions no aporten cap millora significativa.

² L'*odds ratio* mesura quantes vegades augmenten ($OR > 1$) o disminueixen ($OR < 1$) les probabilitats de ser regular per cada unitat d'increment en la variable explicativa, mantenint la resta constant.

³ IA_SUBST s'incorpora en forma Likert numèrica enlloc de la puntuació factorial de l'EFA perquè barrejava IA_SUBST amb IA_ATENC en un sol factor i feia que no fos significativa quan IA_SUBST sola si que ho és

8.1.3. Validació del model

Linealitat en el log-odds. El test de Box-Tidwell⁴ i els tests de ràtio de versemblança amb termes quadràtics confirmen que cap de les variables numèriques (EDAT, NOTA_num, IA_SUBST_num, MOT_DESMOTIVACIO) requereix transformació: en tots els casos el component quadràtic no és significatiu ($p > 0,15$) i el model lineal s'accepta.

Multicolinealitat (FIV). Tots els FIV queden entre 1,03 i 1,51, molt per sota del llindar de 5.

Bondat d'ajust. El test de Hosmer-Lemeshow⁵ no rebutja la hipòtesi nul·la de bon ajust en cap de les tres particions testades ($p = 0,70$; $p = 0,57$; $p = 0,84$). El calibration plot confirma visualment que les probabilitats predites s'alineen bé amb les proporcions observades. (Vegeu Annex 9)

Observacions influents. Sis observacions presenten residus de Pearson estandarditzats superiors a 2,5, de les quals dues destaquen especialment (observacions 196 i 316, amb residus de -4,6 i -4,7) (Vegeu Annex 10). L'anàlisi de sensibilitat exclou aquestes sis observacions i reestima el model.

Amb això s'obté que set dels vuit coeficients canvien menys d'un 20%, cosa que, seguint la convenció habitual a la literatura de regressió logística aplicada (Hosmer, Lemeshow, & Sturdivant, 2013), es considera indicatiu d'estabilitat. L'excepció és l'OR de T_AVAL, que passa de 8,23 a 15,10 (+83%), probablement perquè la categoria "avaluació única" és molt minoritària i uns pocs casos extrems mouen l'estimació. NOTA_num mostra un canvi proper al llindar del 20% (18,7%), tot i que la direcció i significació es mantenen sense cap problema.

⁴ El test de Box-Tidwell contrasta si la relació entre una variable numèrica i el log-odds és lineal, afegint termes $x \cdot \log(x)$ al model; si el coeficient és significatiu, la relació no és lineal.


⁵ El test de Hosmer-Lemeshow avalua la bondat d'ajust del logit dividint les observacions en grups per probabilitat predita i comparant les freqüències observades amb les predites mitjançant un test chi-quadrat; $p > 0,05$ indica bon ajust.

8.1.4. Resultats

Taula 1: Odds ratios i AME del model final

Variable	Or	Ic (95%)	AME
MOT_DESMOTIVACIO	0,472***	[0,331; 0,674]	-8,6 pp
IA_SUBST_num	0,687***	[0,580; 0,813]	-6,3 pp
MOT_FORCA_MAJOR	1,428**	[1,092; 1,868]	+5,9 pp
EST_AVALUACIO_AC	1,542**	[1,161; 2,047]	+7,2 pp
NOTA_num	1,624**	[1,169; 2,255]	+8,1 pp
CURS_1R	2,679**	[1,376; 5,220]	+18,7 pp
T_AVALContinuada	8,232**	[2,138; 31,700]	+35,5 pp
MOT_DESMOTIVACIO:CURS_1R	2,792**	[1,407; 5,540]	-

Nota: *** $p < 0,001$; ** $p < 0,01$; * $p < 0,05$. AME = efecte marginal promig, expressat en canvi de probabilitat mantenint la resta de variables a la mediana.




Gràfic 12: Odds-Ratios i IC del 95%

Desmotivació pedagògica (AME = -8,6 pp). Cada unitat addicional en el factor de desmotivació pedagògica (que recull la percepció de les classes com a avorrides, massa teòriques o amb un paper passiu de l'estudiant) redueix la probabilitat de ser regular en 8,6 punts percentuals. És el mecanisme actitudinal principal de l'absentisme que el model detecta.

Ús de la IA com a substitut d'anar a classe (AME = -6,3 pp). Cada punt addicional a l'escala IA_SUBST redueix la probabilitat de ser regular en 6,3 punts percentuals. Un estudiant que passa

de no percebre la IA com a alternativa (valor 1) a percebre-la com a alternativa total (valor 6) acumula una reducció de més de 30 punts percentuals en la seva probabilitat d'assistir regularment. Això confirma que la IA, per a una part de l'alumnat, ja no és només una eina d'estudi sinó una alternativa real a la classe.

Interacció desmotivació × primer curs (OR = 2,79). L'efecte de la desmotivació sobre l'assistència és significativament diferent entre els estudiants de primer i els de cursos superiors, tal i com es pot veure al Gràfic 13: per als de primer, la desmotivació té un impacte molt menor sobre l'assistència. Com s'ha comentat en apartats anteriors, una possible justificació és que els estudiants de primer any encara no han desenvolupat les estratègies alternatives (acadèmia, apunts externs, materials de cursos anteriors) que els de cursos superiors ja dominen, de manera que la desmotivació no es tradueix tan directament en absència.




Gràfic 13: Interacció entre MOT_DESMOTIVACIO i CURS_1R

Tipus d'avaluació (AME = +35,5 pp). Seguir l'avaluació continuada incrementa la probabilitat de ser regular en 35 punts percentuals. Quan l'assistència té conseqüències directes en la nota, l'alumnat assisteix.

Nota d'expedient i primer curs reforcen un patró coherent: els estudiants amb millor rendiment i els de primer any són els més regulars, cosa que apunta tant a motivació com a una percepció més alta del valor de la classe.

Força major (AME = +5,9 pp). Confirma el que ja mostrava l'EDA: els estudiants regulars falten per motius externs i involuntaris. La relació positiva amb l'assistència regular reforça que els irregulars s'absenten per raons actitudinals, no per circumstàncies fora del seu control.



Gràfic 14: Efectes Marginals Promig amb IC 95%

Els resultats del model logístic apunten a un patró clar: l'absentisme s'explica per percepcions i actituds envers la classe. Els dos factors amb efecte negatiu més gran (la desmotivació pedagògica i la percepció de la IA com a substitut de la classe) són ambdós de naturalesa actitudinal, cosa que suggereix que reduir l'absentisme requereix intervencions sobre el valor percebut de la presència a l'aula, no únicament canvis organitzatius.

El paper de la IA mereix una atenció especial: no actua com un factor de fons sinó com un competidor directe de la classe presencial, i el seu efecte és acumulatiu al llarg de l'escala.

En sentit contrari, l'avaluació continuada és el mecanisme amb més potencial: quan assistir té conseqüències directes en la nota, l'efecte sobre l'assistència és molt superior al de qualsevol altra variable del model. Finalment, la interacció entre desmotivació i curs indica que el problema s'agreuja amb el pas dels anys, de manera que les intervencions haurien de prioritzar els cursos superiors, on la desmotivació es tradueix més directament en absència.

8.2. Model d'equacions estructurals (SEM)

8.2.1. Introducció i justificació del model

El model logístic permet identificar quines variables tenen un efecte significatiu sobre l'assistència i quantificar-ne la magnitud, però presenta una limitació important: tracta tots els predictors com si fossin directament observables i independents entre ells. En canvi, bona part de les variables d'aquest estudi (les percepcions dels estudiants sobre les classes, la seva actitud envers la IA o les circumstàncies de força major) no s'observen directament sinó que estan latents a les respostes de les variables Likert.

Per aquest motiu s'utilitza un Model d'Equacions Estructurals (SEM), que permet modelar simultàniament dues coses: d'una banda, la relació entre els constructes latents (que no s'observen) i els indicadors observats. De l'altra, les relacions entre els propis constructes i la variable d'assistència per veure com es relacionen. A diferència de combinar una EFA amb una regressió en passos separats, el SEM estima tot de forma conjunta, de manera que l'error de mesura de les variables latents queda incorporat a l'estimació i no es transmet als coeficients estructurals.

Un altre avantatge rellevant és que el SEM permet contrastar si els resultats del logit es mantenen quan es modelitzen els constructes directament a partir dels ítems originals. Si ambdós models apunten en la mateixa direcció, voldrà dir que els resultats són robustos.

8.2.2. Metodologia i preparació del model

Constructes inclosos. A partir de l'EFA, s'han seleccionat quatre constructes latents:

- Desmotivació pedagògica (DESMOTIVACIO_PEDAG), format per cinc ítems de motius de no assistència de caràcter pedagògic (M_TEOR, M_PASSIU, M_AVORR, M_PROF, M_AMICS)
- Força major (FORCA_MAJOR), amb tres ítems que recullen motius d'absència involuntaris (M_SALUT, M_FAM, M_TREB)
- Avaluació contínua (AVALUACIO_AC), que mesura el pes que l'estudiant percep que té l'avaluació contínua com a incentiu d'assistència (E_ACT_AC, E_PES_AC, E_PART)
- Substitució per IA (IA_SUBSTITUCIO), que recull la percepció que la IA pot substituir la presència a classe (IA_SUBST, IA_ATENC, IA_CONF).

Estimador. S'ha optat per l'estimador WLSMV perquè, d'acord amb (Li, 2015), ofereix estimacions de les càrregues factorials menys esbiaixades i més precises que MLR robust de

forma consistent, independentment de la mida mostral, el nombre de categories i el grau de desviació de la normalitat. Tot i que WLSMV tendeix a sobreestimar moderadament les correlacions interfactorials en mostres petites, aquesta limitació no afecta a aquest estudi perquè està més centrat en els efectes sobre l'assistència i no tant en les relacions entre els constructes latents.


Validació del model de mesura (CFA)

Abans d'interpretar els resultats estructurals cal comprovar que els constructes latents estan ben definits, ja que en cas contrari els coeficients no serien fiables.

Els índexs d'ajust del CFA mostren un model de mesura sòlid: $CFI = 0,984$, $TLI = 0,979$, $RMSEA = 0,070$ [IC 95%: 0,058 – 0,082] i $SRMR = 0,070$ ⁶. Tots els índexs se situen dins dels llindars acceptables. Això vol dir que la forma en què els ítems s'agrupen en els quatre constructes és coherent amb les dades.

Les càrregues factorials estandarditzades (λ) de tots els ítems superen el llindar de 0,50, amb valors entre 0,60 (M_AMICS) i 0,97 (M_FAM), cosa que confirma que cada ítem mesura bé el constructe al qual pertany. La variància extreta mitjana (AVE) per constructe supera en tots els casos el llindar de 0,50: DESMOTIVACIO_PEDAG (0,579), FORCA_MAJOR (0,685), AVALUACIO_AC (0,617) i IA_SUBSTITUCIO (0,653). La fiabilitat composta (omega) oscil·la entre 0,770 i 0,846, totes per sobre del llindar habitual de 0,70, cosa que reforça la consistència interna de cada constructe.

⁶ Els criteris s'han extret d'aquests article: Li-tze Hu & Peter M. Bentler (1999): Cutoff criteria for fit indexes in covariance structure analysis: Conventional criteria versus new alternatives, Structural Equation Modeling: A Multidisciplinary Journal, 6:1, 1-55
https://www.researchgate.net/profile/Raouf_Mostafazadeh/post/Dear_respected_researchers_and_respected_Professors_do_you_have_access_to_any_or_both_of_these_articles_freely/attachment/59d6530c79197b80779ab183/AS%3A515263440986112%401499859785355/download/hu1999.pdf



Gràfic 15: Càrregues factorials estandaritzades del CFA per cada constructe

8.2.3. Resultats del model estructural

Comparació de models. El test de diferència de chi-quadrat entre el Model A (sense mediació) i el Model B (amb la ruta DESMOTIVACIO_PEDAG → AVALUACIO_AC → P_ASSIST⁷) no resulta significatiu ($\Delta\chi^2 = 3,04$; $\Delta df = 2$; $p = 0,219$). Això indica que DESMOTIVACIO_PEDAG no actua a través d'AVALUACIO_AC sinó que té un efecte directe sobre l'assistència. Per tant, el Model A (sense mediació) és el model final, per ser més parsimoniós i estadísticament equivalent al Model B.

L'ajust del model final és acceptable: $CFI = 0,964$, $TLI = 0,969$, $RMSEA = 0,077$ [0,069 – 0,087], $SRMR = 0,069$.

Coefficients estructurals. La Taula 2 recull els coeficients estandarditzats del model estructural. El predictor amb efecte més gran sobre el percentatge d'assistència és el tipus d'avaluació ($\beta = 0,351$, $p < 0,001$): quan un estudiant segueix avaluació contínua, el seu percentatge d'assistència és substancialment més alt, fet consistent amb el que ja mostrava el logit. En segon

⁷ Serveix per comprobar si la desmotivació pedagògica afecta l'assistència de forma directa o ho fa a través de l'avaluació continuada. És a dir, L'estudiant està desmotivats per això no li importa l'avaluació continuada i, per tant, falta més a classe.

lloc, la desmotivació pedagògica ($\beta = -0,263, p < 0,001$) confirma que els estudiants que perceben les classes com a avorrides, massa teòriques o poc participatives assisteixen menys. L'avaluació contínua com a incentiu ($\beta = 0,206, p < 0,001$), la nota ($\beta = 0,183, p < 0,001$) i si és de primer curs ($\beta = 0,178, p = 0,002$) mostren efectes positius i significatius, en la mateixa línia que el logit. La força major ($\beta = 0,198, p < 0,001$) té un efecte positiu, cosa que es llegeix igual que al logit: els regulars falten per raons involuntàries, no per actitud.

Taula 2: Coeficients estructurals del model SEM (variable dependent: percentatge d'assistència)


Variable	β est.	Efecte (pp)	IC 95%	p-valor	Signe
Tipus d'avaluació (T_AVAL_num)	0,351	+40	[29,0; 51,0]	< 0,001	+
Nota d'expedient (NOTA_num)	0,183	+6,1	[2,9; 9,3]	< 0,001	+
Primer curs (CURS_1R_d)	0,178	+12,2	[4,5; 19,9]	< 0,002	+
Desmotivació pedagògica	-0,263	-7,7	[-11,3; -4,0]	< 0,001	-
Força major	0,198	+5,8	[3,0; 8,5]	< 0,001	+
Avaluació contínua (incentiu)	0,206	+6,0	[3,1; 8,9]	< 0,001	+
Substitució per IA	0,004	+0,1	[-3,3; 3,5]	0,952	n.s.

Variable dependent: P_ASSIST (percentatge d'assistència, 0–100). Estimador: WLSMV. N = 342. $R^2 = 0,374$.

L'única variable que no resulta significativa és la substitució per IA ($\beta = 0,004, p = 0,952$). Això contrasta amb el logit, on IA_SUBST sí que era significativa. La discrepància s'explica per la diferència en el nivell de mesura: al logit s'introduïa com a variable Likert individual, ja que introduint el factor de l'EFA tampoc era significativa.

L'explicació és la mateixa que al lògit: quan s'agafa el constructe IA_SUBSTITUCIO perd el senyal específic que feia significativa la variable IA_SUBST en solitari, probablement perquè IA_ATENC i IA_CONF afegeixen soroll que dilata l'efecte.

8.2.4. Interpretació i connexió amb el logit



Gràfic 16: Comparació SEM vs. Logit — direccions i magnituds

La comparació sistemàtica entre el SEM i el logit resulta especialment rellevant perquè els dos models aborden la mateixa pregunta des d'angles complementaris. El logit treballa amb la variable P_ASSIST dicotomitzada i utilitza puntuacions factorials com a predictors; el SEM treballa amb P_ASSIST contínua i modelitza els constructes directament des dels ítems. Tot i les diferències metodològiques, els resultats de tots dos models coincideixen en direcció per a totes les variables, excepte l'efecte no significatiu de IA_SUBSTITUCIO al SEM, tal i com es pot observar tant al Gràfic 16 com a la Taula 3.

Taula 3: Comparació SEM vs. Logit — direccions i consistència entre ambdós models

Variable	Direcció SEM	Direcció Logit	Consistent
T_AVAL_num	+	+	Sí
DESMOTIVACIO_PEDAG	-	-	Sí
AVALUACIO_AC	+	+	Sí
NOTA_num	+	+	Sí
CURS_1R_d	+	+	Sí
FORCA_MAJOR	+	+	Sí
IA_SUBSTITUCIO	No significatiu	-	Parcial