

Doble grau en Economia i Estadística

Títol: Quan les aules es buiden: absència a la FEE en un context marcat per la intel·ligència artificial

Autora: Edurne Álvarez Ferrer

Directora: Esther Vayá Valcarce

Departament:

Convocatòria: Juliol de 2026



UNIVERSITAT DE
BARCELONA



UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Facultat de Matemàtiques i Estadística

Capítol I: Resum i paraules clau

Capítol II: Classificació AMS

Capítol III: Índex

Capítol I: Resum i paraules clau	3
Capítol II: Classificació AMS.....	3
Capítol III: Índex.....	4
Capítol V: Introducció.....	7
Capítol VI: Metodologia i dades	9
1. Disseny de l'estudi i variable objectiu	9
2. Recollida de dades i instrument	10
3. Descripció de les variables.....	11
4. Preprocessament de dades.....	13
4.1. Depuració i gestió dels missings	13
4.2. Detecció d'outliers	14
5. Anàlisi descriptiva.....	16
5.1. Variables analitzades.....	16
5.2. Estadístics utilitzats	16
5.3. Variable objectiu i definició de grups	16
5.4. Gràfics utilitzats	16
6. Anàlisi Exploratori de Dades (EDA).....	17
7. Anàlisi Factorial Exploratòria	18
8. Anàlisi inferencial i causal	19
8.1. Model logístic.....	20
8.2. Model d'equacions estructurals.....	21
9. Classificació i predicció	22
9.1. Regressió logística.....	23
9.2. Random Forest	24
9.3. Models Boosting	25
9.4. Support Vector Machine (SVM)	26
10. Anàlisi textual	27
11. Clustering i profiling	28

12. KNN Fuzzy-Aware	30
Capítol VII: Resultats.....	31
1. Resultats descriptius.....	31
1.1. Resultats acadèmics: nota i tipus d'avaluació	31
1.2. El paper del treball	32
1.3. Motius per no anar a classe i estratègies per anar-hi	33
1.4. El paper de la Intel·ligència Artificial	34
2. Resultats exploratoris	35
2.1. Variables categòriques	35
2.2. Variables numèriques.....	35
2.3. Variables de percepció	36
3. Anàlisi Factorial Explorària	38
3.1. Bloc 1 — Motius de no assistència	38
3.2. Bloc 2 — Estratègies docents.....	39
3.3. Bloc 3 — Ús de la IA	39
3.4. Puntuacions factorials i ús als models predictius	40
4. Anàlisi inferencial i causal	41
4.1. Model logístic.....	41
4.2. Resultats del model estructural.....	43
4.3. Comparació i síntesi dels models	45
5. Classificació i predicció	47
5.1. Model logístic.....	47
5.2. Random Forest	49
5.3. XGBoost.....	51
5.4. Support Vector Machine (SVM)	53
5.5. Síntesi bloc predictiu	54
6. Anàlisi textual	55
6.1. Experiències positives	55
6.2. Experiències negatives	55

6.3. Propostes de motivació.....	55
6.4. Comparativa EXP_POS vs. EXP_NEG	57
6.5. Connexió amb el bloc quantitatiu.....	57
7. Clustering i profiling	58
8. KNN Fuzzy-Aware	61
Capítol VIII: Propostes docents	62
Capítol IX: Conclusions	63
Capítol X: Agraïments	64
5. Bibliografia	66
Capítol XI: Annexos	67
1. Formulari i codificació de dades	67
2. Preprocessament.....	73
3. Descriptiva	74
4. EDA.....	75
5. EFA	78
6. Logit explicatiu	80
7. SEM.....	81
8. Logit predictiu	82
9. Random forest	83
10. Boosting	86
11. SVM.....	88
12. Anàlisi textual	90
13. Clustering i profiling	92

Capítol IV: Introducció

L'assistència a classe és un dels indicadors més estudiats actualment en l'àmbit universitari, i la seva relació amb el rendiment acadèmic ha estat documentada en múltiples treballs. Malgrat això, el fenomen de l'absentisme continua sent complex, a més de que no tots els estudiants falten a classe pels mateixos motius, ni en la mateixa mesura, ni tenen les mateixes conseqüències. Autors com Álvarez Pérez i López Aguilar assenyalen que l'absentisme és un obstacle important a la universitat actual, ja que entra en conflicte amb les premisses de l'Espai Europeu d'Educació Superior (EEES), on es prioritza l'aprenentatge autònom, la participació i la responsabilitat de l'estudiant en el seu procés formatiu. (Álvarez Pérez & López Aguilar, 2011)

Des de la pandèmia de la COVID-19, aquest problema s'ha tornat més greu: el pas forçat a la docència virtual va canviar sobtadament els hàbits d'estudi de molts estudiants i, un cop recuperada la presencialitat, els nivells d'assistència no han tornat als d'abans. A aquesta realitat s'hi ha sumat la introducció d'una nova eina tecnològica: intel·ligència artificial (IA) generativa com a eina d'ús habitual entre l'alumnat universitari. La integració d'aquesta tecnologia planteja nous desafiaments: la literatura recent adverteix d'una possible "penalització de l'aprenentatge" (*learning penalty*) (Strömberg, Lei, & Wu, 2026). En aquest estudi s'ha observat que, tot i que la IA permet als estudiants augmentar la productivitat a l'hora de fer tasques i treballs a casa, l'externalització de l'esforç cognitiu comporta menys aprenentatge real i, conseqüentment, una penalització significativa en les notes dels exàmens presencials. Aquesta nova facilitat acadèmica podria estar actuant com un nou incentiu per a l'absentisme, creant un perfil d'alumne que percep la IA com un substitut directe de les explicacions a l'aula.

Aquesta preocupació no és nova a la Facultat d'Economia i Empresa (FEE) de la Universitat de Barcelona: ja l'any 2022 es va dur a terme un estudi descriptiu sobre l'absentisme de l'alumnat de la facultat. Ara bé, els canvis en quatre anys han estat molt profunds degut a la IA. Per tant, és interessant veure si els factors que expliquen la no assistència a classe continuen sent els mateixos o si n'han aparegut de nous. De fet, aquest treball ha estat possible gràcies al suport rebut per part de l'equip deganal de la FEE, que un cop proposat el tema a la meva tutora – Vicedegana d'estudiants, ocupabilitat i innovació docent – va comunicar el tema a la resta de companys i donat l'interès del tema, van facilitar la difusió de l'enquesta a través dels canals oficials de la facultat.

Aquest treball té dos grans objectius: d'una banda, identificar els principals motius pels quals els estudiants de la FEE no assisteixen a classe; de l'altra, construir models que permetin predir si un alumne faltarà a classe per poder oferir-li solucions personalitzades abans que el problema es produeixi. No es tracta, per tant, d'un estudi purament predictiu, sinó d'una anàlisi que combina

un enfocament explicatiu – per quantificar l'efecte de cada factor sobre el comportament d'assistència – amb un bloc predictiu – per classificar estudiants en risc d'absentisme

Per assolir aquests objectius s'ha dissenyat una enquesta que pren com a punt de partida la que es va elaborar el 2022, ampliant-la amb variables rellevants identificades en estudis previs i incorporant un bloc específic sobre l'ús de la intel·ligència artificial. L'enquesta es va distribuir entre l'alumnat de grau de la FEE entre el febrer i l'abril de 2026, i la mostra final és de 342 estudiants. L'anàlisi combina tècniques estadístiques diverses: des de l'estadística descriptiva i els tests no paramètrics fins a l'anàlisi factorial exploratòria, model logístic, models d'equacions estructurals, algoritmes de *machine learning* (Random Forest, XGBoost, SVM), anàlisi textual i *clustering* difús (*Fuzzy C-Means*), tot processat amb el programari estadístic R

El treball s'estructura en els capítols següents: el Capítol III detalla la metodologia i el tractament de les dades; el Capítol IV presenta els resultats, organitzats en blocs descriptiu, exploratori, factorial, inferencial i causal, predictiu, textual i de *clustering*; i el Capítol V recull les conclusions.

Capítol V: Metodologia i dades

Per assolir els objectius d'aquest treball s'ha dut a terme una anàlisi quantitativa a partir de dades primàries recollides mitjançant enquesta. El procés combina diverses tècniques estadístiques i de mineria de dades: des de l'estadística descriptiva i tests no paramètrics de comparació de grups, fins a tècniques de reducció de la dimensionalitat (anàlisi factorial exploratòria) i models de classificació, tant explicatius com predictius. Tot el processament i l'anàlisi s'ha dut a terme amb el programari estadístic R. En els apartats següents es detalla el disseny de l'estudi, la procedència i estructura de les dades, el tractament previ que han requerit, i finalment la metodologia estadística aplicada per respondre a cada part de l'objectiu.

1. Disseny de l'estudi i variable objectiu

Per respondre a l'objectiu de l'estudi — identificar els motius d'absentisme i detectar perfils diferenciats d'estudiants —, s'ha optat per un disseny que combina un enfocament explicatiu (per quantificar l'efecte de cada factor sobre el comportament d'assistència) amb un enfocament predictiu (per classificar estudiants segons el seu perfil de risc d'absentisme).

La variable dependent és el percentatge d'assistència declarat per l'estudiant (P_ASSIST), una variable contínua entre 0 i 100. Ara bé, treballar directament amb aquesta variable contínua presenta un inconvenient pràctic: la seva distribució és asimètrica i acumulada als extrems, cosa que dificulta la modelització i la interpretació dels resultats. Per aquest motiu, s'ha optat per crear una variable binària ($GRUP_ASSIST$), que classifica els estudiants en dos grups: *regulars* ($P_ASSIST \geq 80\%$) i *irregulars* ($P_ASSIST < 80\%$). El llindar del 80% no és arbitrari: coincideix amb el mínim d'assistència que alguns plans docents de la facultat estableixen com a condició per a poder seguir l'avaluació continuada. Amb aquest criteri, un 56,7% dels enquestats es classifica com a regulars i un 43,3% com a irregulars, una distribució prou equilibrada que no genera problemes de classes desequilibrades en els models posteriors.

2. Recollida de dades i instrument

Les dades provenen d'una enquesta dissenyada específicament per a aquest estudi i distribuïda entre l'alumnat de grau de la FEE entre el febrer i l'abril del 2026. El formulari es va elaborar amb Microsoft Forms i es va difondre a través dels canals oficials de la facultat. La participació va ser voluntària i anònima.

L'enquesta es va difondre a través dels canals oficials de la facultat, una decisió que va sorgir de en proposar el tema d'aquest treball. Després de comentar-ho amb la meua tutora, Vicedegana d'Estudiants, Ocupabilitat i Innovació Docent de la FEE, ella mateixa ho va traslladar a l'equip deganal. Atès que es tracta d'un tema rellevant per a la facultat – i que ja s'havia abordat en un estudi anterior anys enrere – es va decidir difondre l'enquesta a través dels Campus Virtuals dels Plans d'Acció Tutorial (PAT) de cada grau, amb l'objectiu d'arribar al màxim d'alumnat possible.

La mostra final és de 342 estudiants. Tot i que la mida mostral permet aplicar els mètodes estadístics emprats en aquest treball i obtenir conclusions rellevants, cal tenir en compte que l'estudi presenta limitacions pel que fa a la capacitat de generalitzar els resultats al conjunt de l'alumnat de la FEE.

L'enquesta es va estructurar en quatre seccions diferenciades. La primera recull informació acadèmica bàsica: grau, curs, nombre d'assignatures matriculades, nota mitjana d'expedient, tipus d'avaluació i percentatge d'assistència. La segona secció captura la situació personal de l'estudiant: gènere, edat, dedicació laboral i temps de desplaçament fins a la facultat. La tercera, que és la part més important del qüestionari, conté dos blocs de preguntes en escala Likert: un sobre els motius per no assistir a classe (15 ítems) i un altre sobre les estratègies que implementa l'alumnat a l'hora de decidir perquè va o deixa d'anar a una classe (13 ítems), a més de tres preguntes obertes on podien parlar d'experiències positives, negatives o propostes de millora. Finalment, la quarta secció és la més innovadora i recull la percepció de l'estudiant sobre l'ús de la intel·ligència artificial i el seu impacte en els hàbits d'estudi (8 ítems Likert). (Vegeu l'enquesta completa a l'Annex 1)

3. Descripció de les variables

Variables acadèmiques i de rendiment. La nota mitjana d'expedient (NOTA) es recull en format ordinal amb cinc categories: 1=[5-5,9], 2=[6-6,9], 3=[7-7,9], 4=[8-8,9] i 5=[≥9]. Tot i la naturalesa ordinal, s'ha tractat com a variable numèrica discreta en els models, de manera que el valor 1 representa la franja de notes més baixa i el 5 la més alta. El tipus d'avaluació (T_AVAL) és dicotòmica: única (0) o continuada (1), i constitueix una de les variables amb més poder explicatiu de l'absentisme al llarg de tota l'anàlisi. El nombre d'assignatures matriculades (N_ASSIG) és una variable numèrica discreta que actua com a indicador indirecte de la càrrega acadèmica.

Finalment, el grau cursat (GRAU) i el curs (CURS) completen la situació acadèmica de l'enquestat: el primer és una variable categòrica nominal amb deu categories (incloent-hi els dobles graus), mentre que el segon és ordinal, de 1r a "a partir de 6è".

Variables de situació personal i laboral. La dedicació als estudis (DEDIC) recull quatre categories: estudiant a temps complet, treballa ocasionalment, treballa a temps parcial i treballa a temps complet. El temps de desplaçament (DESPL) és numèric continu, mesurat en minuts, i presenta alguns valors extrems que s'han tractat en la fase de preprocessament.

Finalment, el gènere (GENERE) i l'edat (EDAT) completen la descripció sociodemogràfica: la primera és una variable categòrica nominal amb quatre categories (dona, home, no binari, prefereixo no respondre), i la segona es recull de forma numèrica entera.

Variables de percepció: motius per no assistir a classe. El bloc de motius recull 15 ítems (variables *M_*) mesurats en escala Likert d'1 (Gens d'acord) a 5 (Totalment d'acord), que demanen a l'enquestat fins a quin punt cada motiu explica la seva no assistència a classe. Els ítems cobreixen causes de naturalesa molt diversa: laborals i familiars (*M_TREB*, *M_FAM*), de salut (*M_SALUT*), per la distància (*M_DIST*), d'autonomia en l'estudi (*M_AUTON*, *M_CV*), estratègiques en relació a l'avaluació (*M_EXAM*, *M_UTIL*, *M_REPET*), i de percepció sobre les classes i el professorat (*M_AVORR*, *M_PASSIU*, *M_TEOR*, *M_PROF*, *M_ACAD*, *M_AMICS*). Cal aclarir que està en escala de l'1 al 5 i no fins al 6 per un error en el disseny de l'enquesta.

Variables de percepció: estratègies docents que afavoreixen l'assistència. El bloc d'estratègies recull 13 ítems (variables *E_*) amb l'escala Likert d'1 a 6, que demanen a l'enquestat en quina mesura determinades pràctiques docents l'animen més a assistir a classe. Inclou aspectes relacionats amb l'avaluació (*E_PES_AC*, *E_PES_AS*), amb la metodologia i la dinàmica de classe (*E_PART*, *E_DINAM*, *E_REDU*, *E_ACT_AC*), amb l'estructura i durada (*E_CURT*, *E_DESC*,

E_RITME), amb el clima i la relació amb el professorat (E_CLIMA, E_EXPL, E_PROP), i amb aspectes organitzatius (E_HORA).

Variables de resposta oberta. El qüestionari inclou tres preguntes de text lliure que recullen informació qualitativa: l'experiència positiva amb alguna assignatura (EXP_POS), l'experiència negativa que ha portat a no assistir a classe (EXP_NEG) i les propostes de l'alumnat per motivar l'assistència (PROP_MOT). Aquestes variables no es poden incloure en els models, però s'utilitzaran per fer anàlisi textual i buscar la seva relació amb els resultats que s'obtinguin.

Ús de la intel·ligència artificial. El bloc d'IA recull 8 ítems (variables IA_) mesurats en la mateixa escala Likert d'1 (Gens d'acord) a 6 (Totalment d'acord), que cobreixen aspectes de la relació de l'estudiant amb aquestes eines: la freqüència d'ús (IA_HABIT), la utilitat per entendre continguts (IA_COMPR), la percepció de substitució de l'assistència a classe (IA_SUBST), el grau de confiança sense contrastar la informació (IA_CONF), la pèrdua d'atenció a classe per dependència de la IA (IA_ATENC), la preocupació per l'aprenentatge real (IA_PREOC), la percepció de millora del rendiment (IA_REND) i l'ús per contextualitzar material propi (IA_PDFS).

Codificació i tractament. La matriu de codificació completa es recull a l'Annex 2. Les variables Likert es tracten com a ordinals en els tests no paramètrics i com a numèriques contínues quan s'incorporen als factors de l'EFA.

4. Preprocessament de dades


El següent pas abans d'iniciar el modelatge és netejar les dades. L'objectiu d'aquest apartat és trobar els errors i possibles dades que puguin causar errors o distorsions en el model. Per això, s'han revisat sistemàticament tant els valors faltants com els valors atípics (*outliers*).

4.1. Depuració i gestió dels missings

El primer pas ha consistit en una revisió de la consistència de les dades. En filtrar les variables numèriques per trobar possibles valors anòmals, s'ha detectat un cas amb un temps de desplaçament (DESPL) de 605 minuts (vegeu Annex 3), és a dir, més de 10 hores de trajecte fins a la facultat. Atès que aquest valor és pràcticament impossible, s'ha interpretat com un error tipogràfic en el moment d'emplenar el formulari.

Per tenir més context d'aquest cas, s'ha consultat la resposta de text obert del mateix estudiant, on comenta que triga molt a arribar a la facultat. A partir d'aquesta informació, s'ha optat per imputar manualment un valor de 65 minuts, una xifra coherent amb el context de la resposta. Alternativament, s'havia provat una imputació amb el mètode MICE, que donava un resultat de 40 minuts, però aquesta xifra s'ha descartat per no ajustar-se tan bé al que l'estudiant descrivia.

Pel que fa als valors absents, s'han mirat totes les variables per identificar on es concentraven les dades faltants i decidir com tractar-les en cada cas. El gràfic següent mostra el percentatge de NA per variable:



Font: elaboració pròpia

S'ha observat que les variables on falten respostes són les de caràcter obert (PROP_MOT, EXP_NEG, EXP_POS), amb percentatges que oscil·len entre el 60,8% i el 66,4%. Cal destacar que aquestes preguntes eren de resposta lliure i que únicament s'utilitzaran per fer l'anàlisi textual.


4.2. Detecció d'outliers

En aquesta base de dades es disposa d'una mostra mixta (variables numèriques i ordinals tipus Likert). Per aquest motiu, s'ha optat per una metodologia robusta en dues etapes:

1. **Distància de Gower:** s'ha calculat una matriu de distàncies utilitzant la distància de Gower que, a diferència de la distància euclidiana, aquesta és idònia per a dades mixtes, ja que permet ponderar correctament les variables categòriques i les escales Likert sense necessitat de transformar-les artificialment en numèriques contínues.
2. **Local Outlier Factor (LOF):** sobre aquesta matriu, s'ha aplicat l'algorisme LOF. Aquest mètode funciona bé perquè mesura la densitat local d'una observació respecte als seus veïns, de manera que aquells individus que estiguin més allunyats dels seus veïns, poden ser "estranyos".

Per garantir la robustesa, s'ha testejat l'algorisme amb diferents valors de veïns ($k=5, 10, 15, 18, 20$). El criteri per considerar una observació com a *outlier* ha estat un *LOF score* superior a 2. Els resultats mostren una gran estabilitat de la mostra: amb $k=18$ (l'arrel quadrada de n), només s'identifica una única observació (índex 153) com a potencial valor atípic, però té un *score* inferior a 2.

Gràfic 2: LOF score amb distància de Gower



Font: elaboració pròpia

L'observació 153 correspon a una dona de 20 anys amb una nota excel·lent que cursa 10 assignatures simultàniament. Tot i que és un perfil poc freqüent, no representa un error de mesura ni un valor impossible. Per tant, s'ha pres la decisió de mantenir-la a la mostra, ja que la seva eliminació podria treure variabilitat rellevant a l'estudi del perfil d'alt rendiment.

Finalment, convé assenyalar una decisió metodològica clau. Inicialment, es va considerar l'aplicació d'una Anàlisi Factorial de Dades Mixtes (*Factor analysis of mixed data: FAMD*) prèvia al càlcul del LOF, amb l'objectiu de reduir la dimensionalitat del conjunt de dades per poder aplicar un altre mètode de detecció d'outliers multivariants, el *Mahalanobis* robust. No obstant això, aquesta via es va descartar en la fase exploratòria, ja que calia retenir un nombre de

dimensions excessivament elevat per assolir un percentatge de variància explicada acceptable (al voltant del 70%).

Donat que l'objectiu inicial era considerar realment com *outliers*, aquelles observacions que es detectessin amb els dos mètodes, finalment el criteri de detecció s'ha basat únicament en els resultats del LOF.

5. Anàlisi descriptiva

Abans d'entrar en els models predictius, és fonamental entendre les dades amb les quals es treballa. L'objectiu d'aquesta secció és identificar quins patrons separen els estudiants que van a classe regularment dels que no ho fan, i obtenir una visió preliminar de quines variables poden ser rellevants a l'hora de modelar. A continuació es presenten les variables analitzades i els estadístics i gràfics emprats.

5.1. Variables analitzades

Les variables analitzades es poden agrupar en tres blocs: variables numèriques (edat, temps de desplaçament, nombre d'assignatures i percentatge d'assistència), variables categòriques (gènere, curs, grau, dedicació laboral i tipus d'avaluació) i variables Likert (motius de no assistència, estratègies per anar a classe i ús de la intel·ligència artificial).

5.2. Estadístics utilitzats

Per a les variables numèriques s'han calculat la mitjana, la mediana, la desviació estàndard, el mínim i el màxim. Per a les variables Likert, s'ha comparat la mitjana de cada ítem entre els dos grups (regulars i irregulars) per identificar on hi ha les diferències més grans. Aquest apartat és purament descriptiu i l'objectiu és detectar quins ítems mostren un patró diferenciat entre grups. La significació d'aquestes diferències es contrasta en el següent apartat, mitjançant el test de Mann-Whitney.

5.3. Variable objectiu i definició de grups

Tot i que es disposa de la variable contínua (percentatge d'assistència), com s'ha explicat a l'apartat 1, per a l'anàlisi s'utilitza la variable dicotòmica GRUP_ASSIST (regulars/irregulars, amb llinar al 80%).

5.4. Gràfics utilitzats

S'han emprat box-plots per comparar la distribució del percentatge d'assistència entre grups, gràfics de barres apilades per a variables categòriques, i gràfics de barres de doble columna per comparar les mitjanes dels ítems Likert entre regulars i irregulars. A l'annex es recullen *heatmaps* per curs i grau, que, tot i apuntar patrons interessants, presenten cel·les amb mida mostral molt reduïda i poden induir a interpretacions errònies si no es miren amb perspectiva global.

Per tal de no desviar l'atenció dels resultats més determinants, s'ha optat per moure a l'annex aquells gràfics on les diferències entre grups són mínimes. És el cas de l'edat i del gènere, dues variables que, malgrat haver-se explorat visualment, no mostren contrastos rellevants entre estudiants regulars i irregulars.

6. Anàlisi Exploratori de Dades (EDA)

Aquest apartat busca identificar quines variables es relacionen amb l'assistència i detectar patrons o redundàncies que puguin condicionar els models posteriors. Atesa la naturalesa de les dades (majoritàriament categòriques i ordinals en escala Likert), s'han aplicat exclusivament contrastos no paramètrics¹.

La metodologia es divideix en tres eixos:

- **Associació entre variables categòriques i l'assistència:** s'utilitza el test Chi-quadrat i la *V de Cramér* com a mesura de la intensitat de l'associació². Els resultats relatius a GRAU s'interpreten amb cautela, donat l'elevat nombre de categories i la baixa freqüència en algunes cel·les; per a aquesta dimensió es prioritza la variable agrupada DOBLE_GRAU_EST.
- **Relació entre variables Likert i numèriques amb l'assistència:** s'utilitza el test de Mann-Whitney U i la correlació rang-biserial (r) com a mesura d'efecte, que indica magnitud i direcció de la diferència entre grups (positiu = regulars puntuen més alt). Donada l'elevada presència d'empats en totes les variables Likert, es reporta també la τ de Kendall com a contrast de robustesa³.
- **Correlació de les variables numèriques amb el percentatge d'assistència:** s'utilitza la correlació de Spearman i, en els casos amb empats superiors al 10%, la τ de Kendall. P_ASSIST s'exclou de la comparació amb GRUP_ASSIST, ja que aquesta darrera deriva directament de la primera.

Cal destacar que, prèviament a l'anàlisi, s'han creat variables categòriques noves a partir dels resultats de la descriptiva, agrupant categories amb patrons d'assistència similars per facilitar la seva interpretació i posterior ús als models. Aquestes variables són: TREB_INTENS (1 si treballa a temps parcial o complet), NOTA_ALTA (1 si nota > 8), CURS_1R (1 si és de primer curs) i DOBLE_GRAU_EST (1 si estudia doble grau o Estadística).

¹ Les variables no compleixen els supòsits de normalitat ni homoscedasticitat necessaris per als tests paramètrics clàssics.

² Aquesta mesura és independent de la mida mostral. En els casos amb cel·les de freqüència esperada inferior a 5 (condició que invalida l'aproximació asimptòtica del Chi-quadrat), s'ha aplicat una simulació de Monte Carlo ($B=10.000$) per garantir la validesa dels p-valors; en cap cas hi ha hagut canvis de significació respecte al test estàndard.

³ La τ de Kendall és més adequada que Spearman en distribucions amb molts valors repetits, com és el cas de les escales Likert.

7. Anàlisi Factorial Exploratòria

Les variables de percepció (motius, estratègies, ús de la IA) mesuren aspectes molt propers entre si, i introduir-les de forma aïllada als models generaria multicol·linealitat. Per això s'aplica una anàlisi exploratòria de les dades (*Exploratory Factor Analysis*: EFA) a cada bloc per separat, que busca constructes latents interpretables, com la desmotivació pedagògica o la dependència de la IA. Es pot llegir més informació sobre l'anàlisi factorial exploratòria en aquest article: (Watkins, 2018). Aquest apartat s'ha redactat seguint les bones pràctiques que recomana.

Els contrastos que verifiquen si les dades presenten una bona estructura correlacional⁴ han estat superats pels tres blocs. El KMO ha estat entre 0,82 i 0,85 i el test de Bartlett ha estat significatiu en tots els casos, $p < 0,001$).

Per determinar el nombre de factors s'ha aplicat l'anàlisi paral·lela, i per a la seva interpretació s'ha utilitzat una rotació obliqua (*oblimin*) atès que permet la correlació entre factors i els constructes avaluats estan interrelacionats.⁵

S'han mantingut fora de l'EFA cinc variables amb comunalitat⁶ molt baixa (a l'article es consideren baixes si estan per sota de 0,3 o 0,4) i sense diferències significatives a l'EDA (M_ACAD: $h^2 = 0,17$, E_PES_AS: $h^2 = 0,26$, IA_PREOC: $h^2 = 0,21$), i les variables M_DIST ($h^2 = 0,22$) i E_HORA ($h^2 = 0,22$) que si eren significatives a l'anàlisi exploratòria de les dades.

Un cop refeta l'anàlisi, s'ha forçat el nombre final de factors a 3 (Motius) i 4 (Estratègies), ja que el factor addicional suggerit en cada cas resultava residual (explicant menys que d'un 4% de variabilitat). El bloc IA queda fixat en 2 factors de forma natural una vegada extreta la variable IA_PREOC.

⁴ El test de Bartlett, contrasta la hipòtesi nul·la que la matriu de correlacions és una matriu identitat —és a dir, que no hi ha cap correlació entre variables—, i el KMO (Kaiser-Meyer-Olkin) compara les correlacions totals amb les parcials, indicant si la relació entre variables es deu a factors comuns globals o només a connexions aïllades entre elles

⁵ L'anàlisi paral·lela compara els valors propis observats amb els d'una matriu de dades aleatòria de la mateixa mida, retenint només els factors que superen aquests valors aleatoris.

⁶ La comunalitat és la variabilitat total d'una variable explicada pels factors latents comuns.

8. Anàlisi inferencial i causal

Fins aquí, l'anàlisi ha consistit a entendre les dades (descriptiva i anàlisi exploratòria de les dades) i identificar l'estructura latent de les percepcions dels estudiants (anàlisi exploratòria de factors). El pas següent és aprofitar aquests factors i la resta de variables per respondre el primer gran objectiu del treball: identificar quines variables tenen un efecte real sobre l'assistència, quina és la seva magnitud i direcció, i com s'articulen entre elles per explicar per què alguns estudiants no van a classe.

Aquest bloc es divideix en dos models amb objectius diferenciats. El Model d'Equacions Estructurals (*Structural Equation Model*: SEM) permet anar més enllà de la correlació i contrastar relacions causals directes i indirectes entre factors, cosa que cap dels mètodes anteriors permetia fer. El Logit, en canvi, s'utilitza per quantificar l'efecte individual de cada variable sobre la probabilitat de ser un estudiant irregular: a diferència dels models de *machine learning*, permet fer inferència estadística formal – contrastar significació, estimar *odds ratios* i construir intervals de confiança –, i per aquest motiu s'estima sobre la mostra completa ($n=342$).

8.1. Model logístic

L'objectiu d'aquest model no és predir si un estudiant anirà o no a classe, sinó identificar quines variables tenen un efecte estadísticament significatiu sobre l'assistència i quantificar-ne la magnitud. Per això s'estima sobre la mostra completa ($n = 342$): a diferència dels models de *machine learning* del bloc següent, el logit permet fer inferència formal, és a dir, contrastar la significació de cada variable i construir intervals de confiança per als *odds ratios*⁷.

La selecció de variables s'ha fet en dues etapes. Primer, una eliminació *backward* per BIC a partir del model complet – el BIC és l'adequat perquè tendeix a models més parsimoniosos –. Durant el procés, s'ha comparat mantenir el factor IA_SUBSTITUCIO agregat de l'EFA o substituir-lo per IA_SUBST_num (la variable original en format Likert). El model amb IA_SUBST_num individual obté un BIC de 399,69 davant del 409,60 del model amb el factor agregat, una diferència de 10 punts prou gran per decantar-se per la versió amb les variables crues⁸. El model seleccionat per BIC inclou set variables: MOT_DESMOTIVACIO, MOT_FORCA_MAJOR, EST_AVALUACIO_AC, IA_SUBST_num, T_AVAL, CURS_1R i NOTA_num.

I segona etapa: sobre aquest model s'han provat possibles interaccions: l'única que millora el BIC i resulta significativa és CURS_1R $\times$ MOT_DESMOTIVACIO ($\chi^2 = 8,79, p = 0,003, \Delta BIC = -2,96$), que s'incorpora al model final.

La validació confirma que el model és adequat. Tots els FIV queden entre 1,03 i 1,51, molt per sota del llindar de 5, de manera que no hi ha multicol·linealitat. El test de Hosmer-Lemeshow⁹ no rebutja el bon ajust en cap de les tres particions testades ($p = 0,70; p = 0,57; p = 0,84$), i el *calibration plot* ho confirma visualment (Annex 15). Sis observacions presenten residus de Pearson estandarditzats superiors a 2,5, de les quals dues destaquen especialment (observacions 196 i 316, amb residus de -4,6 i -4,7, vegeu Annex 16). L'anàlisi de sensibilitat sense aquestes sis observacions mostra que set dels vuit coeficients canvien menys d'un 20%, cosa que la literatura considera indicatiu d'estabilitat (Hosmer, Lemeshow, & Sturdivant, 2013). L'excepció és T_AVAL, on l'OR passa de 8,23 a 15,10 (+83%), probablement perquè la categoria d'avaluació única és molt minoritària ($n = 24$) i uns pocs casos extrems mouen l'estimació, però la direcció i la significació es mantenen intactes (per l'anàlisi de sensibilitat vegeu Annex 17).

⁷ L'*odds ratio* mesura quantes vegades augmenten ($OR > 1$) o disminueixen ($OR < 1$) les probabilitats de ser regular per cada unitat d'increment en la variable explicativa, mantenint la resta constant.

⁸ Cal remarcar que la selecció de IA_SUBST_num en lloc del factor IA_SUBSTITUCIO implica l'exclusió de MOT_AUTOGESTIO del model final: Això no vol dir que sigui irrellevant, sinó que en el context explicatiu no aporta prou informació addicional neta.

⁹ El test de Hosmer-Lemeshow avalua la bondat d'ajust del logit dividint les observacions en grups per probabilitat predita i comparant les freqüències observades amb les predites mitjançant un test chi-quadrat; $p > 0,05$ indica bon ajust.

8.2. Model d'equacions estructurals

El model logístic tracta tots els predictors com a directament observables. Les percepcions dels estudiants, en canvi, són constructes latents que no s'observen directament sinó a través de les respostes Likert. El Model d'Equacions estructurals (*Structural equation modeling*: SEM) resol això modelant simultàniament la relació entre els ítems i els constructes latents (model de mesura) i la relació entre aquests constructes i l'assistència (model estructural), incorporant l'error de mesura a l'estimació. A més, permet contrastar si els resultats del logit es mantenen quan es modelen els constructes directament a partir dels ítems originals.

S'han inclòs quatre constructes latents derivats de l'EFA: desmotivació pedagògica (M_TEOR, M_PASSIU, M_AVORR, M_PROF, M_AMICS), força major (M_SALUT, M_FAM, M_TREB), avaluació activa (E_ACT_AC, E_PES_AC, E_PART) i substitució per IA (IA_SUBST, IA_CONF).

S'ha usat l'estimador WLSMV¹⁰, recomanat per a dades ordinals perquè ofereix estimacions menys esbiaixades que MLR¹¹ robust independentment de la mida mostral i el grau de desviació de la normalitat (Li, 2015). Tot i que WLSMV pot sobreestimar les correlacions interfactorials en mostres petites, això no afecta els resultats perquè l'interès del model recau en els efectes sobre l'assistència, no en les relacions entre constructes.

Per facilitar la interpretació dels indicadors, l'Annex 18 inclou una breu descripció dels principals índexs d'ajust, validesa i fiabilitat emprats.

Els índexs d'ajust del CFA confirmen un model de mesura sòlid: $CFI = 0,986$, $TLI = 0,982$, $RMSEA = 0,063[0,050; 0,077]$, $SRMR = 0,066$, tots dins dels llindars acceptables¹². Les càrregues factorials estandarditzades oscil·len entre 0,58 (M_AMICS) i 0,97 (M_FAM), totes per sobre del llindar de 0,50.

L'AVE (*Average Variance Extracted*) supera 0,50 en tots els constructes: DESMOTIVACIO_PEDAG (0,578), FORCA_MAJOR (0,685), AVALUACIO_AC (0,617) i IA_SUBSTITUCIO (0,618), i la fiabilitat composta (omega) oscil·la entre 0,769 i 0,845, per sobre del llindar de 0,70. El model de mesura és, per tant, adequat per procedir a l'estimació estructural.

¹⁰ WLSMV (*Weighted Least Squares Mean and Variance adjusted*) és un estimador de mínims quadrats ponderats dissenyat específicament per a variables ordinals, perquè treballa sobre la matriu de correlacions policòriques.

¹¹ MLR (*Maximum Likelihood Robust*) és l'alternativa basada en màxima versemblança amb correccions de robustesa, però assumeix variables contínues i normalitat aproximada, supòsits que les escales Likert no compleixen.

¹² Criteris d'ajust següent (Hu & Bentler, 1999) CFI i $TLI \geq 0,95$; $RMSEA \leq 0,08$; $SRMR \leq 0,08$.

9. Classificació i predicció

La distinció entre model explicatiu i predictiu no és trivial. En un model explicatiu, la prioritat és la interpretabilitat dels coeficients; en un model predictiu, la prioritat és la capacitat de generalitzar a noves observacions. Això implica decisions metodològiques diferents: cal evitar el sobreajustament, avaluar el model fora de la mostra i calibrar el llindar de classificació en funció del cost dels errors.

La mostra es divideix en *train* i *test* seguint una proporció 80/20 amb partició estratificada per la variable resposta, garantint que la distribució de classes es manté equilibrada en tots dos conjunts. Aquesta partició és la mateixa per a tots els models, cosa imprescindible per comparar-los de forma justa.

En classificació binària, el llindar de 0,5 per defecte no acostuma a ser òptim. En aquest context, classificar erròniament un estudiant irregular com a regular (fals positiu) és més costós que l'error invers, perquè deixa sense intervenció un estudiant que podria necessitar suport, ja que el model diu que cau en el grup de Regulars. Per aquest motiu, el llindar òptim es determina maximitzant la precisió amb una restricció mínima de *recall* de 0,60. En tots els models, el llindar s'estima a partir de la corba *Precision-Recall* sobre probabilitats generades fora de la mostra d'entrenament – via probabilitats *out-of-bag* (OOB) ¹³ en el *Random Forest* o *out-of-fold* (OOF) ¹⁴ en la resta –. El mecanisme específic de cada model es detalla als apartats corresponents. Les mètriques finals es reporten sempre sobre el conjunt de test, que no ha participat en cap fase de construcció ni calibratge.

¹³ *Out-of-Bag* (OOB): En un *Random Forest*, són les observacions que no han estat seleccionades en la mostra bootstrap utilitzada per entrenar un arbre concret.

¹⁴ *Out-of-Fold* (OOF): Són les prediccions obtingudes sobre les observacions que queden fora del conjunt d'entrenament en cada iteració de la validació creuada.

9.1. Regressió logística

L'objectiu d'aquest model és diferent al del logit explicatiu: aquí no interessa la interpretabilitat dels coeficients sinó la capacitat de classificar correctament estudiants en risc d'absentisme sobre dades no vistes. S'opta de nou per la regressió logística per coherència metodològica amb l'anàlisi explicativa i perquè, amb una mostra de 274 observacions al *train*, models més complexos com el *Random Forest* requereixen una validació més exigent per garantir que els resultats generalitzen bé.

La selecció de variables s'ha fet per *backward* AIC – enlloc del BIC usat al model explicatiu –, perquè l'AIC penalitza menys la complexitat i tendeix a retenir més variables, cosa que és adequada quan l'objectiu és predictiu. El model complet de partida inclou tots els factors de l'EFA, les variables Likert individuals d'IA i totes les variables personals i acadèmiques rellevants. El procés d'eliminació *backward* ha resultat en un model amb 9 predictors i $AIC = 299,47$: MOT_DESMOTIVACIO, MOT_FORCA_MAJOR, EST_AVALUACIO_AC, T_AVAL, CURS_1R, DOBLE_GRAU_EST, EDAT, NOTA_num i IA_SUBST_num.

S'ha provat també incorporar la interacció $MOT_DESMOTIVACIO \times CURS_1R$, que el *backward* AIC reté i millora l'AIC fins a 293,55. Tot i això, al conjunt de test el *recall* cau a 0,463, per sota de la restricció mínima de 0,60 establerta per al conjunt de models predictius, també cau el F1 i el llindar de classificació es col·loca per sobre del 0,7 convertint-se en un model massa conservador. Per aquest motiu, el model final és el model sense interacció, que compleix la restricció (*recall* = 0,561) i obté una F1 superior (0,697 vs 0,623). Que la interacció sigui rellevant explicativament però no millori la predicció és en si mateix un resultat: captura un patró real a les dades però que no generalitza prou bé a noves observacions.

El llindar de classificació s'ha estimat a partir de la corba *Precision-Recall* sobre probabilitats OOF, amb la restricció $recall \geq 0,60$, resultant en un llindar de 0,6617. La validació s'ha fet amb *repeated 5×10-fold CV* (50 iteracions), que proporciona estimacions estables de les mètriques sobre el *train*.

9.2. Random Forest

El *Random Forest* és un algorisme d'aprenentatge automàtic supervisat basat en la construcció de múltiples arbres de decisió. Cada arbre s'entrena sobre una mostra bootstrap del conjunt d'entrenament i en cada divisió de node només considera un subconjunt aleatori de variables predictores (paràmetre *mtry*). La predicció final és la mitjana de les prediccions individuals de tots els arbres, cosa que redueix la variància i millora la generalització respecte a un únic arbre. Aquesta lògica d'ensemblatge fa el *Random Forest* més robust que el lògit davant relacions no lineals i interaccions entre variables, sense necessitat d'especificar-les explícitament.

S'han estimat dos models paral·lels. El RF-A utilitza 17 predictors: les variables del lògit predictiu més factors de l'EFA exclosos (MOT_AUTOGESTIO, IA_EINA_ESTUDI, EST_QUALITAT_DOC, EST_TEMPS_CLASSE, EST_GRUPS_REDUIITS). El RF-B substitueix els factors per les variables Likert originals significatives a l'EDA ($p < 0,05$, Mann-Whitney). L'objectiu és avaluar si la síntesi dimensional de l'EFA aporta millor capacitat predictiva que les variables individuals en brut. La partició *train/test* és la mateixa que al logit per garantir la comparabilitat.

Els hiperparàmetres s'han seleccionat per *grid search* avaluat amb l'AUC OOB. Per al RF-A s'ha provat ($mtry \in \{4, 5, 8, 10, 17\}$, $min.node.size \in \{5, 10, 15\}$, i $num.trees \in \{10, 100, 250, 300, 500, 1000\}$), la combinació guanyadora és $mtry = 5$, $min.node.size = 15$, $num.trees = 500$ ($AUC OOB = 0,765$). Per al RF-B ($mtry$ ampliat fins a 26), el millor model és $mtry = 26$, $min.node.size = 10$, $num.trees = 100$ ($AUC OOB = 0,790$). El llindar de classificació s'estima igual que al lògit – corba PR sobre probabilitats OOB amb restricció $recall \geq 0,60$ –, resultant en 0,569 per al RF-A i 0,604 per al RF-B.

9.3. Models Boosting

A diferència del *Random Forest*, que construeix arbres en paral·lel i fa la mitjana de les prediccions, el *XGBoost* i el *CatBoost* els construeixen de forma seqüencial: cada arbre nou s'entrena per corregir els errors del model anterior. Això els fa més expressius però també més sensibles a l'*overfitting* si no es regularitzen adequadament. La seva inclusió respon a un objectiu comparatiu: verificar si un algorisme de *boosting* millora la capacitat predictiva del RF-A amb una estructura de predictors equivalent.

S'utilitzen els mateixos 17 predictors que el RF-A. Els paràmetres fixats a priori per al *XGBoost* han estat $\eta = 0,01$, $\text{subsample} = 0,6$ i $\text{colsample_bytree} = 0,6$ ¹⁵. Els paràmetres optimitzats per *grid search* (54 combinacions, 5-fold CV per AUC) han estat max_depth , min_child_weight , γ , λ i α . La combinació guanyadora ha estat $\text{max_depth} = 2$, $\text{min_child_weight} = 5$, $\gamma = 0$, $\lambda = 3,0$, amb $\text{AUC CV} = 0,751$ i $\text{best_nrounds} = 21$ determinat per *early stopping*. El llindar de classificació s'ha estimat per corba PR sobre probabilitats OOF, resultant en 0,567.¹⁶

El *CatBoost* s'ha estimat amb la mateixa estructura de predictors però no ha convergit correctament durant el *grid search*. Per aquest motiu els seus resultats no es reporten als resultats principals; es pot consultar la comparació de mètriques *train/test* i la importància de variables a l'Annex X.

¹⁵ **η** (taxa d'aprenentatge): controla quant corregeix cada arbre nou els errors del model acumulat. **subsample** i **colsample_bytree** : fracció d'observacions i variables usades per cada arbre, que actuen com a regularització implícita reduint la correlació entre arbres.

¹⁶ **max_depth** : profunditat màxima de cada arbre; **min_child_weight** : pes mínim per crear un node fill. **γ** : reducció mínima de pèrdua necessària per fer una partició. **λ** i **α** : regularització L2 i L1 sobre els pesos de les fulles, que penalitzen models massa complexos. **best_nrounds** : nombre òptim d'arbres determinat per *early stopping*, que atura l'entrenament quan el rendiment al CV deixa de millorar.

9.4. Support Vector Machine (SVM)

El SVM amb *kernel* radial (RBF) busca un hiperplà de separació òptim entre classes maximitzant el marge entre les observacions més properes a la frontera de decisió – els vectors de suport –. El *kernel* RBF permet capturar relacions no lineals sense especificar-les explícitament. Com que l'objectiu inclou estimar probabilitats de risc individuals i no simplement classificar, s'ha aplicat *Platt Scaling*: una regressió logística sobre els valors de decisió del SVM que els transforma en probabilitats.¹⁷

S'utilitzen 18 predictors amb la mateixa lògica que els models anteriors. Prèviament, totes les variables s'han estandarditzat calculant mitjana i desviació típica exclusivament sobre el *train* i aplicant-los al *test* per evitar filtració d'informació. Els hiperparàmetres cost C i gamma s'han optimitzat per *grid search* (5-fold CV, maximitzant AUC). La combinació guanyadora és $cost = 5$ i $gamma = 0,010$, amb $AUC CV = 0,782$. El llindar s'ha estimat per corba PR sobre probabilitats OOF, resultant en 0,667.

El model final utilitza 179 vectors de suport (65,3% del *train*), un nombre elevat que indica que les dues classes no presenten una frontera de decisió neta en l'espai de predictors fins i tot amb *kernel* RBF. Aquest resultat és coherent amb el que s'ha observat al llarg de tot el treball: l'absentisme és un fenomen difús sense una separació clara entre perfils, cosa que explica per què models basats en arbres obtenen un rendiment superior.

¹⁷ El SVM base produeix distàncies al hiperplà de decisió, no probabilitats. El *Platt Scaling* ajusta una regressió logística sobre aquestes distàncies per obtenir $P(Regular|x)$ interpretables com a probabilitats de risc.

10. Anàlisi textual

Tot l'anàlisi quantitatiu treballa amb variables numèriques i categòriques. Però l'enquesta inclou tres preguntes de resposta oberta que capturen informació qualitativa que cap escala numèrica pot recollir plenament: una experiència d'assignatura positiva (EXP_POS, $n = 134$), una de negativa (EXP_NEG, $n = 130$) i una proposta concreta per motivar l'assistència (PROP_MOT, $n = 115$). Analitzar aquests textos permet entendre quins conceptes associen els estudiants a l'assistència i a l'absència, i si els dos grups expressen opinions diferenciades. Atesa la mida reduïda del *corpus* – entre 115 i 134 respostes per pregunta, amb una mitjana d'entre 25 i 33 paraules cadascuna –, s'han aplicat tècniques de mineria de textos adequades per a textos curts: anàlisi de freqüències, models de tòpics (*Latent Dirichlet Allocation*: LDA), anàlisi de sentiment i xarxes de co-ocurrència.¹⁸

Els textos estan escrits en català i castellà de forma barrejada. El primer pas ha estat traduir-los tots al castellà de forma automàtica amb una API de Softcatalà, per garantir una cobertura completa del lèxic NRC. A continuació s'ha aplicat conversió a minúscules, eliminació de puntuació i dígit, *tokenització* per paraula, eliminació de *stopwords* combinant les llistes estàndard de català i castellà (983 paraules en total) i *lemmatització* mitjançant un diccionari manual de 76 variants que unifica formes equivalents al mateix *token* canònic.

Pel model de tòpics¹⁹ s'ha fixat $k = 3$ tòpics per a cada variable, una decisió basada en la coherència interpretativa i en la mida reduïda del *corpus*. Per a cada tòpic s'han extret les 8 paraules amb major probabilitat β i s'han assignat etiquetes interpretatives manualment.

¹⁸ Tècniques com BERT o altres models de llenguatge preentrenat requereixen *corpus* molt més grans per generalitzar de forma fiable; amb menys de 150 respostes per pregunta, les tècniques clàssiques de mineria de textos són més adequades i interpretables.

¹⁹ El LDA (*Latent Dirichlet Allocation*) és un model probabilístic que assumeix que cada document és una mescla de tòpics, i que cada tòpic és una distribució sobre el vocabulari (Blei, 2003)

11. Clustering i profiling

Un cop identificades les variables associades a l'absentisme, queda un interrogant obert: existeixen perfils diferenciats d'estudiants? Respondre-ho no és trivial, perquè un estudiant pot tenir trets de diversos perfils alhora. Per capturar aquesta complexitat s'utilitza el *Fuzzy C-Means* (FCM), una variant del clustering clàssic que, a diferència del *k-means* estàndard, no assigna cada observació a un únic clúster sinó que li assigna un grau de pertinença a cadascun ($u_{ik} \in [0,1]$, amb $\sum u_{ik} = 1$)²⁰.

S'ha triat FCM per davant d'alternatives com la clusterització jeràrquica (*Ward*) o el *k-medoids* perquè l'objectiu no és una classificació dura sinó obtenir graus de pertinença que es puguin usar directament al pas posterior de *KNN-Fuzzy*.

El clustering s'ha construït sobre 16 variables conegudes abans que l'estudiant comenci el curs: nou sociodemogràfiques i acadèmiques (EDAT, DESPL, N_ASSIG, NOTA_num, T_AVAL_num, CURS_1R, GENEHome, DOBLE_GRAU_EST, TREB_INTENS_num) i set ítems del bloc IA (IA_HABIT, IA_COMPR, IA_REND, IA_PDFS, IA_SUBST, IA_ATENC, IA_CONF). IA_PREOC s'ha exclòs per la seva baixa comunalitat a l'EFA ($h^2 = 0,21$).

Totes les variables s'han estandarditzat en *z-score* calculant mitjana i desviació típica exclusivament sobre el conjunt d'entrenament (*train*) i aplicant-les posteriorment al test, per evitar *data leakage*²¹. El FCM s'ajusta únicament sobre el *train* (80%, $n = 275$) i les pertinences del test es calculen per projecció sobre els centroides apresos. La partició és estratificada respecte a GRUP_ASSIST (56,7%/43,3% en ambdós conjunts) i comparteix el mateix índex de partició que la resta de models del treball per garantir la comparabilitat.

Per la selecció del nombre de clústers s'han avaluat quatre criteris per a $c \in 2,3,4,5$ amb $m = 2$ i 25 inicialitzacions²²:

²⁰ A diferència del *k-means*, que assigna cada observació a un únic clúster (pertinença binària), el FCM permet que un estudiant pertanyi parcialment a diversos perfils, cosa més realista quan els grups no estan nítidament separats.

²¹ Si s'escalessin totes les dades juntes abans de partir, el model hauria "vist" el test durant l'ajust, introduint *data leakage* i inflant artificialment les mètriques de generalització.

²² **PC (Partition Coefficient)**: nitidesa global de les pertinences, màxim=1 (assignació dura), mínim=1/c (màxima difusió). **PE (Partition Entropy)**: entropia informacional, mínim=0 (assignació neta). **Silhouette**: cohesió interna vs. separació entre clústers. **XB (Xie-Beni)**: ràtio variabilitat intra-clúster / distància entre centroides, valors baixos = clústers compactes i ben separats.

Taula 1: Comparació resultats per escollir número de clústers

C	PC	PE	Silhouette	XB
2	0,500	0,693	0,138	457.887
3	0,333	1,100	0,138	13.923.286
4	0,250	1,390	0,138	4.555.011
5	0,200	1,610	-0,023	5.308.155

Font: elaboració pròpia

Els quatre criteris coincideixen a seleccionar $c = 2$ (Taula 1), cosa que dona plena confiança a la decisió.

Per la selecció del paràmetre m – que controla fins a quin punt les pertinences es difuminen entre clústers – s’han provat $m \in 1,5; 2,0; 2,5; 3,0$ i s’ha seleccionat $m = 1,5$ per maximitzar el PC sobre el *train*. Amb exponents més alts l’algoritme no aconsegueix diferenciar els dos perfils, indicant que les pertinences es difuminen excessivament. El model final s’ha ajustat 25 vegades amb inicialitzacions aleatòries i s’ha seleccionat la solució amb el PC més alt.

La qualitat del model ($c = 2, m = 1,5$) es valora amb dos indicadors: $PC = 0,594$ i $PE = 0,593$ reflecteixen que els clústers no estan completament separats però sí diferenciables. El 74,5% dels estudiants del *train* presenten una pertinença màxima superior a 0,60, i el 19,6% supera 0,80, és a dir, tres de cada quatre estudiants s’associen de forma prou clara a un dels dos perfils. La projecció sobre el test dona una nitidesa mediana de 0,707, lleugerament superior a la del *train* (0,693), la qual cosa suggereix que el model generalitza correctament sense signes d’overfitting.

12. KNN Fuzzy-Aware

El KNN és un algorisme de classificació no paramètric que, davant d'un nou individu, busca els k alumnes més similars al conjunt d'entrenament i estima la probabilitat de la classe a partir dels seus veïns. S'inclou al treball no com a alternativa competitiva als altres models, sinó per alimentar una aplicació *Shiny* que permeti, a partir de les característiques observables d'un alumne a l'inici de curs, estimar la probabilitat que no assisteixi regularment i situar-lo dins dels perfils identificats al clustering²³.

Enlloc d'un KNN estàndard s'implementa una versió *fuzzy-aware* que opera en dues fases. Primer, es calculen els graus de pertinença als dos clústers (u_1, u_2) projectant les característiques del nou alumne sobre els centroides ja estimats. Després, dins de cada clúster s'aplica un KNN independent i la probabilitat final es construeix com una mitjana ponderada pels graus de pertinença:

$$P(\text{Regular}|x) = u_1 \cdot P_c1(\text{Regular}) + u_2 \cdot P_c2(\text{Regular})$$

Així, un alumne amb pertinença difusa rep influència dels dos espais de veïns, mentre que un amb pertinença neta queda determinat quasi exclusivament pels veïns del seu clúster. Es reutilitzen la mateixa partició 80/20 (275 *train* / 67 *test*) i els mateixos paràmetres d'escalat del clustering per garantir la comparabilitat entre etapes.

El valor òptim de k s'ha determinat per validació creuada de 5 *folds* sobre el *train*, maximitzant l'AUC-ROC per a $k \in \{3, 5, 7, 9, 11\}$. S'escull $k = 11$ ($AUC - CV = 0,740 \pm 0,063$). Les probabilitats s'han calibrat amb *Platt scaling* sobre prediccions out-of-fold i el llindar de classificació (0,565) s'ha fixat maximitzant la corba *Precision-Recall* amb un mínim de *recall* del 60%.

²³ L'elecció del KNN per a l'aplicació respon a tres raons: la seva lògica és fàcilment comunicable ("aquest alumne s'assembla als següents alumnes"), la integració *fuzzy-aware* permet mostrar simultàniament probabilitat d'irregularitat i grau de pertinença a cada clúster, i un cop estimat no requereix re-entrenament per a noves prediccions.

Capítol VI: Resultats


1. Resultats descriptius

1.1. Resultats acadèmics: nota i tipus d'avaluació

En aquest apartat s'observen dues relacions clares, que ja se sospiten, però que les dades confirmen.

- **L'efecte de l'avaluació continuada:** en l'avaluació única, la irregularitat és gairebé total (88%), mentre que en l'avaluació continuada el percentatge d'irregulars baixa fins al 40% (Gràfic 3). Això suggereix que l'avaluació continuada incentiva un seguiment més constant de l'assignatura, mentre que l'avaluació única permet a l'estudiant gestionar l'aprenentatge de manera més autònoma, sense necessitat d'assistir-hi regularment.


Gràfic 3: Assistència per tipus d'avaluació



Font: elaboració pròpia

- **Relació entre nota i assistència:** existeix un gradient clar i monòton entre rendiment acadèmic i assistència (Gràfic 4). En el grup de notes més baixes (5-5,9), el percentatge d'irregulars puja fins al 59%, mentre que entre els estudiants excel·lents (nota ≥ 9) baixa fins al 22%. L'assistència, doncs, no sembla només una qüestió d'hàbit, sinó que està lligada al rendiment acadèmic.

Gràfic 4: Assistència segons la nota d'expedient




Font: elaboració pròpia

1.2. El paper del treball

El gràfic de percentatge d'assistència per dedicació laboral (Gràfic 5) mostra una diferència clara entre els estudiants que treballen i els que no. Tot i que la mediana dels estudiants que no treballen es manté alta, la dispersió augmenta considerablement en els que treballen, sobretot a temps parcial. El cost d'oportunitat de venir a la facultat és, simplement, molt més alt per a ells.


Gràfic 5: Box-plot de dedicació laboral per percentatge d'assistència



Font: elaboració pròpia

1.3. Motius per no anar a classe i estratègies per anar-hi


Gràfic 6: Diferència de mitjanes en els motius de no assistència entre els dos grups



Font: elaboració pròpia

Mirant les diferències de mitjana per grup (Gràfic 6), els motius més importants per no anar a classe dels estudiants irregulars són la percepció que les classes són massa teòriques (M_TEOR), la preferència per l'estudi autònom (M_AUTON), l'avorriment (M_AVORR) i la necessitat d'estudiar per a altres exàmens (M_EXAM), amb una diferència màxima de 0,85 punts. En canvi, el motiu principal pel qual l'alumnat regular admet faltar a classe és un problema puntual i no dependent d'ell mateix: problemes de salut (M_SALUT), amb una diferència de 0,90 punts a favor dels regulars o motius familiars (M_FAM).

Gràfic 7: Diferència de mitjanes en les estratègies per anar a classe




Font: elaboració pròpia

Pel que fa a les estratègies per anar a classe (Gràfic 7), les diferències entre grups són clarament més petites que en el bloc de motius. La més rellevant és l'horari de classe (E_HORA): els irregulars ho valoren més a l'hora d'assistir-hi (diferència de 0,51 punts), mentre que els regulars donen més importància a que hi hagi descans (E_DESC, diferència de 0,37 punts). Aquesta menor diferència, comparada amb el bloc de motius, suggereix que tothom té clar a quin tipus de classe prefereix anar, però que els irregulars, malgrat saber-ho, igualment no hi assisteixen.

1.4. El paper de la Intel·ligència Artificial

Gràfic 8: Diferència de mitjanes en l'ús de la IA




Font: elaboració pròpia

Com a novetat conceptual d'aquest treball, s'ha explorat si l'ús de la IA diferencia els estudiants que van a classe regularment dels que no hi van. Les dades ho confirmen: dues variables ho mostren clarament al Gràfic 8 (Diferència de mitjanes en l'ús de la IA), IA_SUBST (diferència d'1,34 punts) i IA_ATENC (diferència de 0,84 punts), que mesuren respectivament si l'alumnat creu que la IA redueix la necessitat d'anar a classe i si deixa de prestar atenció confiant en que la IA ja els ho explicarà. En tots dos casos, els estudiants irregulars puntuen significativament més alt. Això suggereix que la IA ja no és només una eina de suport, sinó que per a una part de l'alumnat és una alternativa viable a l'explicació del professor, fins al punt que aquesta és la diferència més gran trobada entre els dos grups d'estudi.

2. Resultats exploratoris

2.1. Variables categòriques

Gràfic 9: Associacions de les variables categòriques amb l'assistència (*V* de Cramér)



Font: elaboració pròpia

Les variables amb més poder explicatiu es presenten al Gràfic 9. El grau ($V = 0,264$) i el tipus d'avaluació ($V = 0,245$) mostren les associacions més intenses, cosa que suggereix que l'absentisme no és únicament una decisió individual sinó que està condicionada per l'entorn acadèmic. La nota d'expedient ($V = 0,232$) apunta en la mateixa direcció: els estudiants amb millor rendiment tendeixen a ser més regulars, tot i que la causalitat podria operar en els dos sentits.

Pel que fa al curs ($V = 0,214$), els estudiants de primer curs ($CURS_1R$, $V = 0,176$) presenten una assistència significativament més regular. Això pot reflectir tant una major motivació inicial com un accés més limitat a estratègies alternatives — apunts externs o informació de companys de cursos superiors — que els cursos superiors ja han incorporat.


Tot i que treballar a temps parcial o complet ($V = 0,118$) és estadísticament significatiu, la intensitat de l'associació és baixa, cosa que indica que la dedicació laboral no és el factor principal de l'absentisme. El gènere i la sobrecàrrega d'assignatures no presenten cap relació estadística amb l'assistència, com ja es sospitava a la descriptiva.

2.2. Variables numèriques

L'edat ($r = -0,096$, $p = 0,124$) i la càrrega lectiva ($r = -0,060$, $p = 0,336$) no mostren cap relació significativa amb el grup d'assistència. El temps de desplaçament presenta una tendència positiva ($r = 0,112$) però no assoleix significació estadística ($p = 0,076$). Aquests resultats suggereixen que l'absentisme és un fenomen que no s'explica per variables logístiques, sociodemogràfiques o de càrrega lectiva.

2.3. Variables de percepció

Gràfic 10: Correlació rank-biserial de les variables Likert (només variables significatives)²⁴



Font: elaboració pròpia

La percepció de la IA com a eina de substitució de la classe és el factor amb la correlació rang-biserial més elevada ($r = -0,412$), indicant que els alumnes que consideren que la IA els pot aportar el mateix que el professor, presenten una probabilitat notablement més alta de pertànyer al grup irregular. La percepció d'autonomia (M_AUTON , $r = -0,367$) mostra una associació similar: els estudiants irregulars puntuen significativament més alt en la preferència per aprendre de manera autònoma fora de l'aula.

Quant a la metodologia docent, les variables relacionades amb la percepció de classes massa teòriques (M_TEOR : $r = -0,329$), la insatisfacció amb el professor (M_PROF : $r = -0,310$) i el rol passiu de l'alumnat a l'aula (M_PASSIU : $r = -0,263$) presenten diferències significatives entre grups, confirmant que el format de la classe és un factor associat a l'absentisme.

En sentit contrari, M_SALUT ($r = 0,265$) i M_FAM ($r = 0,208$) són els únics motius on els estudiants regulars puntuen més alt que els irregulars. Això confirma el que ja s'apuntava a la descriptiva: quan un estudiant regular no va a classe, és gairebé sempre per una causa externa i puntual, no per una decisió pròpia.

Un resultat destacable és que pràcticament cap de les estratègies docents proposades mostra diferències significatives entre grups. De les tretze variables analitzades, només E_HORA

²⁴ Els que són positius indiquen que el valor és més elevat en els regulars que en els irregulars.

(preferència per horaris favorables, $r = -0,166$) i E_DINAM (preferència per classes més dinàmiques, $r = 0,128$) assolixen significació estadística, i ambdues amb magnituds baixes.


Val a dir que E_DINAM és l'única variable d'estratègies on els estudiants regulars puntuen més alt que els irregulars, suggerint que el dinamisme de la classe pot ser un factor que afavoreix l'assistència. La resta d'estratègies no presenten cap diferència entre grups.

3. Anàlisi Factorial Exploratòria

3.1. Bloc 1 — Motius de no assistència

Aquest bloc consta de 3 factors i explica un 56,2% de la variància.

Gràfic 11: Càrregues factorials – Motius de no assistència (càrregues > 30, negreta > 50)



Font: elaboració pròpia

El primer factor, MOT_DESMOTIVACIO, agrupa els motius relacionats amb la dinàmica de l'aula: classes massa teòriques ($\lambda = 0,85$), paper de l'alumnat passiu ($\lambda = 0,87$), classes avorrides ($\lambda = 0,70$), manca de connexió amb la forma d'explicar del professor ($\lambda = 0,56$) i la influència dels amics que no van a classe ($\lambda = 0,49$). La correlació de Spearman amb l'assistència és de $\rho = -0,357$ ($p < 0,001$), de manera que els alumnes irregulars puntuen més alt en desmotivació pedagògica que els regulars.

El segon factor, MOT_AUTOGESTIO, captura la percepció que anar a classe no aporta valor addicional respecte d'estudiar per compte propi: preferència per l'aprenentatge autònom ($\lambda = 0,83$), material al Campus Virtual suficient ($\lambda = 0,74$), percepció que la classe no és útil ($\lambda = 0,61$) i estratègies com no anar quan hi ha un examen proper ($\lambda = 0,37$) o quan es repeteix l'assignatura ($\lambda = 0,34$). És el factor amb la correlació negativa més forta ($\rho = -0,378$, $p < 0,001$), indicant que els alumnes irregulars es perceben molt més capaços d'autogestionar el seu aprenentatge sense assistir.

El tercer factor, MOT_FORCA_MAJOR, recull els motius externs a la universitat: obligacions familiars ($\lambda = 0,96$), problemes de salut ($\lambda = 0,84$) i feina ($\lambda = 0,66$). La correlació amb l'assistència és positiva ($\rho = 0,187$, $p < 0,001$) i era el que s'esperava segons el que s'ha comentat en apartats anteriors.

3.2. Bloc 2 — Estratègies docents

Aquest segon bloc conté 4 factors i explica un 67,4% de variància.

Cap dels quatre factors del bloc d'estratègies assoleix significació estadística en la correlació de Spearman amb l'assistència (vegeu Annex 14). Això confirma el que ja apuntava l'EDA: les preferències pedagògiques no discriminen entre assistents i no assistents, i els factors s'interpreten com a dimensions de preferència, no com a predictors d'absentisme.

EST_QUALITAT_DOC agrupa tot allò relacionat amb les habilitats pedagògiques del professor i el clima de l'aula: qualitat de l'explicació (E_EXPL, $\lambda = 0,985$), ritme de la classe (E_RITME, $\lambda = 0,799$), bon clima (E_CLIMA, $\lambda = 0,782$) i proximitat del professor (E_PROP, $\lambda = 0,588$).

EST_AVALUACIO_AC recull les estratègies que impliquen un rol actiu de l'alumne: activitats d'aula (E_ACT_AC, $\lambda = 0,910$), pes de l'avaluació continuada (E_PES_AC, $\lambda = 0,720$), participació (E_PART, $\lambda = 0,627$) i dinamisme (E_DINAM, $\lambda = 0,385$).


EST_TEMPS_CLASSE captura estratègies purament temporals: descansos (E_DESC, $\lambda = 0,813$) i classes més curtes (E_CURT, $\lambda = 0,665$). Finalment, EST_GRUPS_REDUITS queda pràcticament aïllat amb una sola variable dominant (E_REDU, $\lambda=0,863$).

El gràfic de les càrregues factorials es pot veure a l'Annex 13.

3.3. Bloc 3 — Ús de la IA

L'últim bloc queda amb 2 factors i explica un 67,8% de la variància.

Gràfic 12: Càrregues factorials – Ús de la IA (càrregues > 30, negreta > 50)



Font: elaboració pròpia

IA_EINA_ESTUDI recull l'ús actiu de la IA (IA_HABIT, $\lambda = 0,88$) per comprendre continguts (IA_COMPR, $\lambda = 0,90$), processar documents (IA_PDFS, $\lambda = 0,76$) i millorar el rendiment (IA_REND, $\lambda = 0,74$). La correlació amb l'assistència és negativa i significativa ($\rho = -0,279, p < 0,001$)


IA_SUBSTITUCIO recull el costat més problemàtic de l'ús de la IA: l'alumne deixa d'atendre a classe perquè confia que la IA li proporcionarà tot el que necessita (IA_ATENC, $\lambda = 0,99$), confia en les respostes que li dona (IA_CONF, $\lambda = 0,69$), i veu les seves explicacions com a substitutes d'anar a classe (IA_SUBST, $\lambda = 0,59$). La correlació amb l'assistència és també negativa i significativa ($\rho = -0,271, p < 0,001$).

Les dues correlacions són gairebé idèntiques en magnitud, de manera que no és possible establir cap jerarquia clara entre els dos factors i dir quin pot tenir més relació. Això suggereix que no és només l'ús substitutiu de la IA el que s'associa amb l'absentisme, sinó l'ús intensiu en general.

3.4. Puntuacions factorials i ús als models predictius

Un cop definit el model definitiu, s'han calculat puntuacions factorials²⁵ per regressió per a cada observació (Gràfic 13). Aquestes puntuacions substitueixen el conjunt de variables originals als models econòmics posteriors, resolent el problema de multicolinealitat i reduint la dimensió de l'espai de predictors de forma interpretable.

Gràfic 13: Correlació entre els factors i l'assistència



Font: elaboració pròpia

²⁵ Les puntuacions factorials són com una "nota" en cada factor que resumeix la posició de l'alumne en aquell constructe latent.

4. Anàlisi inferencial i causal

4.1. Model logístic

Cal recordar que el model final utilitza IA_SUBST_num en format Likert individual i no el factor IA_SUBSTITUCIO, ja que, com s'ha explicat a l'apartat 8.1, el model amb la variable crua obté un BIC inferior.

Taula 2: Odds ratios i AME del model final²⁶

Variable	OR	Ic (95%)	AME
MOT_DESMOTIVACIO	0,472***	[0,331; 0,674]	-8,6 pp
IA_SUBST_num	0,687***	[0,580; 0,813]	-6,3 pp
MOT_FORCA_MAJOR	1,428**	[1,092; 1,868]	+5,9 pp
EST_AVALUACIO_AC	1,542**	[1,161; 2,047]	+7,2 pp
NOTA_num	1,624**	[1,169; 2,255]	+8,1 pp
CURS_1R	2,679**	[1,376; 5,220]	+18,7 pp
T_AVALContinuada	8,232**	[2,138; 31,700]	+35,5 pp
MOT_DESMOTIVACIO:CURS_1R	2,792**	[1,407; 5,540]	-

Font: elaboració pròpia

Desmotivació pedagògica (AME = -8,6 pp). Cada unitat addicional en el factor de desmotivació pedagògica²⁷ redueix la probabilitat de tenir assistència regular en 8,6 punts percentuals. És el mecanisme actitudinal principal de l'absentisme que el model detecta.

Ús de la IA com a substitut d'anar a classe (AME = -6,3 pp). Cada punt addicional a IA_SUBST redueix la probabilitat de ser regular en 6,3 punts percentuals. De l'extrem inferior al superior de l'escala, l'efecte acumulat supera els 30 punts percentuals. Això confirma que la IA, per a una part de l'alumnat, ja no és només una eina d'estudi sinó una alternativa real a la classe.

Força major (AME = +5,9 pp). La relació positiva amb l'assistència regular reforça la idea que quan un estudiant regular falta, és per motius externs i involuntaris, no per una decisió pròpia.

²⁶ *** $p < 0,001$; ** $p < 0,01$; * $p < 0,05$. AME = efecte marginal mitjà, expressat en canvi de probabilitat fent la mitjana sobre totes les observacions de la mostra.

²⁷ Recordem que el factor de la desmotivació pedagògica recull la percepció de les classes com a avorrides, massa teòriques o amb un paper passiu de l'estudiant

Paper actiu de l'alumne (AME = +7,2 pp). Les dinàmiques de classe que impliquen un rol actiu de l'estudiant — activitats, participació, avaluació continuada amb pes a la nota — augmenten la probabilitat de ser regular en 7,2 pp.


Nota d'expedient (AME = +8,1 pp) i primer curs (AME = +18,7 pp) reforcen un patró coherent: els estudiants amb millor rendiment i els de primer any són els més regulars, cosa que apunta tant a una major motivació com a una percepció més alta del valor de la classe.

Tipus d'avaluació (AME = +35,5 pp). Seguir l'avaluació continuada incrementa la probabilitat de ser regular en 35 punts percentuals. Quan l'assistència té conseqüències directes en la nota, l'alumnat assisteix.

Interacció desmotivació × primer curs (OR = 2,79). La desmotivació es tradueix menys en absentisme als estudiants de primer que als de cursos superiors, probablement perquè aquests últims ja han incorporat estratègies alternatives per substituir la classe (

Gràfic 14).

Gràfic 14: Interacció entre MOT_DESMOTIVACIO i CURS_1R



Font: elaboració pròpia

Els resultats del model logístic apunten a un patró clar: l'absentisme s'explica sobretot per percepcions i decisions de l'estudiant envers la classe. El factor amb més pes és l'avaluació continuada. Altres dos factors que redueixen l'assistència de forma important – la desmotivació pedagògica i la percepció de la IA com a substitut de la classe – són actitudinals. Reduir l'absentisme, per tant, implica recuperar el valor percebut de la classe presencial, especialment als cursos superiors.

4.2. Resultats del model estructural

S'han estimat dos models alternatius: el Model A, sense cap ruta de mediació, i el Model B, que afegeix la ruta DESMOTIVACIO_PEDAG → AVALUACIO_AC → P_ASSIST per contrastar si la desmotivació actua indirectament sobre l'assistència a través de la percepció de l'avaluació activa. El test de diferència de chi-quadrat no resulta significatiu ($\Delta\chi^2 = 3,70$; $\Delta df = 2$; $p = 0,158$), de manera que el Model A és el model final per ser estadísticament equivalent i més parsimoniós.

Taula 3: Coeficients estructurals del model SEM (variable dependent: percentatge d'assistència)

Variable	β est.	Efecte (pp) ²⁸	IC 95%	p-valor
T_AVAL_num	0,348	+39,7	[28,6; 50,7]	< 0,001
DESMOTIVACIO_PEDAG	-0,221	-6,4	[-9,8; -3,1]	< 0,001
AVALUACIO_AC	0,202	+5,9	[3,1; 8,6]	< 0,001
NOTA_num	0,178	+5,9	[2,8; 9,1]	< 0,001
FORCA_MAJOR	0,156	+4,6	[1,9; 7,2]	0,001
CURS_1R_d	0,154	+10,6	[2,8; 18,4]	0,008
TREB_INTENS	-0,131	-7,8	[-13,5; -2,1]	0,007
DOBLE_GRAU_EST	0,085	+5,3	[-1,9; 12,5]	0,151
IA_SUBSTITUCIO	-0,058	-1,7	[-4,8; 1,4]	0,283

Font: elaboració pròpia. Variable dependent: P_ASSIST (percentatge d'assistència, 0–100).

El predictor amb efecte més gran és el tipus d'avaluació (T_AVAL, $\beta = 0,35$): els estudiants que segueixen avaluació continuada presenten un percentatge d'assistència 40 punts percentuals superior als que segueixen avaluació única. La desmotivació pedagògica (DESMOTIVACIO_PEDAG, $\beta = -0,22$) confirma que els estudiants que perceben les classes com a avorrides o poc participatives assisteixen menys (-6,5 pp). El constructe AVALUACIO_AC ($\beta = 0,20$) captura fins a quin punt percep que les dinàmiques d'avaluació activa a l'aula — activitats, participació, pes a la nota — l'incentiven a assistir. Quan aquesta percepció és alta, l'assistència augmenta +5,6 pp. La nota ($\beta = 0,18$), ser de primer curs ($\beta = 0,15$) i faltar a classe per força major ($\beta = 0,116$) mostren efectes positius i significatius.

²⁸ Efecte (pp) és el coeficient no estandarditzat, És l'efecte en les unitats originals de la variable P_ASSIST (0-100), mentre que l'estandarditzat canvia les variables a una escala comuna, serveix per valorar la importància relativa.

Treballar intensament (TREB_INTENS, $\beta = -0,13$) també resulta significatiu: els estudiants que treballen a temps parcial o complet assisteixen, de mitjana, 7,8 pp menys que els que no treballen.

Veure la IA com a substituta de les classes ($\beta = -0,06, p = 0,28$) i estudiar un doble grau o el grau d'Estadística ($\beta = 0,09, p = 0,15$), no és significatiu. Tot i que en el últim cas el signe positiu suggereix una tendència cap a una assistència lleugerament més regular en aquests perfils.

4.3. Comparació i síntesi dels models

El logit i el SEM, tot i partir d'enfocaments ben diferents – variable dependent binària vs. contínua, puntuacions factorials vs. constructes latents estimats simultàniament –, coincideixen en direcció per a totes les variables significatives (Taula 4). Aquesta convergència reforça la robustesa de les conclusions.

Taula 4: Comparació SEM vs. Logit – direccions i consistència entre ambdós models

Concepte	Variable logit	Variable SEM	Dir. Logit	Dir. SEM	Consistent
Tipus d'avaluació	T_AVAL	T_AVAL_num	+	+	Sí
Desmotivació pedagògica	MOT_DESMOTIVACIO	DESMOTIVACIO_PEDAG	-	-	Sí
Avaluació activa	EST_AVALUACIO_AC	AVALUACIO_AC	+	+	Sí
Nota d'expedient	NOTA_num	NOTA_num	+	+	Sí
Nota d'expedient	CURS_1R	CURS_1R_d	+	+	Sí
Força major	MOT_FORCA_MAJOR	FORCA_MAJOR	+	+	Sí
Substitució per IA	IA_SUBST_num	IA_SUBSTITUCIO	-	n.s.	Parcial
Treball intens	TREB_INTENS	TREB_INTENS	n.s.	-	Parcial

Font: elaboració pròpia.

El tipus d'avaluació és el predictor més potent en tots dos models: l'estructura d'avaluació és el mecanisme que més determina si un estudiant assisteix. La desmotivació pedagògica és el segon factor en magnitud i l'únic amb efecte negatiu consistent. La nota, el curs i la percepció de l'avaluació activa mostren efectes positius i significatius en ambdós models, dibuixant el perfil de l'estudiant regular: bon expedient, de primer curs i que percep l'avaluació activa com un incentiu real.

Hi ha dues discrepàncies parcials. La primera és IA_SUBSTITUCIO, no significativa al SEM: el SEM agrega IA_SUBST i IA_CONF en un constructe latent, cosa que dilueix el senyal específic que feia significativa IA_SUBST en solitari al logit. La segona és TREB_INTENS, que el SEM detecta com a significativa (-7,8 pp) però que el *backward* BIC del logit va eliminar per no aportar informació addicional neta un cop controlades la resta de variables. Cal tenir en compte que la comparació entre models és qualitativa – en termes de direcció i significació –, ja que variables

com MOT_DESMOTIVACIO al logit i DESMOTIVACIO_PEDAG al SEM mesuren el mateix concepte teòric però no són tècnicament idèntiques.

Cal destacar també el que els models no troben: variables com el gènere, el grau cursat o el temps de desplaçament no resulten significatives en cap dels dos models, cosa que indica que l'absentisme no és un fenomen que s'expliqui per característiques sociodemogràfiques o logístiques, sinó per percepcions i decisions de l'estudiant envers la classe.

Els resultats d'aquest bloc es basen en relacions estadístiques sobre la mostra completa. El bloc predictiu que segueix té un objectiu diferent: identificar estudiants en risc d'absentisme i verificar, mitjançant *SHAP values*, si les mateixes variables continuen sent rellevants quan el criteri és la capacitat de generalització.

5. Classificació i predicció

5.1. Model logístic


Taula 5: Coeficients del model logístic predictiu

Variable	Coefficient	Error estàndard	z	p-valor
Intercept	-1,253	0,922	-1,36	0,174
MOT_DESMOTIVACIO	-0,533	0,184	-2,89	0,004 **
MOT_FORCA_MAJOR	0,305	0,150	2,04	0,041 *
EST_AVALUACIO_AC	0,616	0,171	3,60	< 0,001 ***
IA_SUBST_num	-0,376	0,102	-3,67	< 0,001 ***
T_AVALContinuada	1,763	0,725	2,43	0,015 *
CURS_1R	1,001	0,368	2,72	0,006 **
DOBLE_GRAU_EST	0,512	0,327	1,56	0,118
EDAT	-0,039	0,016	-2,37	0,018 *
NOTA_num	0,570	0,182	3,12	0,002 **

Font: elaboració pròpia

El model s'estima sobre el conjunt d'entrenament (274 observacions). Tots els coeficients són significatius al nivell del 5%, excepte DOBLE_GRAU_EST ($p = 0,12$), que el *backward* AIC reté perquè la seva eliminació empitjora el criteri d'informació tot i no assolir el llindar de significació clàssic²⁹. La reducció de deviança respecte al model nul és de 376,10 a 279,47, una reducció del 25,7%.

Gràfic 15: Comparació de mètriques entre train i test del logit



Font: elaboració pròpia

²⁹ En un model predictiu, l'AIC no exigeix significació estadística sinó que avalua si la variable aporta prou informació per compensar el cost d'afegir un paràmetre.

L'AUC al test (0,833) és superior a la mitjana de validació creuada (0,793), cosa que descarta sobreajustament en la capacitat discriminativa global. La precisió al test és del 92,0%: dels 25 estudiants classificats com a regulars, només 2 eren en realitat irregulars. El model quasi no comet l'error que es volia evitar. La contrapartida és un *recall* de 0,561: dels 41 estudiants realment regulars, el model en detecta 23 com a tals i classifica els 18 restants com a irregulars per excés de precaució.

El *recall* al test (0,561) no assoleix el mínim de 0,60 establert durant el calibratge. Això és una limitació de la mida mostral: el llindar s'ha estimat sobre 274 observacions i la seva transferència a un test de 68 no és perfecta. Aquesta limitació motiva la incorporació del *Random Forest*: un algorisme basat en arbres pot capturar relacions no lineals i interaccions sense necessitat d'especificar-les explícitament, cosa que pot traduir-se en un *recall* més alt sense sacrificar la precisió. Per a la corba ROC, la corba *Precision-Recall* i la matriu de confusió vegeu de l'Annex 20 a l'Annex 22.


5.2. Random Forest

El RF-A és el millor model dels tres (lògit, RF-A, i RF-B). Sobre el conjunt de test obté un AUC de 0,912, una F1 de 0,817, una precisió del 96,7% i un *recall* del 70,7%. El RF-B, en canvi, rendeix pitjor que el lògit en F1 (0,615 vs 0,697) i *recall* (0,488), tot i tenir un AUC lleugerament superior. Que el model amb els predictors Likert individuals funcioni pitjor que el dels factors és un resultat rellevant: la reducció dimensiona no és simplement una compressió de dades sinó que elimina redundàncies que en el *Random Forest* distorsionen el càlcul d'importàncies i augmenten la variància. Vegeu la matriu de confusió del RF-B a l'Annex 23: Matriu de confusió de RF-B

Pel que fa a l'*overfitting* del RF-A, la diferència entre OOB i *test* (AUC 0,765 vs 0,912) és aparentment gran però cal interpretar-la amb precaució: el test és un subconjunt fix de 68 observacions on la variància mostral és alta, i el rendiment en test és superior a l'OOB, cosa que descarta sobreajust problemàtic.

Per identificar quines variables contribueixen més a les prediccions s'han calculat dues mesures complementàries. La importància per permutació mesura quant cau l'AUC quan una variable s'aleatoritza. Els valors SHAP descomponen la predicció de cada observació individual i assignen a cada variable la seva contribució marginal, permetent entendre no només quines variables importen sinó en quin sentit ho fan. La importància de les variables es troba a l'Annex 27.

Gràfic 16: Valors SHAP del RF-A




Font: elaboració pròpia

Les dues mesures coincideixen en el rànquing. MOT_DESMOTIVACIO és la variable més important (importància = 0,032; SHAP mitjà = 0,073), seguida de MOT_AUTOGESTIO (0,016; 0,050). A més distància apareixen IA_EINA_ESTUDI (0,011; 0,041), IA_SUBST_num (0,015; 0,039), EST_AVALUACIO_AC (0,006; 0,030) i CURS_1R

(0,011; 0,020). Variables com TREB_INTENS, EDAT, DOBLE_GRAU_EST o N_ASSIG apareixen al final amb importàncies pràcticament nul·les.

Gràfic 17: Beeswarm RF-A (top 8 variables)



Font: elaboració pròpia

El *beeswarm* permet interpretar la direcció dels efectes: cada punt és una observació, la posició horitzontal indica la contribució a la predicció (esquerra = irregular; dreta = regular) i el color reflecteix el valor de la variable (blau = baix, vermell = alt). MOT_DESMOTIVACIO mostra un núvol ample desplaçat cap a l'esquerra: valors alts de desmotivació generen els efectes més forts cap a la irregularitat. MOT_AUTOGESTIO té una distribució concentrada a la dreta de zero: la percepció que s'aprèn millor de manera autònoma empeny cap a la irregularitat.

IA_SUBST_num confirma la direcció del lògit: valors alts s'associen a irregularitat. IA_EINA_ESTUDI mostra un patró més heterogeni: l'ús moderat de la IA no altera gaire la probabilitat d'assistir, però quan l'ús és molt intensiu s'associa a irregularitat, probablement perquè en aquest punt la IA substitueix funcionalment la classe. CURS_1R i EST_AVALUACIO_AC s'associen ambdues a regularitat. Els *dependence plots*, que mostren millor la relació amb l'assistència, es poden consultar de l'Annex 28 a l'Annex 31.

La taula comparativa de tots els models es presenta a l'apartat de síntesi final.


5.3. XGBoost

El *XGBoost* obté un AUC de 0,866 sobre el test, per sota del RF-A (0,912) però per sobre del lògit (0,833). La resta de mètriques se situen en una posició intermèdia: *accuracy* del 75,0%, F1 de 0,754 i *balanced accuracy* del 78,0%, complint la restricció de *recall* $\geq 0,60$ (*recall* = 0,634).

Pràcticament no hi ha *overfitting*: l'AUC *train in-sample* és 0,807 i el de *test* 0,866, una diferència positiva que indica bona generalització. Això és conseqüència de la regularització aplicada i del nombre reduït d'arbres.

El RF-A segueix sent el millor model en totes les mètriques rellevants. El *XGBoost* no l'aconsegueix superar tot i tenir més capacitat d'expressió – un resultat esperable amb 274 observacions de *train*, que no permet que el *boosting* desplegui tot el seu potencial –. Que la regularització hagi de ser tan forta per evitar l'*overfitting* és en si mateix un senyal que les relacions entre variables i assistència no són prou complexes com per justificar un model d'aquesta flexibilitat.

Gràfic 18: Importància SHAP del XGBoost



Font: elaboració pròpia

El rànquing SHAP del XGBoost coincideix amb el del RF-A en les posicions principals: MOT_AUTOGESTIO (0,042), IA_EINA_ESTUDI (0,030), MOT_DESMOTIVACIO (0,023), MOT_FORCA_MAJOR (0,019) i IA_SUBST_num (0,018). Val a dir que IA_ATENC_num apareix amb un SHAP de 0,001 – petita magnitud, però no observable al RF-A ni al lògit – suggerint que deixar de prestar atenció a classe per confiar en la IA pot tenir una incidència sobre l'assistència.


La consistència entre els tres models en el rànquing de variables reforça la robustesa dels resultats: independentment del model i l'especificació, les mateixes dimensions – desmotivació pedagògica, autogestió percebuda, ús substitutiu de la IA i avaluació continuada – emergeixen sistemàticament com els factors centrals de l'absentisme.

5.4. Support Vector Machine (SVM)

El SVM obté un AUC de 0,844 sobre el *test*, una *accuracy* del 72,1%, un F1 de 0,716 i una *balanced accuracy* del 75,6%. Classifica correctament 25 irregulars i 24 regulars, cometent 17 falsos negatius i 2 falsos positius. S'observa una lleugera caiguda entre *train* i *test* (AUC 0,882 vs 0,844), habitual en SVMs amb *kernel* RBF, però dins de marges acceptables per a un test de 68 observacions.

El SVM queda per sota del *XGBoost* en totes les mètriques i clarament per sota del RF-A, confirmant que els models basats en arbres s'adapten millor a l'estructura d'aquestes dades.

Gràfic 19: Importància SHAP del SVM




Font: elaboració pròpia

El rànquing SHAP del SVM mostra un ordre lleugerament diferent als models basats en arbres: EST_AVALUACIO_AC (0,074) i IA_SUBST_num (0,070) encapçalen la llista, seguides de MOT_DESMOTIVACIO (0,053), CURS_1R_num (0,044) i NOTA_num (0,043). MOT_AUTOGESTIO (0,030), que al RF-A i *XGBoost* era el segon factor en importància, aquí queda en desena posició. Malgrat aquesta diferència en l'ordenació, les mateixes variables apareixen sistemàticament en tots els models, cosa que reforça la robustesa de les conclusions.

5.5. Síntesi bloc predictiu

Gràfic 20: Comparació dels models predictius



Font: elaboració pròpia

Els quatre models predictius apunten a la mateixa conclusió: el RF-A és el millor model, amb un AUC de 0,912, una *balanced accuracy* del 83,5% i un F1 de 0,817 sobre el *test*. La seva superioritat respecte al RF-B – que usava les variables Likert originals sense reducció dimensional – confirma que la síntesi de l'EFA no és només una decisió de parsimònia sinó que millora la capacitat predictiva en eliminar soroll i redundàncies.

El lògit, el *XGBoost* i el SVM se situen en una franja similar (AUC entre 0,833 i 0,866), cosa que indica que la dificultat del problema no és model-específica: l'absentisme és un fenomen difús sense una frontera de decisió neta entre perfils, i cap model aconsegueix superar de forma rellevant aquesta limitació estructural.

Un resultat especialment rellevant és la consistència del rànquing de variables a través de tots els models. Independentment de l'algorisme, les variables més rellevants són: la desmotivació pedagògica, la percepció d'autonomia en l'aprenentatge, l'ús substitutiu de la IA i la valoració de l'avaluació continuada. Aquesta convergència reforça que els resultats reflecteixen patrons reals.

Finalment, el bloc predictiu valida el bloc explicatiu: les variables que el lògit i el SEM identifiquen com a significatives estadísticament són també les que els models de *machine learning* consideren més útils per generalitzar. Que inferència i predicció convergeixin és una validació important dels resultats.

6. Anàlisi textual

Van respondre les preguntes obertes 134 estudiants a EXP_POS, 130 a EXP_NEG i 115 a PROP_MOT, amb taxes de resposta d'entre el 34% i el 39%. Les respostes són breus – entre 25 i 33,0 paraules de mitjana – cosa que cal tenir en compte a l'hora d'interpretar els resultats: els patrons detectats són indicatius però no estadísticament robustos.

6.1. *Experiències positives*

Les paraules més freqüents giren entorn de dues figures: *profesor* (76 mencions) i *clase* (64). El vocabulari associat – *explicaba, dinámica, actividad, ejercicios* – (vegeu les freqüències de paraules a l'Annex 41) apunta que les experiències positives es construeixen principalment quan les sessions són dinàmiques i el professor explica amb claredat. El LDA identifica tres tòpics de distribució força equilibrada: Docència participativa (52 respostes), Qualitat explicativa del professor (38) i Metodologia i avaluació (40), cosa que indica que no hi ha un únic element que defineixi l'experiència positiva (Annex 42). No s'observen diferències significatives de vocabulari entre regulars i irregulars en aquesta pregunta.

6.2. *Experiències negatives*

A les experiències negatives apareix un vocabulari absent a EXP_POS: *casa, diapositivas, leen, ganas, mínima*. Als textos positius no apareixia la paraula *casa*, i en canvi als negatius sí, suggerint situacions on quedar-se a casa era una alternativa racional a anar a classe.

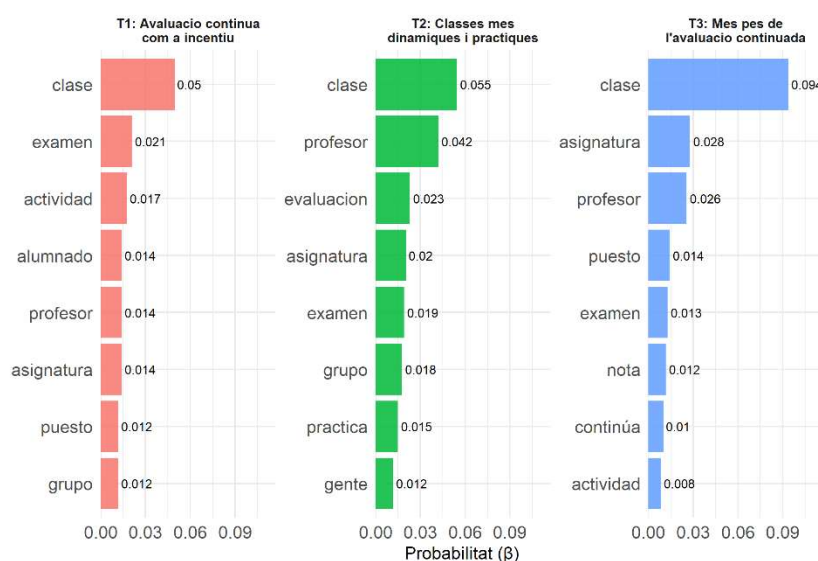
El LDA extreu tres tòpics (Annex 44): Manca de rellevància percebuda (59 respostes), Mala comunicació docent (35) i Passivitat i falta de pràctica (32). A diferència d'EXP_POS, el tòpic més poblat és el de manca de rellevància.

El test de *Wilcoxon* sobre el sentiment net no resulta significatiu ($W = 2214, p = 0,615$), de manera que la diferència entre grups és de contingut temàtic, no d'intensitat emocional.

6.3. *Propostes de motivació*

Les propostes mostren un vocabulari centrat en l'estructura de les classes i l'avaluació: *clase* (95), *profesor* (40), *examen* (25), *actividad* (16). El *bigram* més freqüent és *evaluacion continua/continuada* (10 mencions combinades), confirmant que per a una part important dels estudiants el principal incentiu seria que l'assistència tingués pes real a la nota.

Gràfic 21: Tòpics del LDA per les propostes de millora




Font: elaboració pròpia

El LDA extreu tres tòpics: Avaluació com a incentiu (29 respostes), que agrupa propostes genèriques d'activitats i exàmens parcials com a motiu per assistir; Classes dinàmiques i participatives (39 respostes), centrat en la demanda de classes més pràctiques, amb més participació i en grups reduïts; i Més pes de l'avaluació continuada (44 respostes), el tòpic més poblat, on els estudiants demanen específicament que l'avaluació continuada tingui més pes a la nota final, de manera que assistir es tradueixi directament en millor qualificació.

Val a dir que cap dels tres Wilcoxon de sentiment és significatiu ($p > 0,46$), de manera que no s'observen diferències estadísticament rellevants entre regulars i irregulars ni en la intensitat ni en el to emocional de les respostes.

6.4. Comparativa EXP_POS vs. EXP_NEG

Gràfic 22: Comparació log-ratio entre les experiències positives i negatives



Font: elaboració pròpia

El gràfic de *log-ratio* entre experiències positives i negatives (Gràfic 22) sintetitza visualment el contrast entre els dos tipus d'experiències. Les paraules que caracteritzen les experiències positives – *atención, entiendas, ayudan, comunicación, pasión* – apunten a una docència on l'estudiant se sent acompanyat i entén el que s'explica. Les que caracteritzen les negatives – *teóricas, leen, ganas, practicar* — descriuen classes on el professor llegeix el contingut sense implicar l'alumnat i on es perd la motivació per assistir. De manera que el que diferencia una experiència positiva d'una negativa no és el contingut de l'assignatura, sinó la forma en què es transmet.

6.5. Connexió amb el bloc quantitatiu

En conjunt, l'anàlisi textual reforça els resultats dels models, però té un valor afegit que els models numèrics no poden capturar. El paper central del professor – present com la paraula més freqüent tant a EXP_POS com a EXP_NEG – és coherent amb la rellevància de M_PROF a l'EDA i anticipa el pes del factor EST_QUALITAT_DOC als models posteriors. L'avaluació continuada com a incentiu, identificada als tòpics T1 i T3 de PROP_MOT, connecta directament amb EST_AVALUACIO_AC. El que els textos afegeixen és el detall concret: la imatge del professor llegint diapositives o la paraula casa com a alternativa a la classe.

7. Clustering i profiling

La Taula 6 recull els centroides en escala original per a les dues dimensions que defineixen els clústers. La diferència entre perfils és pràcticament nul·la en les variables sociodemogràfiques i acadèmiques: edat (23,09 vs 21,41 anys), desplaçament (50,5 vs 48,2 minuts) i nota (2,60 vs 2,44 sobre 5). La distinció real entre els dos perfils rau exclusivament en el bloc d'ús de la IA:


Taula 6: Centroides per cada clúster segons l'ús de la IA

Variable	Clúster 1	Clúster 2	Diferència
IA_HABIT (freqüència d'ús)	3,94	5,27	-1,33
IA_COMPR (comprensió)	4,50	5,56	-1,06
IA_REND (rendiment)	3,46	4,75	-1,29
IA_PDFS (materials)	3,97	5,22	-1,25
IA_SUBST (substitució classe)	2,12	3,49	-1,37
IA_ATENC (atenció classe)	1,86	3,21	-1,35
IA_CONF (confiança IA)	1,83	2,72	-0,89

Font: elaboració pròpia

El Clúster 1 agrupa estudiants amb un ús moderat de la IA: la utilitzen com a eina d'estudi complementària però no perceben que substitueixi l'assistència ni que els faci perdre atenció a classe. El Clúster 2 correspon a estudiants amb un ús intensiu i actitud clarament substitutiva: puntuen significativament més alt tant en freqüència d'ús com, sobretot, en els ítems que mesuren si la IA redueix la necessitat d'anar a classe (IA_SUBST: +1,37 punts) i si redueix la seva atenció durant les sessions presencials (IA_ATENC: +1,35 punts).

Gràfic 23: PCA 2D de l'assignació del FCM del train




Font: elaboració pròpia

La representació en l'espai PCA (Gràfic 23) confirma visualment la separació: els dos clústers s'organitzen principalment al llarg del primer component principal, que captura la intensitat en l'ús de la IA. La transparència dels punts és proporcional a la certesa d'assignació ($\max u_{ik}$): els punts més opacs tendeixen a situar-se als extrems del gradient, mentre que els més transparents es troben a la zona de solapament central. La distribució final és de 155 observacions al Clúster 1 (45,3%) i 187 al Clúster 2 (54,7%).

La primera comprovació externa és si els clústers detectats s'associen amb l'assistència real. El test χ^2 entre clúster assignat i condició regular/irregular és estadísticament significatiu ($\chi^2 = 12,422$; $p = 0,0004$), amb una *V de Cramér* de 0,191, indicativa d'una associació moderada. El test de *Mann-Whitney* sobre el percentatge d'assistència contínua confirma el mateix ($W = 17.392$; $p = 0,0014$; $r = 0,173$).

Gràfic 24: Variables per clúster



Font: elaboració pròpia

En termes pràctics, el Clúster 1 presenta una assistència mitjana del 73,7% (mediana: 85%), mentre que el Clúster 2 té una assistència mitjana del 67,5% (mediana: 75%). La diferència de 6 punts en la mitjana i de 10 en la mediana és rellevant tenint en compte que el llindar que defineix la irregularitat és el 80%. Que els estudiants del Clúster 2 mostrin una assistència menor valida la coherència externa del clustering: els perfils no s'han construït a partir de l'assistència, però la reflecteixen de forma indirecta (vegeu Annex 46).

Per enriquir la caracterització dels perfils s'han comparat les puntuacions factorials de l'EFA entre els dos clústers. Com que aquests factors no han entrat al clustering, la seva associació amb els grups és informació nova.

Els dos factors del bloc IA mostren les diferències més grans ($r = -0,429; p < 0,001$ en tots dos): IA_EINA_ESTUDI ($C1 = -0,849, C2 = 0,704$) i IA_SUBSTITUCIO ($C1 = -0,770, C2 = 0,639$), confirmant que el clustering ha capturat de forma neta les dues dimensions d'ús de la IA identificades a l'EFA (vegeu Annex 47).

Més rellevant des del punt de vista de l'objectiu del treball és que els factors de motivació també presenten diferències significatives. MOT_DESMOTIVACIO és superior al Clúster 2 ($C1 = -0,367, C2 = 0,305; p < 0,001; r = -0,333$) i el mateix passa amb MOT_AUTOGESTIO ($C1 = -0,347, C2 = 0,288; p < 0,001; r = -0,324$). Això indica que els estudiants del Clúster 2 no només veuen la IA com a substitut de la classe sinó que també tenen nivells superiors de desmotivació pedagògica i preferència per l'aprenentatge autònom. El patró és coherent: no anar a classe, utilitzar la IA per compensar-ho i estar desmotivats tendeixen a aparèixer junts al mateix perfil.

Síntesi i implicacions

El profiling confirma l'existència de dos perfils d'estudiants que es distingeixen gairebé en exclusiva per la seva relació amb la IA. El Clúster 1 – "ús instrumental" – agrupa estudiants que fan servir la tecnologia com a complement de l'estudi, mostren motivació relativa superior i, quan fallen a classe, és per circumstàncies externes. El Clúster 2 – "ús substitutiu" – agrupa estudiants per als quals la IA s'ha convertit en una alternativa real a les classes físiques.

La implicació per al disseny d'intervencions és clara. Per als estudiants del Clúster 2, actuar sobre els factors motivacionals i sobre la percepció que la IA substitueix la classe hauria de ser prioritari.

8. KNN Fuzzy-Aware

Com a pas previ a l'avaluació del KNN, s'ha comprovat si el grau de pertinença u_1 (Clúster 1, ús reduït de la IA) per si sol és suficient per fixar el llindar de classificació. S'ha ajustat un LDA 1D³⁰ sobre u_1 que dona un tall òptim $u_1 = 0,368$, que dona les mitjanes següents sobre el train: irregulars ($u_1 = 0,402$) vs. regulars ($u_1 = 0,524$).

Els resultats sobre el test ($n=67$) mostren que els dos llindars (LDA i PR) produeixen exactament les mateixes mètriques, cosa que valida la robustesa del tall triat:

Mètrica	Llindar PR (0,565)	Llindar LDA ($u_1 = 0,368$)
AUC	0,683	0,584
Accuracy	0,612	0,612
Precision	0,658	0,658
Recall	0,658	0,658
F1	0,658	0,658
Balanced Acc	0,605	0,605

Font: elaboració pròpia

Els resultats sobre el test mostren que el LDA 1D i el *KNN Fuzzy-Aware* obtenen pràcticament les mateixes mètriques ($AUC = 0,584$ i $0,683$ respectivament, amb matriu de confusió idèntica: 16 irregulars i 25 regulars correctament classificats, 13 errors en cada sentit). Això indica que u_1 ja captura pràcticament tota la informació discriminant del model.

El KNN es manté com a model de l'aplicació Shiny per dues raons: proporciona una probabilitat contínua de ser irregular i personalitzada per a cada nou estudiant (no una classificació binària basada únicament en u_1), i permet mostrar simultàniament el grau de pertinença a cada perfil i els alumnes del train més similars, enriquint la interpretació per al docent o coordinador que consulta l'eina.

³⁰ El LDA (*Linear Discriminant Analysis*) en una dimensió busca el punt de tall sobre u_1 que maximitza la separació entre les distribucions dels dos grups (regulars i irregulars). En aquest cas, el tall $u_1 = 0,368$ implica que els estudiants amb una pertinença al Clúster 1 superior a $0,368$ es classifiquen com a regulars, i els que queden per sota com a irregulars.

Capítol VII: Propostes docents

Els resultats obtinguts no només permeten identificar els factors associats a l'absentisme, sinó que apunten cap a un conjunt de mesures que es podrien incorporar a partir de les variables que els models han identificat com a determinants de l'assistència.

Reforçar l'avaluació continuada i donar-li més pes a la nota final. No tota avaluació continuada és igual d'efectiva: si l'estudiant percep que el seu esforç repercuteix poc en la qualificació final, un alumne desmotivats acaba preferint no seguir-la pel cost-benefici. Cal dissenyar-la de manera que requereixi un seguiment constant – i no únicament un o dos exàmens parcials – i que aquest esforç tingui un pes real i visible sobre la nota.

Reduir el rol passiu de l'alumne a l'aula. Els estudiants no abandonen les classes que els aporten valor afegit, de manera que cal fer classes més dinàmiques i participatives, casos pràctics o activitats grupals.

Gestionar de manera proactiva l'impacte de la intel·ligència artificial. La IA ha deixat de ser una eina de suport per a una part de l'alumnat i s'ha convertit en una alternativa real a la classe. Ja és una nova realitat, per tant, en comptes de prohibir el seu ús, cal integrar-la dins de la dinàmica de l'aula i adaptar el funcionament de les classes a aquesta nova eina.

Capítol VIII: Conclusions

Els resultats d'aquest treball permeten respondre als dos grans objectius plantejats: la identificació dels factors associats a l'absentisme a la Facultat d'Economia i Empresa i la detecció de perfils diferenciats d'estudiants per comprendre millor aquest fenomen.

L'absentisme universitari no respon a qüestions logístiques o estructurals de l'estudiant. S'ha demostrat que característiques com el gènere, el temps de desplaçament fins a la facultat, el grau o la sobrecàrrega d'assignatures matriculades no tenen cap incidència sobre l'assistència. La decisió d'anar a classe depèn fonamentalment de l'experiència viscuda a l'aula i de com s'estructura l'assignatura. En aquest sentit, seguir l'avaluació continuada es consolida com el principal factor de la presencialitat: quan l'assistència té conseqüències directes sobre la nota i s'exigeix un paper actiu a l'aula, l'estudiant té la necessitat d'una dedicació constant a l'assignatura.

D'altra banda, factors acadèmics com tenir un bon expedient o cursar el primer any de carrera actuen com a elements que afavoreixen una major assistència. Per contra, la desmotivació pedagògica és el factor que més frena l'assistència: les assignatures percebudes com a massa teòriques, avorrides o basades en un rol passiu de l'alumne desincentiven la presencialitat de manera generalitzada.

Més enllà d'aquests factors, la intel·ligència artificial ha irromput modificant els hàbits d'estudi i actua com un substitut directe de l'explicació docent. Com més percep l'alumne que la IA generativa és capaç de substituir i millorar les explicacions rebudes a l'aula, menor és la seva assistència. Aquest canvi tecnològic divideix l'alumnat en dos perfils clarament diferenciats. D'una banda, existeix un perfil d'ús instrumental, que està format per estudiants amb una assistència més regular i fan servir la tecnologia com un simple complement al seu aprenentatge. D'altra banda, apareix un perfil d'ús substitutiu, associat a l'absentisme, on la IA es converteix en una veritable alternativa a la classe presencial. Aquest segon grup pateix una forta desvinculació acadèmica, acompanyada d'una major desmotivació i preferència per l'aprenentatge autònom.

En definitiva, reduir l'absentisme requereix una docència amb valor afegit que cap eina d'intel·ligència artificial pugui replicar fora de l'aula, combinada amb estructures d'avaluació continuada que incentiven de manera efectiva la presència i el seguiment constant de l'assignatura.

Capítol IX: Declaració d'ús de la intel·ligència artificial

En l'elaboració d'aquest treball s'han utilitzat eines d'intel·ligència artificial com a suport en diverses fases del procés, d'acord amb els principis d'ús responsable.

En la fase de programació, s'ha utilitzat la intel·ligència artificial – concretament Claude Code – per fer una versió inicial del codi en R. En tots els casos, el codi ha estat revisat, adaptat i verificat per garantir la seva adequació a les dades i als objectius específics de l'estudi.

En la fase de revisió de la redacció, la IA s'ha utilitzat per fer una comprovació final de la coherència entre els resultats i les interpretacions textuais, amb l'objectiu de detectar possibles inconsistències o imprecisions. Per la redacció del treball i la interpretació dels resultats no s'ha utilitzat aquesta eina.

El seu paper ha anat molt més enllà de la generació de codi: ha estat una eina d'aprenentatge que m'ha ensenyat metodologies que d'altra manera haurien quedat fora de l'abast d'aquest treball.

Capítol X: Agraïments

Aquest treball no hauria estat possible sense el suport de moltes persones.

Vull agrair especialment a la meva tutora, Esther Vayá, la seva orientació, suport i recolzament al llarg de tot el procés. I vull agrair també a l'equip deganal de la FEE la seva confiança en el tema i el suport en la difusió de l'enquesta, sense el qual no hauria estat possible assolir la mida mostral necessària.

I, per sobre de tot, vull dedicar aquest treball al meu avi, que per poc no va poder saber quina carrera anava a estudiar, però em va deixar un missatge enorme uns dies abans de marxar sobtadament. *Avi, espero que allà on siguis estiguis orgullós de mi. Cada hora d'estudi durant aquests cinc anys i cada examen l'he fet sempre pensant en tu. T'estimo molt.*

I per descomptat, a la meva àvia, amb la que he viscut aquests anys durant el curs acadèmic, amb la que he compartit els sopars veient i emocionant-nos amb el seu programa preferit i amb la que m'hagués agradat dinar cada dia. *Yaya, sin ti esto no habría sido posible, gracias por cuidar tan bien de mí durante estos años, te lo juro que ha sido maravilloso vivir contigo estos años, no quiero que me faltes nunca.*

5. Bibliografia

- Álvarez Pérez, P. R., & López Aguilar, D. (2011). *Bordón* (Vol. 63). Bordón. Recollit de <https://recyt.fecyt.es/index.php/BORDON/article/download/29054/15498/91821>
- Blei, D. M. (2003). *Latent Dirichlet Allocation* (Vol. 3). Recollit de <https://www.jmlr.org/papers/volume3/blei03a/blei03a.pdf>
- Hosmer, D., Lemeshow, S., & Sturdivant, R. (2013). *Applied Logistic Regression*. Wiley. Recollit de <https://googlegroups.com/group/udsm-mbbgroupnetwork/attach/ef8b0b994f431/Applied%20Logistic%20Regression.pdf?part=0.1>
- Hu, L.-t., & Bentler, P. M. (1999). *Cutoff criteria for fit indexes in covariance structure analysis: Conventional criteria versus new alternatives*. A Multidisciplinary Journal. Recollit de https://www.researchgate.net/profile/Raoof_Mostafazadeh/post/Dear_respected_researchers_and_respected_Professors_do_you_have_access_to_any_or_both_of_these_articles_freely/attachment/59d6530c79197b80779ab183/AS%3A515263440986112%401499859785355/download/h
- Li, C.-H. (2015). *Confirmatory factor analysis with ordinal data: Comparing*. Psychonomic Society, Inc. 2015. Recollit de <https://link.springer.com/article/10.3758/s13428-015-0619-7>
- Rhemtulla, M., Brosseau-Liard, P. É., & Savalei, V. (2012). *When Can Categorical Variables Be Treated as Continuous? A Comparison of Robust Continuous and Categorical SEM Estimation Methods Under Suboptimal Conditions*. Psychological Methods. Recollit de https://psychmodels.ucdavis.edu/sites/g/files/dgvnsk12156/files/inline-files/rhemtullabrosseauliardsavalei_pm.pdf
- Strömberg, D., Lei, V., & Wu, Y. (2026). *DP21577 The Generative AI Learning Penalty: Evidence from Chinese Secondary Education*. Paris i Londres. Recollit de <https://cepr.org/publications/dp21577>
- Watkins, M. W. (2018). *Exploratory Factor Analysis: A Guide to Best Practice* (Vol. 44(3)). Journal of Black Psychology. doi:10.1177/0095798418771807

Capítol XI: Annexos

1. Formulari i codificació de dades

Annex 1: Formulari enviat a l'alumnat de la FEE de graus

L'enquesta original es pot consultar en el següent enllaç: <https://forms.cloud.microsoft/e/Vyk83X36S4> o mitjançant el següent codi QR



Benvolgudes i benvolguts estudiants de grau de la Facultat d'Economia i Empresa,

Us volem demanar de respondre una petita enquesta per tal de conèixer la vostra opinió sobre com podem millorar la docència i fer-la més valuosa, interessant i atractiva per a vosaltres. Només seran cinc minuts i podreu expressar la vostra opinió lliurement.

La participació és totalment voluntària, però us agrairem molt la vostra ajuda.

Totes les respostes són completament anònimes i les dades es tractaran exclusivament de forma agregada. Per tant, us agrairíem molt que ens donéssiu la vostra opinió sincera. El vostre feedback és clau per ajudar-nos a adaptar el curs a les vostres necessitats. Moltes gràcies!

(El responsable del tractament de les dades és la Secretaria General de la Universitat de Barcelona. Les dades seran tractades amb la finalitat de gestionar l'enquesta. Atesa la naturalesa anònima de la consulta, no es recullen dades que permetin identificar els participants. Per aquest motiu, de conformitat amb l'article 26 del RGPD, s'informa que no serà possible exercir els drets d'accés, rectificació, supressió o portabilitat, ja que la Universitat no pot identificar a quina persona correspon cada resposta.

Secció 1: Dades acadèmiques

1. Quin grau estudies?
 - ADE
 - Economia
 - Empresa Internacional
 - Estadística
 - Sociologia
 - Doble grau: Economia + Estadística
 - Doble Grau ADE + Dret
 - Doble Grau: ADE + Matemàtiques
 - Doble Grau: ADE + Química
 - Doble Grau: ADE + Sociologia
2. Quin curs estàs fent aquest any?
 - 1r
 - 2n
 - 3r
 - 4t
 - 5è
 - A partir de 6è
3. A quantes assignatures t'has matriculat aquest curs?
Numèrica entera [1 - 17]
4. Quina és la teva nota mitjana d'expedient? (Sobre 10)
 - 5-5,9
 - 6-6,9
 - 7-7,9
 - 8-8,9
 - ≥ 9
5. Generalment quin tipus d'avaluació segueixes?
 - Única
 - Continuada
6. A quin percentatge de classes assisteixes?
Numèrica entre [0 - 100]

Secció 2: Situació personal

7. Quin és el teu gènere?
 - Dona
 - Home
 - No binari
 - Prefereixo no respondre
8. Quina edat tens?
Numèrica entera [≥ 17]
9. Quina ha estat la teva dedicació als estudis durant aquest curs?
 - Estudio a temps complet (només estudio).
 - Estudio però també treballo ocasionalment
 - Estudio i treball a temps parcial (menys de 35 hores setmanals)
 - Treball a temps complet (més de 35 hores setmanals) i estudio
10. Quants minuts triges en desplaçar-te fins a la facultat?
Numèrica

Secció 3: La teva opinió sobre les classes i la teva assistència

11. Valora la importància que tenen per a tu els següents motius per NO assistir a classe: (1: Gens d'acord a 5: Totalment d'acord)
- Perquè treballo
 - Perquè tinc responsabilitats familiars
 - Perquè tinc problemes de salut
 - Perquè visc lluny i trigo molt a venir
 - Prefereixo estudiar pel meu compte
 - El material al Campus Virtual és suficient
 - Quan tinc una prova deixo d'anar a classe
 - Quan anar a classe no ajuda a aprovar
 - Quan les classes són avorrides
 - Classes magistrals / paper passiu
 - Quan les classes són massa teòriques
 - No m'agrada com explica el/la professor/a
 - Quan repeteixo no cal anar a classe
 - Prefereixo anar a una acadèmia
 - Quan els meus amics/gues tampoc hi van
12. Quines estratègies t'animen a assistir a classe? (1: Gens d'acord a 6: Totalment d'acord)
- Aval. continuada té més pes a la nota
 - Quan hi participo (treballs, presentacions)
 - Canvi d'activitat (problemes, casos)
 - Quan la classe es fa en grups reduïts
 - Quan les classes són més curtes
 - Quan es fa descans
 - Bon clima i comunicació
 - Quan el/la professor/a explica molt bé
 - El ritme de les explicacions es segueix bé
 - Quan es fan activitats d'AC a classe
 - Professor/a proper a l'alumnat
 - Quan l'horari em va bé
 - L'assistència té pes a la nota
13. Vols explicar breument una experiència d'una assignatura que t'hagi interessat/agradat especialment i el motiu?
14. Vols explicar breument una experiència d'una assignatura que NO t'hagi interessat/agradat assistir a classe i el motiu?
15. Vols afegir alguna proposta que et motivaria a assistir a classe?

Secció 4: Ús de la Intel·ligència Artificial

16. Indica en quina mesura estàs d'acord amb les següents afirmacions. (1: Gens d'acord a 6: Totalment d'acord)
- Utilitzo eines d'IA de manera habitual
 - Ajuda a entendre continguts no entesos
 - La IA redueix la necessitat d'anar a classe
 - Em fio de la IA sense contrastar
 - Deixo de prestar atenció (IA ho explicarà)
 - Preocupació per l'aprenentatge real
 - L'ús de la IA millora el rendiment
 - Pujo material propi per contextualitzar

SECCIÓ 1: DADES ACADÈMIQUES			
Número pregunta	ID variable	Codificació / Tipus de Variable	Tipus de variable
1	GRAU	• 1 = ADE • 2 = Economia • 3 = Empresa Internacional • 4 Estadística • 5 = Sociologia • 6 = Doble grau: Economia + Estadística • 7 = Doble Grau ADE + Dret • 8 = Doble Grau: ADE + Matemàtiques • 9 = Doble Grau: ADE + Química • 10 = Doble Grau: ADE + Sociologia	Categòrica (Nominal)
2	CURS	• 1 = 1r • 2 = 2n • 3= 3r • 4 = 4t • 5 = 5è • 6 = A partir de 6è	Categòrica (Ordinal)
3	N_ASSIG	Numèrica entera [1 - 17]	Numèrica (Discreta)
4	NOTA	• 1= [5-5.9] • 2 = [6-6.9] • 3 = [7-7.9] • 4 = [8-8.9] • 5: [≥ 9]	Categòrica (Ordinal)
5	T_AVAL	• 0 = Única • 1 = Continuada	Categòrica (Nominal)
6	P_ASSIST	Numèrica percentual [0 - 100]	Numèrica

SECCIÓ 2: SITUACIÓ PERSONAL

Número pregunta	ID variable	Codificació / Tipus de Variable	Tipus de variable
7	GENERE	• 1 = Dona • 2 = Home • 3 = No binari • 4 = Prefereixo no respondre	Categòrica (Nominal)
8	EDAT	Numèrica entera $[\geq 17]$	Numèrica (Discreta)
9	DEDIC	• 1 = E. Complet • 2 = T. Ocasional • 3 = T. Parcial • 4 = T. Complet	Categòrica (Nominal)
10	DESPL	Numèrica (minuts)	

SECCIÓ 3: LA TEVA OPINIÓ SOBRE LES CLASSES I LA TEVA ASSISTÈNCIA


Número pregunta	ID variable	Codificació / Tipus de Variable	Tipus de variable
11 (Motius de no assistència)	M_TREB	M_AVORR	Escala de Likert
	M_FAM	M_PASSIU	
	M_SALUT	M_TEOR	
	M_DIST	M_PROF	
	M_AUTON	M_REPET	
	M_CV	M_ACAD	
	M_EXAM	M_AMICS	
	M_UTIL		
12 (Estratègies d'assistència)	E_PES_AC	E_EXPL	Escala de Likert
	E_PART	E_RITME	
	E_DINAM	E_ACT_AC	
	E_REDU	E_PROP	
	E_CURT	E_HORA	
	E_DESC	E_PES_AS	
	E_CLIMA		
12	EXP_POS	Text lliure	Qualitativa (Text)
13	EXP_NEG	Text lliure	Qualitativa (Text)
14	PROP_MOT	Text lliure	Qualitativa (Text)

SECCIÓ 4: ÚS DE LA IA

Número pregunta	ID variable	Codificació / Tipus de Variable	Tipus de variable
15	IA_HABIT	1 = Gens d'acord 6 = Totalment d'acord	Escala de Likert
	IA_COMPR		
	IA_SUBST		
	IA_CONF		
	IA_ATENC		
	IA_PREOC		
	IA_REND		
	IA_PDFS		


2. Preprocessament

Annex 3: Box-plot del temps de desplaçament




3. Descriptiva


Annex 4: Box-plot de l'edat segons el grup d'assistència



Annex 5: Distribució de l'assistència per gènere




Annex 6: Percentatge d'alumnes que assisteixen regularment per grau i curs (cel·les amb n>5)



4. EDA

Annex 7: Associació (*V* de Cramér) entre totes les variables categòriques. S'exclouen les parelles redundants per construcció (variables derivades).




Annex 8: Validació Monte-Carlo

El gràfic de punts que compara els p-valors del Chi-quadrat estàndard amb els de Monte Carlo per a totes les parelles amb freqüències esperades < 5 .


S'observa que els resultats del contrast Chi-quadrat es mantenen robustos en aplicar la simulació de Monte Carlo ($B = 10.000$). En cap cas rellevant hi ha hagut canvi de significació.

5. EFA


Annex 10: Comunalitats variables motius de no assistència




Annex 11: Comunalitats variables estratègies d'assistència




Annex 12: Comunalitats variables ús de la IA



Annex 13: Càrregues factorials – Ús de la IA (càrregues > 30, negreta > 50)




Annex 14: Correlació entre els factors d'Estratègies i l'assistència




6. Logit explicatiu

Annex 15: Calibration plot



Annex 16: Leverage vs Residus de Pearson estandarditzats



Annex 17: Anàlisi de sensibilitat — OR complet vs. sense observacions atípiques

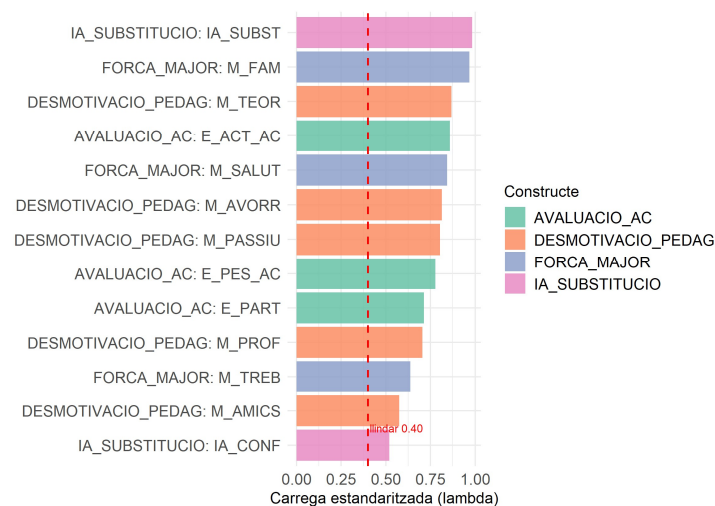
Variable	OR complet	OR sense outliers	Canvi (%)	Estable
MOT_DESMOTIVACIO	0,472	0,391	-17,1%	Si
MOT_FORCA_MAJOR	1,428	1,531	+7,1%	Si
EST_AVALUACIO_AC	1,542	1,779	+15,4%	Si
IA_SUBST_num	0,687	0,654	-4,7%	Si
T_AVALContinuada	8,232	15,098	+83,4%	No
CURS_1R	2,679	2,844	+6,1%	Si
NOTA_num	1,624	1,927	+18,7%	Si
MOT_DESMOTIVACIO:CURS_1R	2,792	2,768	-0,9%	Si

7. SEM

Annex 18: Resum dels indicadors utilitzats en el SEM


Indicador	Què mesura?	Valor recomanat
CFI	Compara l'ajust del model amb un model nul on les variables no estan relacionades.	$\geq 0,95$
TLI	Avalua l'ajust del model tenint en compte la seva complexitat.	$\geq 0,95$
RMSEA	Estima l'error d'ajust que tindria el model en la població.	$\leq 0,08$
SRMR	Diferència mitjana entre les correlacions observades i les reproduïdes pel model.	$\leq 0,08$
Càrrega factorial (λ)	Indica la força de la relació entre un ítem observat i el constructe latent. Mostra fins a quin punt l'ítem representa el factor que està mesurant; com més alta és la càrrega, més informació aporta l'ítem sobre el constructe.	$\geq 0,50$ acceptable; $\geq 0,70$ indica una relació forta
AVE	Proporció de variància dels ítems explicada pel constructe latent.	$\geq 0,50$
Omega (ω)	Consistència interna dels ítems que formen el constructe.	$\geq 0,70$

Annex 19: Càrregues factorials estandarditzades del CFA per cada constructe




8. Logit predictiu

Annex 20: Corba Precision – Recall del lògit predictiu (OOF train)



Annex 21: Corba ROC sobre el test




Annex 22: Matriu de confusió del logit


Valor Observat	Irregular	TN 25	FP 2
	Regular	FN 18	TP 23
		Irregular	Regular
		Valor Predit	

9. Random forest


Annex 23: Matriu de confusió de RF-B




Annex 24: Corba Precision – Recall RF-B (OOB)




Annex 25: Corba ROC sobre el test del RF-A




Annex 26: Matriu de confusió de RF-A




Annex 27: Importància de les variables RF-A




Annex 28: Dependence plot RF-A – MOT_DESMOTIVACIÓ




Annex 29: Dependence plot RF-A – MOT_AUTOGESTIÓ



Annex 30: Dependence plot RF-A – IA_EINA_ESTUDI




Annex 31: Dependence plot RF-A – IA_SUBST_num




10. Boosting


Annex 32: Importància SHAP del CatBoost




Annex 33: Comparació mètriques traint vs test CatBoost



Annex 34: Corba Precision – Recall XGBoost



Annex 35: Corba ROC sobre el test del XGBoost




Annex 36: Matriu de confusió del XGBoost


Valor Observat	Irregular	TN 25	FP 2
	Regular	FN 15	TP 26
		Irregular	Regular
		Valor Predit	

11. SVM


Annex 37: Hetmap Grid Search SVM



Annex 38: Corba Precision – Recall SVM



Annex 39: Corba ROC sobre el test del SVM




Annex 40: Matriu de confusió del SVM

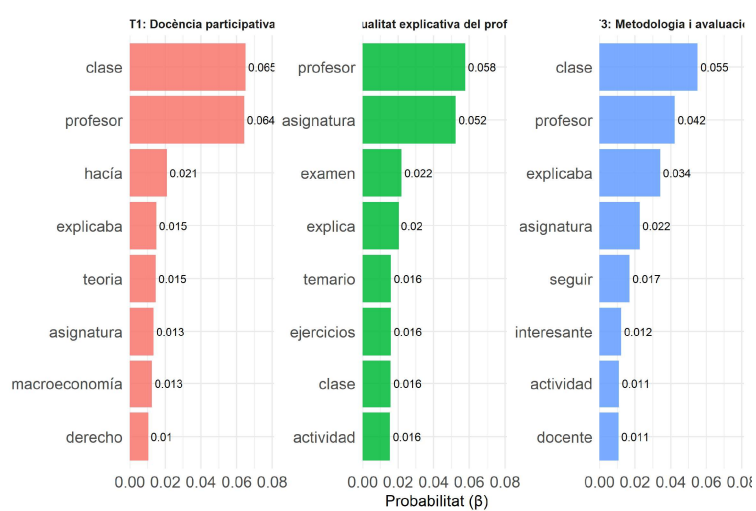
Valor Observat	Valor Predit	
	Irregular	Regular
Irregular	TN 25	FP 2
Regular	FN 17	TP 24

12. Anàlisi textual


Annex 41: Frequència de paraules de l'experiència positiva (top 20)



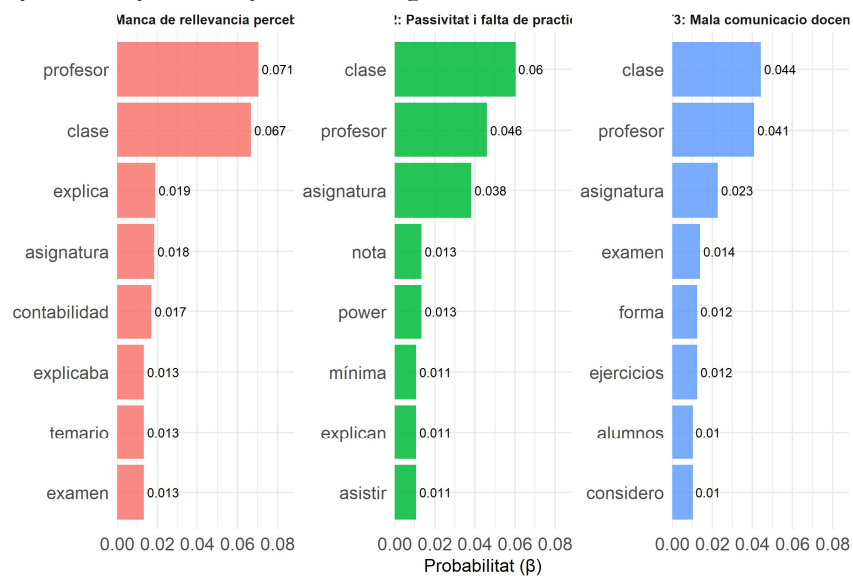
Annex 42: Tòpics LDA per les experiències positives




Annex 43: Frequència de paraules de les experiències negatives



Annex 44: Tòpics LDA per les experiències negatives




Annex 45: Frequència de paraules de les propostes de millora



13. Clustering i profiling

Annex 46: Distribució de P_ASSIST per clúster.



Annex 47: Factors EFA per clúster

