

Capítol III: Metodologia i dades

Per assolir els objectius d'aquest treball s'ha dut a terme una anàlisi quantitativa a partir de dades primàries recollides mitjançant enquesta. El procés combina diverses tècniques estadístiques i de mineria de dades: des de l'estadística descriptiva i tests no paramètrics de comparació de grups, fins a tècniques de reducció de la dimensionalitat (anàlisi factorial exploratòria) i models de classificació, tant explicatius com predictius. Tot el processament i l'anàlisi s'ha dut a terme amb el programari estadístic R. En els apartats següents es detalla el disseny de l'estudi, la procedència i estructura de les dades, el tractament previ que han requerit, i finalment la metodologia estadística aplicada per respondre a cada part de l'objectiu.

1. Disseny de l'estudi i variable objectiu

Per respondre a l'objectiu de l'estudi — identificar els motius d'absentisme i detectar perfils diferenciats d'estudiants —, s'ha optat per un disseny que combina un enfocament explicatiu (per quantificar l'efecte de cada factor sobre el comportament d'assistència) amb un enfocament predictiu (per classificar estudiants segons el seu perfil de risc d'absentisme).

La variable dependent és el percentatge d'assistència declarat per l'estudiant (P_ASSIST), una variable contínua entre 0 i 100. Ara bé, treballar directament amb aquesta variable contínua presenta un inconvenient pràctic: la seva distribució és asimètrica i acumulada als extrems, cosa que dificulta la modelització i la interpretació dels resultats. Per aquest motiu, s'ha optat per crear una variable binària ($GRUP_ASSIST$), que classifica els estudiants en dos grups: *regulars* ($P_ASSIST \geq 80\%$) i *irregulars* ($P_ASSIST < 80\%$). El llindar del 80% no és arbitrari: coincideix amb el mínim d'assistència que alguns plans docents de la facultat estableixen com a condició per a poder seguir l'avaluació continuada. Amb aquest criteri, un 56,7% dels enquestats es classifica com a regulars i un 43,3% com a irregulars, una distribució prou equilibrada que no genera problemes de classes desequilibrades en els models posteriors.

2. Recollida de dades i instrument

Les dades provenen d'una enquesta dissenyada específicament per a aquest estudi i distribuïda entre l'alumnat de grau de la FEE entre el febrer i l'abril del 2026. El formulari es va elaborar amb Microsoft Forms i es va difondre a través dels canals oficials de la facultat. La participació va ser voluntària i anònima.

L'enquesta es va difondre a través dels canals oficials de la facultat, una decisió que va sorgir de en proposar el tema d'aquest treball. Després de comentar-ho amb la meua tutora, Vicedegana d'Estudiants, Ocupabilitat i Innovació Docent de la FEE, ella mateixa ho va traslladar a l'equip deganal. Atès que es tracta d'un tema rellevant per a la facultat – i que ja s'havia abordat en un estudi anterior anys enrere – es va decidir difondre l'enquesta a través dels Campus Virtuals dels Plans d'Acció Tutorial (PAT) de cada grau, amb l'objectiu d'arribar al màxim d'alumnat possible.

La mostra final és de 342 estudiants. Tot i que la mida mostral permet aplicar els mètodes estadístics emprats en aquest treball i obtenir conclusions rellevants, cal tenir en compte que l'estudi presenta limitacions pel que fa a la capacitat de generalitzar els resultats al conjunt de l'alumnat de la FEE.

L'enquesta es va estructurar en quatre seccions diferenciades. La primera recull informació acadèmica bàsica: grau, curs, nombre d'assignatures matriculades, nota mitjana d'expedient, tipus d'avaluació i percentatge d'assistència. La segona secció captura la situació personal de l'estudiant: gènere, edat, dedicació laboral i temps de desplaçament fins a la facultat. La tercera, que és la part més important del qüestionari, conté dos blocs de preguntes en escala Likert: un sobre els motius per no assistir a classe (15 ítems) i un altre sobre les estratègies que implementa l'alumnat a l'hora de decidir perquè va o deixa d'anar a una classe (13 ítems), a més de tres preguntes obertes on podien parlar d'experiències positives, negatives o propostes de millora. Finalment, la quarta secció és la més innovadora i recull la percepció de l'estudiant sobre l'ús de la intel·ligència artificial i el seu impacte en els hàbits d'estudi (8 ítems Likert). (Vegeu l'enquesta completa a l'Annex 1)

3. Descripció de les variables

Variables acadèmiques i de rendiment. La nota mitjana d'expedient (NOTA) es recull en format ordinal amb cinc categories: 1=[5-5,9], 2=[6-6,9], 3=[7-7,9], 4=[8-8,9] i 5=[≥9]. Tot i la naturalesa ordinal, s'ha tractat com a variable numèrica discreta en els models, de manera que el valor 1 representa la franja de notes més baixa i el 5 la més alta. El tipus d'avaluació (T_AVAL) és dicotòmica: única (0) o continuada (1), i constitueix una de les variables amb més poder explicatiu de l'absentisme al llarg de tota l'anàlisi. El nombre d'assignatures matriculades (N_ASSIG) és una variable numèrica discreta que actua com a indicador indirecte de la càrrega acadèmica.

Finalment, el grau cursat (GRAU) i el curs (CURS) completen la situació acadèmica de l'enquestat: el primer és una variable categòrica nominal amb deu categories (incloent-hi els dobles graus), mentre que el segon és ordinal, de 1r a "a partir de 6è".

Variables de situació personal i laboral. La dedicació als estudis (DEDIC) recull quatre categories: estudiant a temps complet, treballa ocasionalment, treballa a temps parcial i treballa a temps complet. El temps de desplaçament (DESPL) és numèric continu, mesurat en minuts, i presenta alguns valors extrems que s'han tractat en la fase de preprocessament.

Finalment, el gènere (GENERE) i l'edat (EDAT) completen la descripció sociodemogràfica: la primera és una variable categòrica nominal amb quatre categories (dona, home, no binari, prefereixo no respondre), i la segona es recull de forma numèrica entera.

Variables de percepció: motius per no assistir a classe. El bloc de motius recull 15 ítems (variables *M_*) mesurats en escala Likert d'1 (Gens d'acord) a 5 (Totalment d'acord), que demanen a l'enquestat fins a quin punt cada motiu explica la seva no assistència a classe. Els ítems cobreixen causes de naturalesa molt diversa: laborals i familiars (*M_TREB*, *M_FAM*), de salut (*M_SALUT*), per la distància (*M_DIST*), d'autonomia en l'estudi (*M_AUTON*, *M_CV*), estratègiques en relació a l'avaluació (*M_EXAM*, *M_UTIL*, *M_REPET*), i de percepció sobre les classes i el professorat (*M_AVORR*, *M_PASSIU*, *M_TEOR*, *M_PROF*, *M_ACAD*, *M_AMICS*). Cal aclarir que està en escala de l'1 al 5 i no fins al 6 per un error en el disseny de l'enquesta.

Variables de percepció: estratègies docents que afavoreixen l'assistència. El bloc d'estratègies recull 13 ítems (variables *E_*) amb l'escala Likert d'1 a 6, que demanen a l'enquestat en quina mesura determinades pràctiques docents l'animen més a assistir a classe. Inclou aspectes relacionats amb l'avaluació (*E_PES_AC*, *E_PES_AS*), amb la metodologia i la dinàmica de classe (*E_PART*, *E_DINAM*, *E_REDU*, *E_ACT_AC*), amb l'estructura i durada (*E_CURT*, *E_DESC*,

E_RITME), amb el clima i la relació amb el professorat (E_CLIMA, E_EXPL, E_PROP), i amb aspectes organitzatius (E_HORA).

Variables de resposta oberta. El qüestionari inclou tres preguntes de text lliure que recullen informació qualitativa: l'experiència positiva amb alguna assignatura (EXP_POS), l'experiència negativa que ha portat a no assistir a classe (EXP_NEG) i les propostes de l'alumnat per motivar l'assistència (PROP_MOT). Aquestes variables no es poden incloure en els models, però s'utilitzaran per fer anàlisi textual i buscar la seva relació amb els resultats que s'obtinguin.

Ús de la intel·ligència artificial. El bloc d'IA recull 8 ítems (variables IA_) mesurats en la mateixa escala Likert d'1 (Gens d'acord) a 6 (Totalment d'acord), que cobreixen aspectes de la relació de l'estudiant amb aquestes eines: la freqüència d'ús (IA_HABIT), la utilitat per entendre continguts (IA_COMPR), la percepció de substitució de l'assistència a classe (IA_SUBST), el grau de confiança sense contrastar la informació (IA_CONF), la pèrdua d'atenció a classe per dependència de la IA (IA_ATENC), la preocupació per l'aprenentatge real (IA_PREOC), la percepció de millora del rendiment (IA_REND) i l'ús per contextualitzar material propi (IA_PDFS).

Codificació i tractament. La matriu de codificació completa es recull a l'Annex 2. Les variables Likert es tracten com a ordinals en els tests no paramètrics i com a numèriques contínues quan s'incorporen als factors de l'EFA.

4. Preprocessament de dades


El següent pas abans d'iniciar el modelatge és netejar les dades. L'objectiu d'aquest apartat és trobar els errors i possibles dades que puguin causar errors o distorsions en el model. Per això, s'han revisat sistemàticament tant els valors faltants com els valors atípics (*outliers*).

4.1. Depuració i gestió dels missings

El primer pas ha consistit en una revisió de la consistència de les dades. En filtrar les variables numèriques per trobar possibles valors anòmals, s'ha detectat un cas amb un temps de desplaçament (DESPL) de 605 minuts (vegeu Annex 3), és a dir, més de 10 hores de trajecte fins a la facultat. Atès que aquest valor és pràcticament impossible, s'ha interpretat com un error tipogràfic en el moment d'emplenar el formulari.

Per tenir més context d'aquest cas, s'ha consultat la resposta de text obert del mateix estudiant, on comenta que triga molt a arribar a la facultat. A partir d'aquesta informació, s'ha optat per imputar manualment un valor de 65 minuts, una xifra coherent amb el context de la resposta. Alternativament, s'havia provat una imputació amb el mètode MICE, que donava un resultat de 40 minuts, però aquesta xifra s'ha descartat per no ajustar-se tan bé al que l'estudiant descrivia.

Pel que fa als valors absents, s'han mirat totes les variables per identificar on es concentraven les dades faltants i decidir com tractar-les en cada cas. El gràfic següent mostra el percentatge de NA per variable:



Font: elaboració pròpia

S'ha observat que les variables on falten respostes són les de caràcter obert (PROP_MOT, EXP_NEG, EXP_POS), amb percentatges que oscil·len entre el 60,8% i el 66,4%. Cal destacar que aquestes preguntes eren de resposta lliure i que únicament s'utilitzaran per fer l'anàlisi textual.


4.2. Detecció d'outliers

En aquesta base de dades es disposa d'una mostra mixta (variables numèriques i ordinals tipus Likert). Per aquest motiu, s'ha optat per una metodologia robusta en dues etapes:

1. **Distància de Gower:** s'ha calculat una matriu de distàncies utilitzant la distància de Gower que, a diferència de la distància euclidiana, aquesta és idònia per a dades mixtes, ja que permet ponderar correctament les variables categòriques i les escales Likert sense necessitat de transformar-les artificialment en numèriques contínues.
2. **Local Outlier Factor (LOF):** sobre aquesta matriu, s'ha aplicat l'algorisme LOF. Aquest mètode funciona bé perquè mesura la densitat local d'una observació respecte als seus veïns, de manera que aquells individus que estiguin més allunyats dels seus veïns, poden ser "estranyos".

Per garantir la robustesa, s'ha testejat l'algorisme amb diferents valors de veïns ($k=5, 10, 15, 18, 20$). El criteri per considerar una observació com a *outlier* ha estat un *LOF score* superior a 2. Els resultats mostren una gran estabilitat de la mostra: amb $k=18$ (l'arrel quadrada de n), només s'identifica una única observació (índex 153) com a potencial valor atípic, però té un *score* inferior a 2.

Gràfic 2: LOF score amb distància de Gower



Font: elaboració pròpia

L'observació 153 correspon a una dona de 20 anys amb una nota excel·lent que cursa 10 assignatures simultàniament. Tot i que és un perfil poc freqüent, no representa un error de mesura ni un valor impossible. Per tant, s'ha pres la decisió de mantenir-la a la mostra, ja que la seva eliminació podria treure variabilitat rellevant a l'estudi del perfil d'alt rendiment.

Finalment, convé assenyalar una decisió metodològica clau. Inicialment, es va considerar l'aplicació d'una Anàlisi Factorial de Dades Mixtes (*Factor analysis of mixed data: FAMD*) prèvia al càlcul del LOF, amb l'objectiu de reduir la dimensionalitat del conjunt de dades per poder aplicar un altre mètode de detecció d'outliers multivariants, el *Mahalanobis* robust. No obstant això, aquesta via es va descartar en la fase exploratòria, ja que calia retenir un nombre de

dimensions excessivament elevat per assolir un percentatge de variància explicada acceptable (al voltant del 70%).

Donat que l'objectiu inicial era considerar realment com *outliers*, aquelles observacions que es detectessin amb els dos mètodes, finalment el criteri de detecció s'ha basat únicament en els resultats del LOF.

5. Anàlisi descriptiva

Abans d'entrar en els models predictius, és fonamental entendre les dades amb les quals es treballa. L'objectiu d'aquesta secció és identificar quins patrons separen els estudiants que van a classe regularment dels que no ho fan, i obtenir una visió preliminar de quines variables poden ser rellevants a l'hora de modelar. A continuació es presenten les variables analitzades i els estadístics i gràfics emprats.

5.1. *Variables analitzades*

Les variables analitzades es poden agrupar en tres blocs: variables numèriques (edat, temps de desplaçament, nombre d'assignatures i percentatge d'assistència), variables categòriques (gènere, curs, grau, dedicació laboral i tipus d'avaluació) i variables Likert (motius de no assistència, estratègies per anar a classe i ús de la intel·ligència artificial).

5.2. *Estadístics utilitzats*

Per a les variables numèriques s'han calculat la mitjana, la mediana, la desviació estàndard, el mínim i el màxim. Per a les variables Likert, s'ha comparat la mitjana de cada ítem entre els dos grups (regulars i irregulars) per identificar on hi ha les diferències més grans. Aquest apartat és purament descriptiu i l'objectiu és detectar quins ítems mostren un patró diferenciat entre grups. La significació d'aquestes diferències es contrasta en el següent apartat, mitjançant el test de Mann-Whitney.

5.3. *Variable objectiu i definició de grups*

Tot i que es disposa de la variable contínua (percentatge d'assistència), com s'ha explicat a l'apartat 1, per a l'anàlisi s'utilitza la variable dicotòmica GRUP_ASSIST (regulars/irregulars, amb llinar al 80%).

5.4. *Gràfics utilitzats*

S'han emprat box-plots per comparar la distribució del percentatge d'assistència entre grups, gràfics de barres apilades per a variables categòriques, i gràfics de barres de doble columna per comparar les mitjanes dels ítems Likert entre regulars i irregulars. A l'annex es recullen *heatmaps* per curs i grau, que, tot i apuntar patrons interessants, presenten cel·les amb mida mostral molt reduïda i poden induir a interpretacions errònies si no es miren amb perspectiva global.

Per tal de no desviar l'atenció dels resultats més determinants, s'ha optat per moure a l'annex aquells gràfics on les diferències entre grups són mínimes. És el cas de l'edat i del gènere, dues variables que, malgrat haver-se explorat visualment, no mostren contrastos rellevants entre estudiants regulars i irregulars.

6. Anàlisi Exploratori de Dades (EDA)

Aquest apartat busca identificar quines variables es relacionen amb l'assistència i detectar patrons o redundàncies que puguin condicionar els models posteriors. Atesa la naturalesa de les dades (majoritàriament categòriques i ordinals en escala Likert), s'han aplicat exclusivament contrastos no paramètrics¹.

La metodologia es divideix en tres eixos:

- **Associació entre variables categòriques i l'assistència:** s'utilitza el test Chi-quadrat i la *V de Cramér* com a mesura de la intensitat de l'associació². Els resultats relatius a GRAU s'interpreten amb cautela, donat l'elevat nombre de categories i la baixa freqüència en algunes cel·les; per a aquesta dimensió es prioritza la variable agrupada DOBLE_GRAU_EST.
- **Relació entre variables Likert i numèriques amb l'assistència:** s'utilitza el test de Mann-Whitney U i la correlació rang-biserial (r) com a mesura d'efecte, que indica magnitud i direcció de la diferència entre grups (positiu = regulars puntuen més alt). Donada l'elevada presència d'empats en totes les variables Likert, es reporta també la τ de Kendall com a contrast de robustesa³.
- **Correlació de les variables numèriques amb el percentatge d'assistència:** s'utilitza la correlació de Spearman i, en els casos amb empats superiors al 10%, la τ de Kendall. P_ASSIST s'exclou de la comparació amb GRUP_ASSIST, ja que aquesta darrera deriva directament de la primera.

Cal destacar que, prèviament a l'anàlisi, s'han creat variables categòriques noves a partir dels resultats de la descriptiva, agrupant categories amb patrons d'assistència similars per facilitar la seva interpretació i posterior ús als models. Aquestes variables són: TREB_INTENS (1 si treballa a temps parcial o complet), NOTA_ALTA (1 si nota > 8), CURS_1R (1 si és de primer curs) i DOBLE_GRAU_EST (1 si estudia doble grau o Estadística).

¹ Les variables no compleixen els supòsits de normalitat ni homoscedasticitat necessaris per als tests paramètrics clàssics.

² Aquesta mesura és independent de la mida mostral. En els casos amb cel·les de freqüència esperada inferior a 5 (condició que invalida l'aproximació asimptòtica del Chi-quadrat), s'ha aplicat una simulació de Monte Carlo ($B=10.000$) per garantir la validesa dels p-valors; en cap cas hi ha hagut canvis de significació respecte al test estàndard.

³ La τ de Kendall és més adequada que Spearman en distribucions amb molts valors repetits, com és el cas de les escales Likert.

7. Anàlisi Factorial Exploratòria

Les variables de percepció (motius, estratègies, ús de la IA) mesuren aspectes molt propers entre si, i introduir-les de forma aïllada als models generaria multicol·linealitat. Per això s'aplica una anàlisi exploratòria de les dades (*Exploratory Factor Analysis*: EFA) a cada bloc per separat, que busca constructes latents interpretables, com la desmotivació pedagògica o la dependència de la IA. Es pot llegir més informació sobre l'anàlisi factorial exploratòria en aquest article: (Watkins, 2018). Aquest apartat s'ha redactat seguint les bones pràctiques que recomana.

Els contrastos que verifiquen si les dades presenten una bona estructura correlacional⁴ han estat superats pels tres blocs. El KMO ha estat entre 0,82 i 0,85 i el test de Bartlett ha estat significatiu en tots els casos, $p < 0,001$).

Per determinar el nombre de factors s'ha aplicat l'anàlisi paral·lela, i per a la seva interpretació s'ha utilitzat una rotació obliqua (*oblimin*) atès que permet la correlació entre factors i els constructes avaluats estan interrelacionats.⁵

S'han mantingut fora de l'EFA cinc variables amb comunalitat⁶ molt baixa (a l'article es consideren baixes si estan per sota de 0,3 o 0,4) i sense diferències significatives a l'EDA (M_ACAD: $h^2 = 0,17$, E_PES_AS: $h^2 = 0,26$, IA_PREOC: $h^2 = 0,21$), i les variables M_DIST ($h^2 = 0,22$) i E_HORA ($h^2 = 0,22$) que si eren significatives a l'anàlisi exploratòria de les dades.

Un cop refeta l'anàlisi, s'ha forçat el nombre final de factors a 3 (Motius) i 4 (Estratègies), ja que el factor addicional suggerit en cada cas resultava residual (explicant menys que d'un 4% de variabilitat). El bloc IA queda fixat en 2 factors de forma natural una vegada extreta la variable IA_PREOC.

⁴ El test de Bartlett, contrasta la hipòtesi nul·la que la matriu de correlacions és una matriu identitat —és a dir, que no hi ha cap correlació entre variables—, i el KMO (Kaiser-Meyer-Olkin) compara les correlacions totals amb les parcials, indicant si la relació entre variables es deu a factors comuns globals o només a connexions aïllades entre elles

⁵ L'anàlisi paral·lela compara els valors propis observats amb els d'una matriu de dades aleatòria de la mateixa mida, retenint només els factors que superen aquests valors aleatoris.

⁶ La comunalitat és la variabilitat total d'una variable explicada pels factors latents comuns.

8. Anàlisi inferencial i causal

Fins aquí, l'anàlisi ha consistit a entendre les dades (descriptiva i anàlisi exploratòria de les dades) i identificar l'estructura latent de les percepcions dels estudiants (anàlisi exploratòria de factors). El pas següent és aprofitar aquests factors i la resta de variables per respondre el primer gran objectiu del treball: identificar quines variables tenen un efecte real sobre l'assistència, quina és la seva magnitud i direcció, i com s'articulen entre elles per explicar per què alguns estudiants no van a classe.

Aquest bloc es divideix en dos models amb objectius diferenciats. El Model d'Equacions Estructurals (*Structural Equation Model*: SEM) permet anar més enllà de la correlació i contrastar relacions causals directes i indirectes entre factors, cosa que cap dels mètodes anteriors permetia fer. El Logit, en canvi, s'utilitza per quantificar l'efecte individual de cada variable sobre la probabilitat de ser un estudiant irregular: a diferència dels models de *machine learning*, permet fer inferència estadística formal – contrastar significació, estimar *odds ratios* i construir intervals de confiança –, i per aquest motiu s'estima sobre la mostra completa ($n=342$).

8.1. Model logístic

L'objectiu d'aquest model no és predir si un estudiant anirà o no a classe, sinó identificar quines variables tenen un efecte estadísticament significatiu sobre l'assistència i quantificar-ne la magnitud. Per això s'estima sobre la mostra completa ($n = 342$): a diferència dels models de *machine learning* del bloc següent, el logit permet fer inferència formal, és a dir, contrastar la significació de cada variable i construir intervals de confiança per als *odds ratios*⁷.

La selecció de variables s'ha fet en dues etapes. Primer, una eliminació *backward* per BIC a partir del model complet – el BIC és l'adequat perquè tendeix a models més parsimoniosos –. Durant el procés, s'ha comparat mantenir el factor IA_SUBSTITUCIO agregat de l'EFA o substituir-lo per IA_SUBST_num (la variable original en format Likert). El model amb IA_SUBST_num individual obté un BIC de 399,69 davant del 409,60 del model amb el factor agregat, una diferència de 10 punts prou gran per decantar-se per la versió amb les variables crues⁸. El model seleccionat per BIC inclou set variables: MOT_DESMOTIVACIO, MOT_FORCA_MAJOR, EST_AVALUACIO_AC, IA_SUBST_num, T_AVAL, CURS_1R i NOTA_num.

I segona etapa: sobre aquest model s'han provat possibles interaccions: l'única que millora el BIC i resulta significativa és CURS_1R $\times$ MOT_DESMOTIVACIO ($\chi^2 = 8,79, p = 0,003, \Delta BIC = -2,96$), que s'incorpora al model final.

La validació confirma que el model és adequat. Tots els FIV queden entre 1,03 i 1,51, molt per sota del llindar de 5, de manera que no hi ha multicol·linealitat. El test de Hosmer-Lemeshow⁹ no rebutja el bon ajust en cap de les tres particions testades ($p = 0,70; p = 0,57; p = 0,84$), i el *calibration plot* ho confirma visualment (Annex 15). Sis observacions presenten residus de Pearson estandarditzats superiors a 2,5, de les quals dues destaquen especialment (observacions 196 i 316, amb residus de -4,6 i -4,7, vegeu Annex 16). L'anàlisi de sensibilitat sense aquestes sis observacions mostra que set dels vuit coeficients canvien menys d'un 20%, cosa que la literatura considera indicatiu d'estabilitat (Hosmer, Lemeshow, & Sturdivant, 2013). L'excepció és T_AVAL, on l'OR passa de 8,23 a 15,10 (+83%), probablement perquè la categoria d'avaluació única és molt minoritària ($n = 24$) i uns pocs casos extrems mouen l'estimació, però la direcció i la significació es mantenen intactes (per l'anàlisi de sensibilitat vegeu Annex 17).

⁷ L'*odds ratio* mesura quantes vegades augmenten ($OR > 1$) o disminueixen ($OR < 1$) les probabilitats de ser regular per cada unitat d'increment en la variable explicativa, mantenint la resta constant.

⁸ Cal remarcar que la selecció de IA_SUBST_num en lloc del factor IA_SUBSTITUCIO implica l'exclusió de MOT_AUTOGESTIO del model final: Això no vol dir que sigui irrellevant, sinó que en el context explicatiu no aporta prou informació addicional neta.

⁹ El test de Hosmer-Lemeshow avalua la bondat d'ajust del logit dividint les observacions en grups per probabilitat predita i comparant les freqüències observades amb les predites mitjançant un test chi-quadrat; $p > 0,05$ indica bon ajust.

8.2. Model d'equacions estructurals

El model logístic tracta tots els predictors com a directament observables. Les percepcions dels estudiants, en canvi, són constructes latents que no s'observen directament sinó a través de les respostes Likert. El Model d'Equacions estructurals (*Structural equation modeling*: SEM) resol això modelant simultàniament la relació entre els ítems i els constructes latents (model de mesura) i la relació entre aquests constructes i l'assistència (model estructural), incorporant l'error de mesura a l'estimació. A més, permet contrastar si els resultats del logit es mantenen quan es modelen els constructes directament a partir dels ítems originals.

S'han inclòs quatre constructes latents derivats de l'EFA: desmotivació pedagògica (M_TEOR, M_PASSIU, M_AVORR, M_PROF, M_AMICS), força major (M_SALUT, M_FAM, M_TREB), avaluació activa (E_ACT_AC, E_PES_AC, E_PART) i substitució per IA (IA_SUBST, IA_CONF).

S'ha usat l'estimador WLSMV¹⁰, recomanat per a dades ordinals perquè ofereix estimacions menys esbiaixades que MLR¹¹ robust independentment de la mida mostral i el grau de desviació de la normalitat (Li, 2015). Tot i que WLSMV pot sobreestimar les correlacions interfactorials en mostres petites, això no afecta els resultats perquè l'interès del model recau en els efectes sobre l'assistència, no en les relacions entre constructes.

Per facilitar la interpretació dels indicadors, l'Annex 18 inclou una breu descripció dels principals índexs d'ajust, validesa i fiabilitat emprats.

Els índexs d'ajust del CFA confirmen un model de mesura sòlid: $CFI = 0,986$, $TLI = 0,982$, $RMSEA = 0,063[0,050; 0,077]$, $SRMR = 0,066$, tots dins dels llindars acceptables¹². Les càrregues factorials estandarditzades oscil·len entre 0,58 (M_AMICS) i 0,97 (M_FAM), totes per sobre del llindar de 0,50.

L'AVE (*Average Variance Extracted*) supera 0,50 en tots els constructes: DESMOTIVACIO_PEDAG (0,578), FORCA_MAJOR (0,685), AVALUACIO_AC (0,617) i IA_SUBSTITUCIO (0,618), i la fiabilitat composta (omega) oscil·la entre 0,769 i 0,845, per sobre del llindar de 0,70. El model de mesura és, per tant, adequat per procedir a l'estimació estructural.

¹⁰ WLSMV (*Weighted Least Squares Mean and Variance adjusted*) és un estimador de mínims quadrats ponderats dissenyat específicament per a variables ordinals, perquè treballa sobre la matriu de correlacions policòriques.

¹¹ MLR (*Maximum Likelihood Robust*) és l'alternativa basada en màxima versemblança amb correccions de robustesa, però assumeix variables contínues i normalitat aproximada, supòsits que les escales Likert no compleixen.

¹² Criteris d'ajust següent (Hu & Bentler, 1999) CFI i $TLI \geq 0,95$; $RMSEA \leq 0,08$; $SRMR \leq 0,08$.

9. Classificació i predicció

La distinció entre model explicatiu i predictiu no és trivial. En un model explicatiu, la prioritat és la interpretabilitat dels coeficients; en un model predictiu, la prioritat és la capacitat de generalitzar a noves observacions. Això implica decisions metodològiques diferents: cal evitar el sobreajustament, avaluar el model fora de la mostra i calibrar el llindar de classificació en funció del cost dels errors.

La mostra es divideix en *train* i *test* seguint una proporció 80/20 amb partició estratificada per la variable resposta, garantint que la distribució de classes es manté equilibrada en tots dos conjunts. Aquesta partició és la mateixa per a tots els models, cosa imprescindible per comparar-los de forma justa.

En classificació binària, el llindar de 0,5 per defecte no acostuma a ser òptim. En aquest context, classificar erròniament un estudiant irregular com a regular (fals positiu) és més costós que l'error invers, perquè deixa sense intervenció un estudiant que podria necessitar suport, ja que el model diu que cau en el grup de Regulars. Per aquest motiu, el llindar òptim es determina maximitzant la precisió amb una restricció mínima de *recall* de 0,60. En tots els models, el llindar s'estima a partir de la corba *Precision-Recall* sobre probabilitats generades fora de la mostra d'entrenament – via probabilitats *out-of-bag* (OOB) ¹³ en el *Random Forest* o *out-of-fold* (OOF) ¹⁴ en la resta –. El mecanisme específic de cada model es detalla als apartats corresponents. Les mètriques finals es reporten sempre sobre el conjunt de test, que no ha participat en cap fase de construcció ni calibratge.

¹³ *Out-of-Bag* (OOB): En un *Random Forest*, són les observacions que no han estat seleccionades en la mostra bootstrap utilitzada per entrenar un arbre concret.

¹⁴ *Out-of-Fold* (OOF): Són les prediccions obtingudes sobre les observacions que queden fora del conjunt d'entrenament en cada iteració de la validació creuada.

9.1. Regressió logística

L'objectiu d'aquest model és diferent al del logit explicatiu: aquí no interessa la interpretabilitat dels coeficients sinó la capacitat de classificar correctament estudiants en risc d'absentisme sobre dades no vistes. S'opta de nou per la regressió logística per coherència metodològica amb l'anàlisi explicativa i perquè, amb una mostra de 274 observacions al *train*, models més complexos com el *Random Forest* requereixen una validació més exigent per garantir que els resultats generalitzen bé.

La selecció de variables s'ha fet per *backward* AIC – enlloc del BIC usat al model explicatiu –, perquè l'AIC penalitza menys la complexitat i tendeix a retenir més variables, cosa que és adequada quan l'objectiu és predictiu. El model complet de partida inclou tots els factors de l'EFA, les variables Likert individuals d'IA i totes les variables personals i acadèmiques rellevants. El procés d'eliminació *backward* ha resultat en un model amb 9 predictors i $AIC = 299,47$: MOT_DESMOTIVACIO, MOT_FORCA_MAJOR, EST_AVALUACIO_AC, T_AVAL, CURS_1R, DOBLE_GRAU_EST, EDAT, NOTA_num i IA_SUBST_num.

S'ha provat també incorporar la interacció $MOT_DESMOTIVACIO \times CURS_1R$, que el *backward* AIC reté i millora l'AIC fins a 293,55. Tot i això, al conjunt de test el *recall* cau a 0,463, per sota de la restricció mínima de 0,60 establerta per al conjunt de models predictius, també cau el F1 i el llindar de classificació es col·loca per sobre del 0,7 convertint-se en un model massa conservador. Per aquest motiu, el model final és el model sense interacció, que compleix la restricció (*recall* = 0,561) i obté una F1 superior (0,697 vs 0,623). Que la interacció sigui rellevant explicativament però no millori la predicció és en si mateix un resultat: captura un patró real a les dades però que no generalitza prou bé a noves observacions.

El llindar de classificació s'ha estimat a partir de la corba *Precision-Recall* sobre probabilitats OOF, amb la restricció $recall \geq 0,60$, resultant en un llindar de 0,6617. La validació s'ha fet amb *repeated 5×10-fold CV* (50 iteracions), que proporciona estimacions estables de les mètriques sobre el *train*.

Capítol IV: Resultats


1. Resultats descriptius

1.1. Resultats acadèmics: nota i tipus d'avaluació

En aquest apartat s'observen dues relacions clares, que ja se sospiten, però que les dades confirmen.

- **L'efecte de l'avaluació continuada:** en l'avaluació única, la irregularitat és gairebé total (88%), mentre que en l'avaluació continuada el percentatge d'irregulars baixa fins al 40% (Gràfic 3). Això suggereix que l'avaluació continuada incentiva un seguiment més constant de l'assignatura, mentre que l'avaluació única permet a l'estudiant gestionar l'aprenentatge de manera més autònoma, sense necessitat d'assistir-hi regularment.


Gràfic 3: Assistència per tipus d'avaluació



Font: elaboració pròpia

- **Relació entre nota i assistència:** existeix un gradient clar i monòton entre rendiment acadèmic i assistència (Gràfic 4). En el grup de notes més baixes (5-5,9), el percentatge d'irregulars puja fins al 59%, mentre que entre els estudiants excel·lents (nota ≥9) baixa fins al 22%. L'assistència, doncs, no sembla només una qüestió d'hàbit, sinó que està lligada al rendiment acadèmic.

Gràfic 4: Assistència segons la nota d'expedient




Font: elaboració pròpia

1.2. El paper del treball

El gràfic de percentatge d'assistència per dedicació laboral (Gràfic 5) mostra una diferència clara entre els estudiants que treballen i els que no. Tot i que la mediana dels estudiants que no treballen es manté alta, la dispersió augmenta considerablement en els que treballen, sobretot a temps parcial. El cost d'oportunitat de venir a la facultat és, simplement, molt més alt per a ells.


Gràfic 5: Box-plot de dedicació laboral per percentatge d'assistència



Font: elaboració pròpia

1.3. Motius per no anar a classe i estratègies per anar-hi


Gràfic 6: Diferència de mitjanes en els motius de no assistència entre els dos grups



Font: elaboració pròpia

Mirant les diferències de mitjana per grup (Gràfic 6), els motius més importants per no anar a classe dels estudiants irregulars són la percepció que les classes són massa teòriques (M_TEOR), la preferència per l'estudi autònom (M_AUTON), l'avorriment (M_AVORR) i la necessitat d'estudiar per a altres exàmens (M_EXAM), amb una diferència màxima de 0,85 punts. En canvi, el motiu principal pel qual l'alumnat regular admet faltar a classe és un problema puntual i no dependent d'ell mateix: problemes de salut (M_SALUT), amb una diferència de 0,90 punts a favor dels regulars o motius familiars (M_FAM).

Gràfic 7: Diferència de mitjanes en les estratègies per anar a classe




Font: elaboració pròpia

Pel que fa a les estratègies per anar a classe (Gràfic 7), les diferències entre grups són clarament més petites que en el bloc de motius. La més rellevant és l'horari de classe (E_HORA): els irregulars ho valoren més a l'hora d'assistir-hi (diferència de 0,51 punts), mentre que els regulars donen més importància a que hi hagi descans (E_DESC, diferència de 0,37 punts). Aquesta menor diferència, comparada amb el bloc de motius, suggereix que tothom té clar a quin tipus de classe prefereix anar, però que els irregulars, malgrat saber-ho, igualment no hi assisteixen.

1.4. El paper de la Intel·ligència Artificial

Gràfic 8: Diferència de mitjanes en l'ús de la IA




Font: elaboració pròpia

Com a novetat conceptual d'aquest treball, s'ha explorat si l'ús de la IA diferencia els estudiants que van a classe regularment dels que no hi van. Les dades ho confirmen: dues variables ho mostren clarament al Gràfic 8 (Diferència de mitjanes en l'ús de la IA), IA_SUBST (diferència d'1,34 punts) i IA_ATENC (diferència de 0,84 punts), que mesuren respectivament si l'alumnat creu que la IA redueix la necessitat d'anar a classe i si deixa de prestar atenció confiant en que la IA ja els ho explicarà. En tots dos casos, els estudiants irregulars puntuen significativament més alt. Això suggereix que la IA ja no és només una eina de suport, sinó que per a una part de l'alumnat és una alternativa viable a l'explicació del professor, fins al punt que aquesta és la diferència més gran trobada entre els dos grups d'estudi.

2. Resultats exploratoris

2.1. Variables categòriques

Gràfic 9: Associacions de les variables categòriques amb l'assistència (*V* de Cramér)



Font: elaboració pròpia

Les variables amb més poder explicatiu es presenten al Gràfic 9. El grau ($V = 0,264$) i el tipus d'avaluació ($V = 0,245$) mostren les associacions més intenses, cosa que suggereix que l'absentisme no és únicament una decisió individual sinó que està condicionada per l'entorn acadèmic. La nota d'expedient ($V = 0,232$) apunta en la mateixa direcció: els estudiants amb millor rendiment tendeixen a ser més regulars, tot i que la causalitat podria operar en els dos sentits.

Pel que fa al curs ($V = 0,214$), els estudiants de primer curs ($CURS_1R$, $V = 0,176$) presenten una assistència significativament més regular. Això pot reflectir tant una major motivació inicial com un accés més limitat a estratègies alternatives — apunts externs o informació de companys de cursos superiors — que els cursos superiors ja han incorporat.


Tot i que treballar a temps parcial o complet ($V = 0,118$) és estadísticament significatiu, la intensitat de l'associació és baixa, cosa que indica que la dedicació laboral no és el factor principal de l'absentisme. El gènere i la sobrecàrrega d'assignatures no presenten cap relació estadística amb l'assistència, com ja es sospitava a la descriptiva.

2.2. Variables numèriques

L'edat ($r = -0,096$, $p = 0,124$) i la càrrega lectiva ($r = -0,060$, $p = 0,336$) no mostren cap relació significativa amb el grup d'assistència. El temps de desplaçament presenta una tendència positiva ($r = 0,112$) però no assoleix significació estadística ($p = 0,076$). Aquests resultats suggereixen que l'absentisme és un fenomen que no s'explica per variables logístiques, sociodemogràfiques o de càrrega lectiva.

2.3. Variables de percepció

Gràfic 10: Correlació rank-biserial de les variables Likert (només variables significatives)¹⁶



Font: elaboració pròpia

La percepció de la IA com a eina de substitució de la classe és el factor amb la correlació rang-biserial més elevada ($r = -0,412$), indicant que els alumnes que consideren que la IA els pot aportar el mateix que el professor, presenten una probabilitat notablement més alta de pertànyer al grup irregular. La percepció d'autonomia ($M_AUTON, r = -0,367$) mostra una associació similar: els estudiants irregulars puntuen significativament més alt en la preferència per aprendre de manera autònoma fora de l'aula.

Quant a la metodologia docent, les variables relacionades amb la percepció de classes massa teòriques ($M_TEOR: r = -0,329$), la insatisfacció amb el professor ($M_PROF: r = -0,310$) i el rol passiu de l'alumnat a l'aula ($M_PASSIU: r = -0,263$) presenten diferències significatives entre grups, confirmant que el format de la classe és un factor associat a l'absentisme.

En sentit contrari, M_SALUT ($r = 0,265$) i M_FAM ($r = 0,208$) són els únics motius on els estudiants regulars puntuen més alt que els irregulars. Això confirma el que ja s'apuntava a la descriptiva: quan un estudiant regular no va a classe, és gairebé sempre per una causa externa i puntual, no per una decisió pròpia.

Un resultat destacable és que pràcticament cap de les estratègies docents proposades mostra diferències significatives entre grups. De les tretze variables analitzades, només E_HORA

¹⁶ Els que són positius indiquen que el valor és més elevat en els regulars que en els irregulars.

(preferència per horaris favorables, $r = -0,166$) i E_DINAM (preferència per classes més dinàmiques, $r = 0,128$) assolixen significació estadística, i ambdues amb magnituds baixes.


Val a dir que E_DINAM és l'única variable d'estratègies on els estudiants regulars puntuen més alt que els irregulars, suggerint que el dinamisme de la classe pot ser un factor que afavoreix l'assistència. La resta d'estratègies no presenten cap diferència entre grups.

3. Anàlisi Factorial Exploratòria

3.1. Bloc 1 — Motius de no assistència

Aquest bloc consta de 3 factors i explica un 56,2% de la variància.

Gràfic 11: Càrregues factorials – Motius de no assistència (càrregues > 30, negreta > 50)



Font: elaboració pròpia

El primer factor, MOT_DESMOTIVACIO, agrupa els motius relacionats amb la dinàmica de l'aula: classes massa teòriques ($\lambda = 0,85$), paper de l'alumnat passiu ($\lambda = 0,87$), classes avorrides ($\lambda = 0,70$), manca de connexió amb la forma d'explicar del professor ($\lambda = 0,56$) i la influència dels amics que no van a classe ($\lambda = 0,49$). La correlació de Spearman amb l'assistència és de $\rho = -0,357$ ($p < 0,001$), de manera que els alumnes irregulars puntuen més alt en desmotivació pedagògica que els regulars.

El segon factor, MOT_AUTOGESTIO, captura la percepció que anar a classe no aporta valor addicional respecte d'estudiar per compte propi: preferència per l'aprenentatge autònom ($\lambda = 0,83$), material al Campus Virtual suficient ($\lambda = 0,74$), percepció que la classe no és útil ($\lambda = 0,61$) i estratègies com no anar quan hi ha un examen proper ($\lambda = 0,37$) o quan es repeteix l'assignatura ($\lambda = 0,34$). És el factor amb la correlació negativa més forta ($\rho = -0,378$, $p < 0,001$), indicant que els alumnes irregulars es perceben molt més capaços d'autogestionar el seu aprenentatge sense assistir.

El tercer factor, MOT_FORCA_MAJOR, recull els motius externs a la universitat: obligacions familiars ($\lambda = 0,96$), problemes de salut ($\lambda = 0,84$) i feina ($\lambda = 0,66$). La correlació amb l'assistència és positiva ($\rho = 0,187$, $p < 0,001$) i era el que s'esperava segons el que s'ha comentat en apartats anteriors.

3.2. Bloc 2 — Estratègies docents

Aquest segon bloc conté 4 factors i explica un 67,4% de variància.

Cap dels quatre factors del bloc d'estratègies assoleix significació estadística en la correlació de Spearman amb l'assistència (vegeu Annex 14). Això confirma el que ja apuntava l'EDA: les preferències pedagògiques no discriminen entre assistents i no assistents, i els factors s'interpreten com a dimensions de preferència, no com a predictors d'absentisme.

EST_QUALITAT_DOC agrupa tot allò relacionat amb les habilitats pedagògiques del professor i el clima de l'aula: qualitat de l'explicació (E_EXPL, $\lambda = 0,985$), ritme de la classe (E_RITME, $\lambda = 0,799$), bon clima (E_CLIMA, $\lambda = 0,782$) i proximitat del professor (E_PROP, $\lambda = 0,588$).

EST_AVALUACIO_AC recull les estratègies que impliquen un rol actiu de l'alumne: activitats d'aula (E_ACT_AC, $\lambda = 0,910$), pes de l'avaluació continuada (E_PES_AC, $\lambda = 0,720$), participació (E_PART, $\lambda = 0,627$) i dinamisme (E_DINAM, $\lambda = 0,385$).


EST_TEMPS_CLASSE captura estratègies purament temporals: descansos (E_DESC, $\lambda = 0,813$) i classes més curtes (E_CURT, $\lambda = 0,665$). Finalment, EST_GRUPS_REDUITS queda pràcticament aïllat amb una sola variable dominant (E_REDU, $\lambda=0,863$).

El gràfic de les càrregues factorials es pot veure a l'Annex 13.

3.3. Bloc 3 — Ús de la IA

L'últim bloc queda amb 2 factors i explica un 67,8% de la variància.

Gràfic 12: Càrregues factorials – Ús de la IA (càrregues > 30, negreta > 50)



Font: elaboració pròpia

IA_EINA_ESTUDI recull l'ús actiu de la IA (IA_HABIT, $\lambda = 0,88$) per comprendre continguts (IA_COMPR, $\lambda = 0,90$), processar documents (IA_PDFS, $\lambda = 0,76$) i millorar el rendiment (IA_REND, $\lambda = 0,74$). La correlació amb l'assistència és negativa i significativa ($\rho = -0,279, p < 0,001$)


IA_SUBSTITUCIO recull el costat més problemàtic de l'ús de la IA: l'alumne deixa d'atendre a classe perquè confia que la IA li proporcionarà tot el que necessita (IA_ATENC, $\lambda = 0,99$), confia en les respostes que li dona (IA_CONF, $\lambda = 0,69$), i veu les seves explicacions com a substitutes d'anar a classe (IA_SUBST, $\lambda = 0,59$). La correlació amb l'assistència és també negativa i significativa ($\rho = -0,271, p < 0,001$).

Les dues correlacions són gairebé idèntiques en magnitud, de manera que no és possible establir cap jerarquia clara entre els dos factors i dir quin pot tenir més relació. Això suggereix que no és només l'ús substitutiu de la IA el que s'associa amb l'absentisme, sinó l'ús intensiu en general.

3.4. Puntuacions factorials i ús als models predictius

Un cop definit el model definitiu, s'han calculat puntuacions factorials¹⁷ per regressió per a cada observació (Gràfic 13). Aquestes puntuacions substitueixen el conjunt de variables originals als models econòmics posteriors, resolent el problema de multicolinealitat i reduint la dimensió de l'espai de predictors de forma interpretable.

Gràfic 13: Correlació entre els factors i l'assistència



Font: elaboració pròpia

¹⁷ Les puntuacions factorials són com una "nota" en cada factor que resumeix la posició de l'alumne en aquell constructe latent.

4. Anàlisi inferencial i causal

4.1. Model logístic

Cal recordar que el model final utilitza IA_SUBST_num en format Likert individual i no el factor IA_SUBSTITUCIO, ja que, com s'ha explicat a l'apartat 8.1, el model amb la variable crua obté un BIC inferior.

Taula 2: Odds ratios i AME del model final¹⁸

Variable	OR	Ic (95%)	AME
MOT_DESMOTIVACIO	0,472***	[0,331; 0,674]	-8,6 pp
IA_SUBST_num	0,687***	[0,580; 0,813]	-6,3 pp
MOT_FORCA_MAJOR	1,428**	[1,092; 1,868]	+5,9 pp
EST_AVALUACIO_AC	1,542**	[1,161; 2,047]	+7,2 pp
NOTA_num	1,624**	[1,169; 2,255]	+8,1 pp
CURS_1R	2,679**	[1,376; 5,220]	+18,7 pp
T_AVALContinuada	8,232**	[2,138; 31,700]	+35,5 pp
MOT_DESMOTIVACIO:CURS_1R	2,792**	[1,407; 5,540]	-

Font: elaboració pròpia

Desmotivació pedagògica (AME = -8,6 pp). Cada unitat addicional en el factor de desmotivació pedagògica¹⁹ redueix la probabilitat de tenir assistència regular en 8,6 punts percentuals. És el mecanisme actitudinal principal de l'absentisme que el model detecta.

Ús de la IA com a substitut d'anar a classe (AME = -6,3 pp). Cada punt addicional a IA_SUBST redueix la probabilitat de ser regular en 6,3 punts percentuals. De l'extrem inferior al superior de l'escala, l'efecte acumulat supera els 30 punts percentuals. Això confirma que la IA, per a una part de l'alumnat, ja no és només una eina d'estudi sinó una alternativa real a la classe.

Força major (AME = +5,9 pp). La relació positiva amb l'assistència regular reforça la idea que quan un estudiant regular falta, és per motius externs i involuntaris, no per una decisió pròpia.

¹⁸ *** $p < 0,001$; ** $p < 0,01$; * $p < 0,05$. AME = efecte marginal mitjà, expressat en canvi de probabilitat fent la mitjana sobre totes les observacions de la mostra.

¹⁹ Recordem que el factor de la desmotivació pedagògica recull la percepció de les classes com a avorrides, massa teòriques o amb un paper passiu de l'estudiant

Paper actiu de l'alumne (AME = +7,2 pp). Les dinàmiques de classe que impliquen un rol actiu de l'estudiant — activitats, participació, avaluació continuada amb pes a la nota — augmenten la probabilitat de ser regular en 7,2 pp.


Nota d'expedient (AME = +8,1 pp) i primer curs (AME = +18,7 pp) reforcen un patró coherent: els estudiants amb millor rendiment i els de primer any són els més regulars, cosa que apunta tant a una major motivació com a una percepció més alta del valor de la classe.

Tipus d'avaluació (AME = +35,5 pp). Seguir l'avaluació continuada incrementa la probabilitat de ser regular en 35 punts percentuals. Quan l'assistència té conseqüències directes en la nota, l'alumnat assisteix.

Interacció desmotivació × primer curs (OR = 2,79). La desmotivació es tradueix menys en absentisme als estudiants de primer que als de cursos superiors, probablement perquè aquests últims ja han incorporat estratègies alternatives per substituir la classe (

Gràfic 14).

Gràfic 14: Interacció entre MOT_DESMOTIVACIO i CURS_1R



Font: elaboració pròpia

Els resultats del model logístic apunten a un patró clar: l'absentisme s'explica sobretot per percepcions i decisions de l'estudiant envers la classe. El factor amb més pes és l'avaluació continuada. Altres dos factors que redueixen l'assistència de forma important – la desmotivació pedagògica i la percepció de la IA com a substitut de la classe – són actitudinals. Reduir l'absentisme, per tant, implica recuperar el valor percebut de la classe presencial, especialment als cursos superiors.

4.2. Resultats del model estructural

S'han estimat dos models alternatius: el Model A, sense cap ruta de mediació, i el Model B, que afegeix la ruta DESMOTIVACIO_PEDAG → AVALUACIO_AC → P_ASSIST per contrastar si la desmotivació actua indirectament sobre l'assistència a través de la percepció de l'avaluació activa. El test de diferència de chi-quadrat no resulta significatiu ($\Delta\chi^2 = 3,70$; $\Delta df = 2$; $p = 0,158$), de manera que el Model A és el model final per ser estadísticament equivalent i més parsimoniós.

Taula 3: Coeficients estructurals del model SEM (variable dependent: percentatge d'assistència)

Variable	β est.	Efecte (pp) ²⁰	IC 95%	p-valor
T_AVAL_num	0,348	+39,7	[28,6; 50,7]	< 0,001
DESMOTIVACIO_PEDAG	-0,221	-6,4	[-9,8; -3,1]	< 0,001
AVALUACIO_AC	0,202	+5,9	[3,1; 8,6]	< 0,001
NOTA_num	0,178	+5,9	[2,8; 9,1]	< 0,001
FORCA_MAJOR	0,156	+4,6	[1,9; 7,2]	0,001
CURS_1R_d	0,154	+10,6	[2,8; 18,4]	0,008
TREB_INTENS	-0,131	-7,8	[-13,5; -2,1]	0,007
DOBLE_GRAU_EST	0,085	+5,3	[-1,9; 12,5]	0,151
IA_SUBSTITUCIO	-0,058	-1,7	[-4,8; 1,4]	0,283

Font: elaboració pròpia. Variable dependent: P_ASSIST (percentatge d'assistència, 0–100).

El predictor amb efecte més gran és el tipus d'avaluació (T_AVAL, $\beta = 0,35$): els estudiants que segueixen avaluació continuada presenten un percentatge d'assistència 40 punts percentuals superior als que segueixen avaluació única. La desmotivació pedagògica (DESMOTIVACIO_PEDAG, $\beta = -0,22$) confirma que els estudiants que perceben les classes com a avorrides o poc participatives assisteixen menys (-6,5 pp). El constructe AVALUACIO_AC ($\beta = 0,20$) captura fins a quin punt percep que les dinàmiques d'avaluació activa a l'aula — activitats, participació, pes a la nota — l'incentiven a assistir. Quan aquesta percepció és alta, l'assistència augmenta +5,6 pp. La nota ($\beta = 0,18$), ser de primer curs ($\beta = 0,15$) i faltar a classe per força major ($\beta = 0,116$) mostren efectes positius i significatius.

²⁰ Efecte (pp) és el coeficient no estandarditzat, És l'efecte en les unitats originals de la variable P_ASSIST (0-100), mentre que l'estandarditzat canvia les variables a una escala comuna, serveix per valorar la importància relativa.

Treballar intensament (TREB_INTENS, $\beta = -0,13$) també resulta significatiu: els estudiants que treballen a temps parcial o complet assisteixen, de mitjana, 7,8 pp menys que els que no treballen.

Veure la IA com a substituta de les classes ($\beta = -0,06, p = 0,28$) i estudiar un doble grau o el grau d'Estadística ($\beta = 0,09, p = 0,15$), no és significatiu. Tot i que en el últim cas el signe positiu suggereix una tendència cap a una assistència lleugerament més regular en aquests perfils.

4.3. Comparació i síntesi dels models

El logit i el SEM, tot i partir d'enfocaments ben diferents – variable dependent binària vs. contínua, puntuacions factorials vs. constructes latents estimats simultàniament –, coincideixen en direcció per a totes les variables significatives (Taula 4). Aquesta convergència reforça la robustesa de les conclusions.

Taula 4: Comparació SEM vs. Logit – direccions i consistència entre ambdós models

Concepte	Variable logit	Variable SEM	Dir. Logit	Dir. SEM	Consistent
Tipus d'avaluació	T_AVAL	T_AVAL_num	+	+	Sí
Desmotivació pedagògica	MOT_DESMOTIVACIO	DESMOTIVACIO_PEDAG	-	-	Sí
Avaluació activa	EST_AVALUACIO_AC	AVALUACIO_AC	+	+	Sí
Nota d'expedient	NOTA_num	NOTA_num	+	+	Sí
Nota d'expedient	CURS_1R	CURS_1R_d	+	+	Sí
Força major	MOT_FORCA_MAJOR	FORCA_MAJOR	+	+	Sí
Substitució per IA	IA_SUBST_num	IA_SUBSTITUCIO	-	n.s.	Parcial
Treball intens	TREB_INTENS	TREB_INTENS	n.s.	-	Parcial

Font: elaboració pròpia.

El tipus d'avaluació és el predictor més potent en tots dos models: l'estructura d'avaluació és el mecanisme que més determina si un estudiant assisteix. La desmotivació pedagògica és el segon factor en magnitud i l'únic amb efecte negatiu consistent. La nota, el curs i la percepció de l'avaluació activa mostren efectes positius i significatius en ambdós models, dibuixant el perfil de l'estudiant regular: bon expedient, de primer curs i que percep l'avaluació activa com un incentiu real.

Hi ha dues discrepàncies parcials. La primera és IA_SUBSTITUCIO, no significativa al SEM: el SEM agrega IA_SUBST i IA_CONF en un constructe latent, cosa que dilueix el senyal específic que feia significativa IA_SUBST en solitari al logit. La segona és TREB_INTENS, que el SEM detecta com a significativa (-7,8 pp) però que el *backward* BIC del logit va eliminar per no aportar informació addicional neta un cop controlades la resta de variables. Cal tenir en compte que la comparació entre models és qualitativa – en termes de direcció i significació –, ja que variables

com MOT_DESMOTIVACIO al logit i DESMOTIVACIO_PEDAG al SEM mesuren el mateix concepte teòric però no són tècnicament idèntiques.

Cal destacar també el que els models no troben: variables com el gènere, el grau cursat o el temps de desplaçament no resulten significatives en cap dels dos models, cosa que indica que l'absentisme no és un fenomen que s'expliqui per característiques sociodemogràfiques o logístiques, sinó per percepcions i decisions de l'estudiant envers la classe.

Els resultats d'aquest bloc es basen en relacions estadístiques sobre la mostra completa. El bloc predictiu que segueix té un objectiu diferent: identificar estudiants en risc d'absentisme i verificar, mitjançant *SHAP values*, si les mateixes variables continuen sent rellevants quan el criteri és la capacitat de generalització.

5. Classificació i predicció

5.1. Model logístic


Taula 5: Coeficients del model logístic predictiu

Variable	Coeficient	Error estàndard	z	p-valor
Intercept	-1,253	0,922	-1,36	0,174
MOT_DESMOTIVACIO	-0,533	0,184	-2,89	0,004 **
MOT_FORCA_MAJOR	0,305	0,150	2,04	0,041 *
EST_AVALUACIO_AC	0,616	0,171	3,60	< 0,001 ***
IA_SUBST_num	-0,376	0,102	-3,67	< 0,001 ***
T_AVALContinuada	1,763	0,725	2,43	0,015 *
CURS_1R	1,001	0,368	2,72	0,006 **
DOBLE_GRAU_EST	0,512	0,327	1,56	0,118
EDAT	-0,039	0,016	-2,37	0,018 *
NOTA_num	0,570	0,182	3,12	0,002 **

Font: elaboració pròpia

El model s'estima sobre el conjunt d'entrenament (274 observacions). Tots els coeficients són significatius al nivell del 5%, excepte DOBLE_GRAU_EST ($p = 0,12$), que el *backward* AIC reté perquè la seva eliminació empitjora el criteri d'informació tot i no assolir el llindar de significació clàssic²¹. La reducció de deviança respecte al model nul és de 376,10 a 279,47, una reducció del 25,7%.

Gràfic 15: Comparació de mètriques entre train i test del logit



Font: elaboració pròpia

²¹ En un model predictiu, l'AIC no exigeix significació estadística sinó que avalua si la variable aporta prou informació per compensar el cost d'afegir un paràmetre.

L'AUC al test (0,833) és superior a la mitjana de validació creuada (0,793), cosa que descarta sobreajustament en la capacitat discriminativa global. La precisió al test és del 92,0%: dels 25 estudiants classificats com a regulars, només 2 eren en realitat irregulars. El model quasi no comet l'error que es volia evitar. La contrapartida és un *recall* de 0,561: dels 41 estudiants realment regulars, el model en detecta 23 com a tals i classifica els 18 restants com a irregulars per excés de precaució.

El *recall* al test (0,561) no assoleix el mínim de 0,60 establert durant el calibratge. Això és una limitació de la mida mostral: el llindar s'ha estimat sobre 274 observacions i la seva transferència a un test de 68 no és perfecta. Aquesta limitació motiva la incorporació del *Random Forest*: un algorisme basat en arbres pot capturar relacions no lineals i interaccions sense necessitat d'especificar-les explícitament, cosa que pot traduir-se en un *recall* més alt sense sacrificar la precisió. Per a la corba ROC, la corba *Precision-Recall* i la matriu de confusió vegeu de l'Annex 20 a l'Annex 22.

Capítol VI: Annexos

Taules: mateixa lletra que la resta del document, o 1-2 punts per sota si les seves dimensions ho requereixen. Han d'anar centrades i dur un títol també centrat a la part superior. Es numeraran d'acord amb el capítol en què s'incloguin. Per exemple, la primera taula del capítol 2 serà la 2.1., la segona la 2.2., etc. Es pot triar lliurement el seu estil, sempre procurant que el seu aspecte sigui adequat a un document de caràcter científic. Gràfics: mateixes indicacions que per a les taules.

1. Formulari i codificació de dades

Annex 1: Formulari enviat a l'alumnat de la FEE de graus

L'enquesta original es pot consultar en el següent enllaç: <https://forms.cloud.microsoft/e/Vyk83X36S4> o mitjançant el següent codi QR



Benvolgudes i benvolguts estudiants de grau de la Facultat d'Economia i Empresa,

Us volem demanar de respondre una petita enquesta per tal de conèixer la vostra opinió sobre com podem millorar la docència i fer-la més valuosa, interessant i atractiva per a vosaltres. Només seran cinc minuts i podreu expressar la vostra opinió lliurement.

La participació és totalment voluntària, però us agrairem molt la vostra ajuda.

Totes les respostes són completament anònimes i les dades es tractaran exclusivament de forma agregada. Per tant, us agrairíem molt que ens donéssiu la vostra opinió sincera. El vostre feedback és clau per ajudar-nos a adaptar el curs a les vostres necessitats. Moltes gràcies!

(El responsable del tractament de les dades és la Secretaria General de la Universitat de Barcelona. Les dades seran tractades amb la finalitat de gestionar l'enquesta. Atesa la naturalesa anònima de la consulta, no es recullen dades que permetin identificar els participants. Per aquest motiu, de conformitat amb l'article 26 del RGPD, s'informa que no serà possible exercir els drets d'accés, rectificació, supressió o portabilitat, ja que la Universitat no pot identificar a quina persona correspon cada resposta.

Secció 1: Dades acadèmiques

1. Quin grau estudies?
 - ADE
 - Economia
 - Empresa Internacional
 - Estadística
 - Sociologia
 - Doble grau: Economia + Estadística
 - Doble Grau ADE + Dret
 - Doble Grau: ADE + Matemàtiques
 - Doble Grau: ADE + Química
 - Doble Grau: ADE + Sociologia
2. Quin curs estàs fent aquest any?
 - 1r
 - 2n
 - 3r
 - 4t
 - 5è
 - A partir de 6è
3. A quantes assignatures t'has matriculat aquest curs?
Numèrica entera [1 - 17]
4. Quina és la teva nota mitjana d'expedient? (Sobre 10)
 - 5-5,9
 - 6-6,9
 - 7-7,9
 - 8-8,9
 - ≥ 9
5. Generalment quin tipus d'avaluació segueixes?
 - Única
 - Continuada
6. A quin percentatge de classes assisteixes?
Numèrica entre [0 - 100]

Secció 2: Situació personal

7. Quin és el teu gènere?
 - Dona
 - Home
 - No binari
 - Prefereixo no respondre
8. Quina edat tens?
Numèrica entera [≥ 17]
9. Quina ha estat la teva dedicació als estudis durant aquest curs?
 - Estudio a temps complet (només estudio).
 - Estudio però també treballo ocasionalment
 - Estudio i treball a temps parcial (menys de 35 hores setmanals)
 - Treball a temps complet (més de 35 hores setmanals) i estudio
10. Quants minuts triges en desplaçar-te fins a la facultat?
Numèrica

Secció 3: La teva opinió sobre les classes i la teva assistència

11. Valora la importància que tenen per a tu els següents motius per NO assistir a classe: (1: Gens d'acord a 5: Totalment d'acord)
- Perquè treballo
 - Perquè tinc responsabilitats familiars
 - Perquè tinc problemes de salut
 - Perquè visc lluny i trigo molt a venir
 - Prefereixo estudiar pel meu compte
 - El material al Campus Virtual és suficient
 - Quan tinc una prova deixo d'anar a classe
 - Quan anar a classe no ajuda a aprovar
 - Quan les classes són avorrides
 - Classes magistrals / paper passiu
 - Quan les classes són massa teòriques
 - No m'agrada com explica el/la professor/a
 - Quan repeteixo no cal anar a classe
 - Prefereixo anar a una acadèmia
 - Quan els meus amics/gues tampoc hi van
12. Quines estratègies t'animen a assistir a classe? (1: Gens d'acord a 6: Totalment d'acord)
- Aval. continuada té més pes a la nota
 - Quan hi participo (treballs, presentacions)
 - Canvi d'activitat (problemes, casos)
 - Quan la classe es fa en grups reduïts
 - Quan les classes són més curtes
 - Quan es fa descans
 - Bon clima i comunicació
 - Quan el/la professor/a explica molt bé
 - El ritme de les explicacions es segueix bé
 - Quan es fan activitats d'AC a classe
 - Professor/a proper a l'alumnat
 - Quan l'horari em va bé
 - L'assistència té pes a la nota
13. Vols explicar breument una experiència d'una assignatura que t'hagi interessat/agradat especialment i el motiu?
14. Vols explicar breument una experiència d'una assignatura que NO t'hagi interessat/agradat assistir a classe i el motiu?
15. Vols afegir alguna proposta que et motivaria a assistir a classe?

Secció 4: Ús de la Intel·ligència Artificial

16. Indica en quina mesura estàs d'acord amb les següents afirmacions. (1: Gens d'acord a 6: Totalment d'acord)
- Utilitzo eines d'IA de manera habitual
 - Ajuda a entendre continguts no entesos
 - La IA redueix la necessitat d'anar a classe
 - Em fio de la IA sense contrastar
 - Deixo de prestar atenció (IA ho explicarà)
 - Preocupació per l'aprenentatge real
 - L'ús de la IA millora el rendiment
 - Pujo material propi per contextualitzar

SECCIÓ 1: DADES ACADÈMIQUES			
Número pregunta	ID variable	Codificació / Tipus de Variable	Tipus de variable
1	GRAU	• 1 = ADE • 2 = Economia • 3 = Empresa Internacional • 4 Estadística • 5 = Sociologia • 6 = Doble grau: Economia + Estadística • 7 = Doble Grau ADE + Dret • 8 = Doble Grau: ADE + Matemàtiques • 9 = Doble Grau: ADE + Química • 10 = Doble Grau: ADE + Sociologia	Categòrica (Nominal)
2	CURS	• 1 = 1r • 2 = 2n • 3= 3r • 4 = 4t • 5 = 5è • 6 = A partir de 6è	Categòrica (Ordinal)
3	N_ASSIG	Numèrica entera [1 - 17]	Numèrica (Discreta)
4	NOTA	• 1= [5-5.9] • 2 = [6-6.9] • 3 = [7-7.9] • 4 = [8-8.9] • 5: [$\geq$ 9]	Categòrica (Ordinal)
5	T_AVAL	• 0 = Única • 1 = Continuada	Categòrica (Nominal)
6	P_ASSIST	Numèrica percentual [0 - 100]	Numèrica
SECCIÓ 2: SITUACIÓ PERSONAL			

Número pregunta	ID variable	Codificació / Tipus de Variable	Tipus de variable
7	GENERE	• 1 = Dona • 2 = Home • 3 = No binari • 4 = Prefereixo no respondre	Categòrica (Nominal)
8	EDAT	Numèrica entera [≥ 17]	Numèrica (Discreta)
9	DEDIC	• 1 = E. Complet • 2 = T. Ocasional • 3 = T. Parcial • 4 = T. Complet	Categòrica (Nominal)
10	DESPL	Numèrica (minuts)	

SECCIÓ 3: LA TEVA OPINIÓ SOBRE LES CLASSES I LA TEVA ASSISTÈNCIA


Número pregunta	ID variable	Codificació / Tipus de Variable	Tipus de variable
11 (Motius de no assistència)	M_TREB M_AVORR M_FAM M_PASSIU M_SALUT M_TEOR M_DIST M_PROF M_AUTON M_REPET M_CV M_ACAD M_EXAM M_AMICS M_UTIL	1 = Gens d'acord 5 = Totalment d'acord	Escala de Likert
12 (Estratègies d'assistència)	E_PES_AC E_EXPL E_PART E_RITME E_DINAM E_ACT_AC E_REDU E_PROP E_CURT E_HORA E_DESC E_PES_AS E_CLIMA	1 = Gens d'acord 6 = Totalment d'acord	Escala de Likert
12	EXP_POS	Text lliure	Qualitativa (Text)
13	EXP_NEG	Text lliure	Qualitativa (Text)
14	PROP_MOT	Text lliure	Qualitativa (Text)

SECCIÓ 4: ÚS DE LA IA

Número pregunta	ID variable	Codificació / Tipus de Variable	Tipus de variable
15	IA_HABIT		
	IA_COMPR		
	IA_SUBST		
	IA_CONF	1 = Gens d'acord	Escala de Likert
	IA_ATENC	6 = Totalment d'acord	
	IA_PREOC		
	IA_REND		
	IA_PDFS		


2. Preprocessament

Annex 3: Box-plot del temps de desplaçament




3. Descriptiva


Annex 4: Box-plot de l'edat segons el grup d'assistència



Annex 5: Distribució de l'assistència per gènere




Annex 6: Percentatge d'alumnes que assisteixen regularment per grau i curs (cel·les amb n>5)



4. EDA


Annex 7: Associació (*V* de Cramér) entre totes les variables categòriques. S'exclouen les parelles redundants per construcció (variables derivades).



Annex 8: Validació Monte-Carlo


El gràfic de punts que compara els p-valors del Chi-quadrat estàndard amb els de Monte Carlo per a totes les parelles amb freqüències esperades < 5 .

S'observa que els resultats del contrast Chi-quadrat es mantenen robustos en aplicar la simulació de Monte Carlo ($B = 10.000$). En cap cas rellevant hi ha hagut canvi de significació.




Annex 9: Correlació Spearman entre variables numèriques

Només dues correlacions assoleixen significació estadística: EDAT×N_ASSIG ($\rho = -0,246$), que indica que els estudiants de més edat cursen menys assignatures, probablement per compatibilitzar amb la feina, i EDAT×P_ASSIST ($\rho = -0,111$), una associació molt feble però significativa segons la qual els estudiants més grans tendeixen a assistir lleugerament menys. La resta de correlacions no és significativa.




5. EFA


Annex 10: Comunalitats variables motius de no assistència




Annex 11: Comunalitats variables estratègies d'assistència




Annex 12: Comunalitats variables ús de la IA



Annex 13: Càrregues factorials – Ús de la IA (càrregues > 30, negreta > 50)




Annex 14: Correlació entre els factors d'Estratègies i l'assistència




6. Logit explicatiu

Annex 15: Calibration plot



Annex 16: Leverage vs Residus de Pearson estandarditzats



Annex 17: Anàlisi de sensibilitat — OR complet vs. sense observacions atípiques


Variable	OR complet	OR sense outliers	Canvi (%)	Estable
MOT_DESMOTIVACIO	0,472	0,391	-17,1%	Si
MOT_FORCA_MAJOR	1,428	1,531	+7,1%	Si
EST_AVALUACIO_AC	1,542	1,779	+15,4%	Si
IA_SUBST_num	0,687	0,654	-4,7%	Si
T_AVALContinuada	8,232	15,098	+83,4%	No
CURS_1R	2,679	2,844	+6,1%	Si
NOTA_num	1,624	1,927	+18,7%	Si
MOT_DESMOTIVACIO:CURS_1R	2,792	2,768	-0,9%	Si

7. SEM

Annex 18: Resum dels indicadors utilitzats en el SEM


Indicador	Què mesura?	Valor recomanat
CFI	Compara l'ajust del model amb un model nul on les variables no estan relacionades.	$\geq 0,95$
TLI	Avalua l'ajust del model tenint en compte la seva complexitat.	$\geq 0,95$
RMSEA	Estima l'error d'ajust que tindria el model en la població.	$\leq 0,08$
SRMR	Diferència mitjana entre les correlacions observades i les reproduïdes pel model.	$\leq 0,08$
Càrrega factorial (λ)	Indica la força de la relació entre un ítem observat i el constructe latent. Mostra fins a quin punt l'ítem representa el factor que està mesurant; com més alta és la càrrega, més informació aporta l'ítem sobre el constructe.	$\geq 0,50$ acceptable; $\geq 0,70$ indica una relació forta
AVE	Proporció de variància dels ítems explicada pel constructe latent.	$\geq 0,50$
Omega (ω)	Consistència interna dels ítems que formen el constructe.	$\geq 0,70$

Annex 19: Càrregues factorials estandarditzades del CFA per cada constructe




8. Logit predictiu

Annex 20: Corba Precision – Recall del lògit predictiu (OOF train)



Annex 21: Corba ROC sobre el test




Annex 22: Matriu de confusió del logit

Valor Observat	Irregular	TN 25	FP 2
	Regular	FN 18	TP 23
		Irregular	Regular
		Valor Predit	

9. Random forest

Annex 23: Matriu de confusió de RF-B



Annex 24: Dependence plot RF-A – MOT_DESMOTIVACIÓ

